文档类型	学习讲义（自学用）	版　　本	3.0（公式版）
适用对象	零基础，需高中物理与基础代数	配套项目	acoustic-lab/（可运行代码）
内容来源	韩纪庆等《语音信号处理（第 3 版）》；王泉《声纹技术：从核心算法到工程实践》；赵力《语音信号处理（第三版）》；梁瑞宇等《语音信号处理实验教程》；柳若边《深度学习语音识别技术实践》；朱柯佳（2021）、陆云才等（2023）变压器声纹文献；项目实测数据		
在线仓库	github.com/Lzq2190/voiceprint-lab（讲义、代码、图表与数据；仓库说明见第 0 讲）		
说　　明	书中公式按标准形式用 KaTeX 排版并标注出处、逐条编号；每讲附推导详解（符号表、逐步推导、数值算例、代码对应、失效条件）；全部图表由配套脚本实测生成		

信 号 处 理 与 识 别 系 列

声纹信号处理

从零开始的学习讲义

信号 → 特征 → 神经网络 → 声纹识别

共 17 讲 + 3 个工程专题 · 每部分含目标、做法、推导与自检

配套复现项目 acoustic-lab　·　全部图表为脚本实测生成

github.com/Lzq2190/voiceprint-lab

2026 年 11 月

目　录

共 20 节（17 讲 + 3 个工程专题）　·　页码为正文页码

第 0 讲　先读这个：怎么用这份讲义 …… 1

第 1 讲　声音是什么：从声波到正弦波 …… 5

第 2 讲　数字化与分帧加窗：把声音变成"能算的数据" …… 11

第 3 讲　时域特征：短时能量、过零率、自相关 …… 19

第 4 讲　傅里叶变换：从时间到频率 …… 24

第 5 讲　时频分析：STFT 与不确定原理 …… 32

第 6 讲　MFCC：最常用的声学特征 …… 37

第 7 讲　小波变换与 EMD：超越固定窗的时频分析 …… 45

第 8 讲　神经网络基础：BP 神经网络 …… 52

第 9 讲　卷积神经网络 CNN …… 59

第 10 讲　训练、评估与过拟合 …… 65

第 11 讲　声纹识别概览：任务、流程、与语音识别的区别 …… 71

第 12 讲　声纹评价指标：EER、ROC、DCF …… 75

第 13 讲　经典声纹方法：GMM、UBM、i-vector …… 80

第 14 讲　深度学习声纹：x-vector 与损失函数 …… 85

专题 A　变压器声纹：从物理机理到故障诊断 …… 89

专题 B　经典算法补遗：LPC、VQ、HMM、DTW 与它们的位置 …… 98

专题 C　动手实验清单与资料索引 …… 107

第 15 讲　收尾：学习路线回顾与进阶方向 …… 111

附录　中英术语对照、章节映射与参考文献 …… 114

正文 17 讲按「目标 → 做法 → 推导详解 → 误区 → 自检」编排；另含 3 个工程专题：变压器声纹实战、经典算法补遗、动手实验与资料索引。全部公式由本地 KaTeX 排版并逐条编号，推导详解含符号表、逐步推导、数值算例与代码对应。配套 acoustic-lab/ 生成全部图表与数值；专题引用的文献准确率非本项目实测。

第 0 讲

先读这个：怎么用这份讲义

目标

- 明白这份讲义和"看教材"的区别：它把每一步都摊开写，不留"读者自明"的跳跃。
- 知道 16 讲之间的依赖关系，能判断自己卡在哪一层。
- 把运行环境跑通，能执行 `python run.py --check` 并看到验证数字。

产出

- 一条能跑通的命令，和一张自己画出的学习进度表。
- 对"我到底要学会什么"有一句话的回答。

为什么很多教程看不懂

初学者读信号处理教材最常卡在三处，这份讲义专门针对它们：

第一，公式没有落到数字。书上写 $\Delta f = F_s/N$，读者记住了符号，却不知道"8 kHz 采样、256 点 FFT，频率分辨率就是 31.25 Hz"这个具体结论。本讲义每个公式后面都跟一个带数字的算例，你要能自己把这个数字算出来。

第二，默认你会。教材写"对信号做 Mel 滤波"，默认你知道滤波器组是一堆三角形、默认你知道为什么要取对数。本讲义把这些"默认"全部展开，包括看起来傻的问题：为什么是三角形不是矩形？为什么取 log 不取平方根？

第三，只讲"是什么"，不讲"错了会怎样"。没有反例的知识不牢固。每一讲后面都有"误区"和"破坏性实验"：改一个参数，先预测结果，再运行验证。这个"预测—打脸"的过程才是真正记住的地方。

三条学习原则

原则 1：先跑通，再抠懂 每个算法先在 `acoustic-lab` 里跑出图、跑出数值，让眼睛先"认识"它，再回头推公式。你会发现很多"看不懂的公式"，跑一次图就懂了——因为公式描述的是一件很具体的事。

原则 2：每个算法走"四步闭环" ① 读本讲对应段落，把符号和物理意义对上；② 不看现成代码，自己用 20–30 行 numpy 写一遍；③ 对拍（和 `numpy.fft`、数值梯度、重构误差比）；④ 破坏性实验（改参数，先预测再验证）。第 ③ 步是硬门槛：算法对不对不靠感觉，靠 1e−12 这种量级。

原则 3：别急着上框架 `acoustic-lab` 里的 BPNN 和 CNN 是纯 numpy 手写的——它们就是 PyTorch 替你做的全部事情。等你能自己写梯度检查，再上框架是半天的事；反过来先学框架，就永远只会调 API，遇到 loss 不降只能干瞪眼。

16 讲的依赖关系

表 0-1　16 讲的依赖关系

层	讲次	学完要能回答的问题
第 1 层：信号	第 1–5 讲	一段声音怎么变成数字？怎么变成频谱？为什么时间和频率不能同时精确？
第 2 层：特征	第 6–7 讲	为什么声纹几乎都用 MFCC？小波和 EMD 补上了什么？
第 3 层：模型	第 8–10 讲	神经网络怎么从数据里学规律？为什么不能只看准确率？
第 4 层：声纹	第 11–14 讲	怎么判断"是不是同一个人/同一种工况"？EER 为什么是 2 倍？
收口	第 15–16 讲	整条链路怎么串起来？下一步往哪走？

依赖是硬的：第 6 讲的 MFCC 建立在第 4、5 讲的 FFT 与 STFT 上；第 9 讲的 CNN 建立在第 8 讲的反向传播上。哪一讲读不下去，往回退一讲，不要硬扛。

环境准备

```
# 只需要 Python 3 + 两个库，其余全部手写
pip install numpy pillow

# 进入项目目录，跑通冒烟测试（约 10 秒）
cd acoustic-lab
python run.py --check
```

两个库的分工：`numpy` 只用来做矩阵运算和数学函数（`np.fft` 仅作为"标准答案"用来对拍，我们自己写的算法不调用它）；`pillow` 只用来画图。也就是说，书上的每个算法都在这个项目里被重新实现了一遍，你可以逐行对照。

> **验证装好了** 运行 `python -c "import numpy, PIL; print(numpy.__version__)"`，能打印出版本号即可。若报错，通常是装到了另一个 Python 解释器里——用 `python -m pip install numpy pillow` 保证装到同一个解释器。

材料从哪来：GitHub 仓库

这份讲义以及它引用的全部代码、图表、数据都在一个公开仓库里，不用自己敲。地址是：

```
https://github.com/Lzq2190/voiceprint-lab
```

第一次使用，克隆到本地：

```
git clone https://github.com/Lzq2190/voiceprint-lab.git
cd voiceprint-lab
```

不想装 git 也可以：打开上面那个网址，点绿色 `Code` 按钮 → `Download ZIP`，解压后的目录结构和 clone 完全一样。

表 0-2　仓库里各目录放的是什么

路径	内容	怎么用
`acoustic-lab/`	手写算法与复现项目：DFT/FFT、小波、EMD、MFCC、BPNN/CNN、零依赖绘图引擎	进去执行 `python run.py`

路径	内容	怎么用
`acoustic-lab/data/`	6 段 8 kHz 合成变压器声纹（正常、铁芯松动、直流偏磁、局部放电、短路冲击、风机老化）	可用 `--wav` 换成自己的录音
`acoustic-lab/outputs/`	57 张图、7 个 CSV、`metrics.json`	讲义里的每一张图都来自这里
`guide-v2/index.html`	本讲义的网页版，离线可开，学习进度存在浏览器里	双击打开即可
`guide-v2/pdf/声纹信号处理学习讲义.pdf`	本讲义的 A4 打印版	阅读、打印、装订
`guide-v2/tools/`	重绘插图（`render_light_figs.py`）与重新排版 PDF（`build_pdf.py`）的脚本	改过正文后重跑这两个

保持最新 讲义还在修订时，在仓库目录执行 `git pull` 就能拿到新版；如果本地自己也改过文件而提示冲突，先 `git stash` 再拉，拉完 `git stash pop`。

仓库里故意没有的东西 两本参考教材（韩纪庆《语音信号处理（第 3 版）》、王泉《声纹技术》）的原文与提取文本没有上传——那是版权内容，请自备正版书。仓库只放自写的代码、脚本生成的图表和自撰的讲义正文，所以你不必依赖这两本书也能读完每一讲。

如果你只想跑代码、暂时不读讲义，clone 之后直接 `cd acoustic-lab` 再执行 `python run.py --check`，十秒内会打印出 DFT/FFT/小波重构/EMD/梯度检查的数值验证表。那张表是判断"代码有没有被改坏"的唯一依据，比看任何说明都可靠。

数据说明：为什么用合成声纹

讲义里的实验用 6 类合成变压器声纹（正常、铁芯松动、直流偏磁、局部放电、短路冲击、风机老化），采样率 8 kHz、时长 0.5 s。合成不是为了偷懒，而是因为合成数据有标准答案：我知道第 n 个采样点应该等于多少，才能验证你的 FFT、你的小波重构、你的梯度推导到底对不对。

真实录音的入口也留好了：`python run.py --wav 你的文件.wav`。换真实录音后你会发现准确率不再漂亮——这恰恰是重点，第 10、15 讲会反复讲这件事：合成数据上的 **100%** 只证明实现正确，不证明现场可用。

建议节奏

表 0-3　建议的四周学习节奏

周	内容	每周产出（自检用）
第 1 周	第 1–5 讲	能手写 DFT、画出语谱图、说清不确定原理
第 2 周	第 6–7 讲	能手写 MFCC 全流程、能解释小波与 EMD 的取舍
第 3 周	第 8–10 讲	能手写 BPNN/CNN 并通过梯度检查、会看混淆矩阵
第 4 周	第 11–15 讲	能对一份识别结果说出 EER 与 DCF、能判断论文结论的可信度

自检

- [ ] 我能说出这份讲义与教材的三点区别（有数字、不默认、讲反例）。
- [ ] 我已经跑通 `run.py --check` 并看到验证数值。
- [ ] 我知道 16 讲分四层，并能说出自己现在处于哪一层。
- [ ] 我已经把仓库克隆到本地（或解压了 ZIP），并跑出 `run.py --check` 的验证表。

第 1 讲

声音是什么：从声波到正弦波

目标

- 能写出正弦波 $x(t) = A\sin(2\pi ft + \varphi)$，并说清 A、f、φ 三个量各决定听感的什么。
- 理解"复合音 = 基频 + 倍音叠加"，能解释为什么不同设备/不同人声听起来不同。
- 知道声纹诊断在物理上到底在比什么。

产出

- 用 numpy 合成一个 100 Hz 复合音，并打印出前 10 个采样值。
- 一张"物理量 → 主观感受"的对照表，能自己讲一遍。

先修知识与准备

需要：正弦函数、角度与弧度的区别（1 圈 = 2π 弧度）、`numpy` 的 `sin/arange`。不需要任何信号处理基础，也不需要复数（复数在第 4 讲才出现）。

① 声音是空气的压强波

声带、铁芯、风机叶片振动，推动空气一疏一密地传播，耳朵接收到的是压强随时间的变化。所以声音最本质的数学表示，就是一个随时间变化的量：

符号约定

符号	含义	单位 / 取值
$x(t)$	时刻 t 的瞬时声压（相对大气压的微小起伏）	Pa（帕）
p_0	听阈参考声压，人耳 1 kHz 处刚能听见	$2 \times 10^{-5}\,\text{Pa} = 20\,\mu\text{Pa}$
L_p	声压级（分贝表示法）	dB SPL

工程上几乎不直接用 Pa，而是用 声压级：$L_p = 20\log_{10}\left(x_{\text{rms}}/p_0\right)$。之所以是 20 而不是 10，见本讲「推导详解」。

三个量级要记住，用来判断"这个采样率够不够"：人耳可听范围约 **20 Hz – 20 kHz**；人说话的主要能量在 **60–4000 Hz**（所以电话用 8 kHz 采样就够）；变压器本体噪声主要能量在 **50–2000 Hz**，其中 100 Hz（两倍工频）是磁致伸缩的基频。

为什么变压器是 100 Hz 而不是 50 Hz 铁芯的磁致伸缩（硅钢片随磁场伸缩）与磁感应强度平方成正比，而 B 又以 50 Hz 交变，平方之后频率翻倍——所以本体噪声的基频是 100 Hz。这一点在第 4 讲的频谱图和文献里会反复出现（例如"50 Hz 倍频倒谱系数"就是用这个物理事实设计的特征）。

② 三个物理量，对应三种听感

最简单的声波是正弦波（纯音，音叉近似）：

$$x(t) = A\sin\big(2\pi f t + \varphi\big) = A\sin\big(\tfrac{2\pi}{T}t + \varphi\big), \qquad T = \frac{1}{f} \tag{1-2}$$

A 振幅（Pa）→ 决定响度；有效值 $x_{\text{rms}} = A/\sqrt{2}$　　f 频率（Hz）→ 决定音高；角频率 $\omega = 2\pi f$

φ 初相位（rad）→ 单听纯音听不出，但多频率叠加时决定波形形状　　T 周期（s），一个完整振荡所需时间

为什么写成 $2\pi f$ 而不是 `f`？因为正弦的自变量是角度，不是时间。一秒转 f 圈，一圈 2π 弧度，所以角速度 ω = 2πf（rad/s）。周期与频率互为倒数：$T = 1/f$。

手算一次，比看十遍公式有用 f = 100 Hz → 周期 T = 1/100 = **0.01 s = 10 ms**。若采样率 Fs = 8000 Hz，则一个周期内有 8000 × 0.01 = **80** 个采样点。记住这个"80 点/周期"，第 2 讲算帧长、第 4 讲算频率分辨率都要用它。

③ 真实声音都是复合音

纯音只有一个频率，但真实语音、乐器、变压器噪声都是很多正弦叠加：一个基频 f₀，加上频率是它整数倍的"倍音"（谐波）。

$$x(t) = \sum_{k=1}^{K} A_k \sin\big(2\pi k f_0 t + \varphi_k\big) = A_1\sin(2\pi f_0 t + \varphi_1) + A_2\sin(4\pi f_0 t + \varphi_2) + \cdots \tag{1-3}$$

其中 f_0 是基频，$k f_0$ 是第 k 次谐波，A_k, φ_k 是它的振幅与相位。 这就是傅里叶级数的思想：任何周期信号都能拆成一组整数倍频率的正弦。变压器本体振动以 $f_0 = 100\,\text{Hz}$（工频 50 Hz 的两倍，因为磁致伸缩与电动势平方成正比）为基频， 故障会改变 $A_2, A_3, \ldots$ 的分布——这正是频域能诊断故障的物理依据。

关键结论：音色由谐波比例决定，不由基频决定。钢琴和小提琴弹同一个音（基频相同），听起来完全不同，因为它们的 2 次、3 次…谐波振幅比例不同。这条结论是"用频谱做识别"的全部依据：如果音色只由基频决定，那只需测一个频率就够了，用不着 FFT。

三种常见波形的谐波构成

表 1-1　三种常见波形的谐波构成

波形	谐波构成	听感	在声纹里的对应
纯正弦	只有 f₀	单薄、像音叉	正常运行的铁芯本体声（近似）
方波（近似）	f₀, 3f₀, 5f₀…（奇次），振幅按 1/k 衰减	空洞、像单簧管	铁芯松动后出现的奇次谐波增强
锯齿（近似）	所有次谐波，振幅按 1/k 衰减	明亮、像弦乐	直流偏磁导致的谐波整体抬升

④ 声纹诊断在物理上比的是什么

把上面的逻辑接到设备上：设备状态改变 → 振动力学结构改变 → 谐波结构或瞬态成分改变 → 声音的频谱/时频图改变。所以"声纹"不是玄学，它比的是这几件事：

表 1-2　典型故障的物理机制与声纹表现

故障	物理机制	声纹上的表现
铁芯松动	压紧力下降，片间摩擦与撞击	100 Hz 及其倍频能量变化，叠加周期性敲击脉冲

故障	物理机制	声纹上的表现
直流偏磁	磁化曲线不对称，半波饱和	出现偶次谐波与 50 Hz 倍频族（文献里用"50 Hz 倍频倒谱系数"专抓这个）
局部放电	微小放电产生宽频脉冲	时频图上出现稀疏的竖直亮条（高频、极短）
风机老化	轴承磨损、转速下降	宽带噪声抬升，高频能量比例上升
短路冲击	绕组受巨大电动力	突发冲击声，短时能量骤增

这张表是本讲义后半部分所有特征设计的"物理依据"：第 3 讲的过零率抓高频，第 6 讲的 MFCC 抓谐波包络，第 7 讲的小波抓瞬态，都是因为它们各自对应上表的一行。

⑤ 从 x(t) 到 x[n]：离散化的预告

计算机存不下连续函数，只能存一串数。做法是每隔 $T_s = 1/F_s$ 秒取一个值：

$$x[n] \equiv x(nT_s) = x\left(\frac{n}{F_s}\right), \qquad T_s = \frac{1}{F_s}, \quad n = 0, 1, \ldots, N-1 \tag{2-1}$$

F_s 是采样率（Hz），T_s 是采样间隔（s），N 是总点数，观测时长 $T_{\text{obs}} = NT_s = N/F_s$。例：$F_s = 8000\,\text{Hz}$、时长 $0.5\,\text{s} \to N = F_s T = 8000 \times 0.5 = 4000$ 点，$T_s = 0.125\,\text{ms}$。

这 4000 个数就是你后面所有操作的原材料。打印出来看，它只是一个上下波动的数列——所有的"频率""音色""故障"，都藏在这个数列的变化规律里，需要后面的工具才能挖出来。

动手 1：合成一个复合音并"看"它

```
import numpy as np

fs = 8000                       # 采样率 8 kHz
t = np.arange(fs) / fs          # 1 秒，共 8000 个时刻
f0 = 100                        # 基频 100 Hz（变压器本体噪声基频）

# 基频 + 2、3 次谐波，振幅递减（符合真实声音"谐波越高能量越低"）
x = 1.0*np.sin(2*np.pi*f0*t) + 0.5*np.sin(2*np.pi*2*f0*t) + 0.3*np.sin(2*np.pi*3*f0*t)

print(x[:10])                   # 前 10 个采样值
print('长度', len(x), '最大幅值', round(np.abs(x).max(), 3))
```

运行后你会看到类似 `[0. 0.15 0.29 ...]` 的一串小数，长度 8000，最大幅值约 1.8（三个分量在某个时刻同相叠加的结果，恰好大于 1）。这个"大于 1"很重要：叠加后幅值会超出单个分量，所以后面做 int16 量化时要注意限幅，否则会削波。

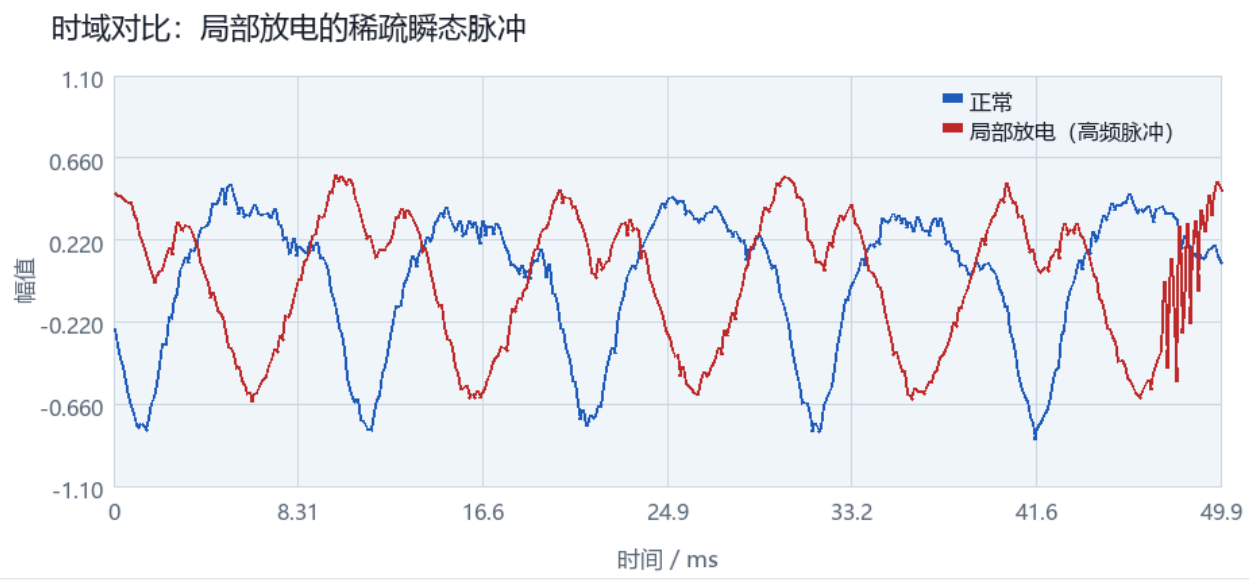


图 1-1　正常与局部放电的时域波形对比：正常样本是连续周期波动，局放样本在平缓背景上突然出现尖脉冲——只看波形就能分辨一类故障

推导详解 • 第 1 讲　声音、分贝与复指数

1. 符号对照表

符号	含义	单位	本讲义典型值
$x(t)$	瞬时声压	Pa	$10^{-3} \sim 1$
p_0	听阈参考声压	Pa	2×10^{-5}
A	峰值振幅	Pa	1（归一化信号）
f_0	基频	Hz	100（变压器）、80–300（人声）
ω	角频率	rad/s	$2\pi f$
c	声速	m/s	343（20 ℃ 空气）

2. 为什么分贝前面是 20 而不是 10

声压是幅度量，声强（单位面积功率）正比于声压的平方：$I = p^2/(\rho c)$，其中 ρ 为空气密度、ρc 为声阻抗。分贝的定义针对的是功率比：

$$L = 10\log_{10}\frac{I}{I_0} = 10\log_{10}\frac{p^2}{p_0^2} = 10\log_{10}\left(\frac{p}{p_0}\right)^2 = 20\log_{10}\frac{p}{p_0} \tag{1-4}$$

所以「20」来自平方，不是另一个约定。同理，幅度谱画 dB 时也是 $20\log_{10}|X|$，而功率谱画 dB 时用 $10\log_{10}P$——因为 $P = |X|^2$ 已经是功率量。混用这两者是频谱图最常见的标定错误。

数值例：把幅值降到原来的 $1/10 \to 20\log_{10}(0.1) = -20\,\text{dB}$；降到 $1/\sqrt{2} \to -3.01\,\text{dB}$（这就是 −3 dB 半功率点的来历）。

3. 为什么一定要引入复数：欧拉公式把两个实数合成一个

$$e^{j\theta} = \cos\theta + j\sin\theta, \qquad \cos\theta = \frac{e^{j\theta}+e^{-j\theta}}{2}, \qquad \sin\theta = \frac{e^{j\theta}-e^{-j\theta}}{2j} \tag{1-5}$$

一个实正弦需要振幅 + 相位两个实数描述，或用一个复数 $X = |X|e^{j\varphi}$ 描述。用复指数的好处是：求导、相乘、平移都变成指数运算，不必反复套三角恒等式。例如把信号延迟 n_0 点：

$$x[n-n_0] \xleftrightarrow{\text{DFT}} X[k]\,e^{-j2\pi k n_0/N}, \qquad \left|e^{-j2\pi k n_0/N}\right| = 1 \tag{1-6}$$

即时延只改相位、不改幅度谱。这条性质解释了为什么声纹特征常丢掉相位：录音起点不同、麦克风距离不同，相位全变，但幅度谱稳。

4. 谐波叠加：一个算到底的例子

设 $f_0 = 100\,\text{Hz}$、$A_1 = 1$、$A_2 = 0.5$、$A_3 = 0.2$，相位全为 0。在 $t = 2.5\,\text{ms}$（即 $2\pi f_0 t = \pi/2$）处：

$$\begin{aligned} x(t) &= \sin(\pi/2) + 0.5\sin(\pi) + 0.2\sin(3\pi/2) \\ &= 1 + 0 - 0.2 = 0.8 \end{aligned} \tag{1-7}$$

把 φ_2 从 0 改成 $\pi/2$，第二项变成 $0.5\sin(\pi+\pi/2) = -0.5$，于是 $x(t) = 1 - 0.5 - 0.2 = 0.3$。三个振幅没变、功率谱没变，波形却明显不同——这就是「相位决定波形形状、幅度谱决定能量分布」的具体含义，也是后面 MFCC 只用幅度谱的代价与理由。

5. 公式 ↔ 代码

```
# 式(1-2)：单频正弦
t = np.arange(N) / fs
x = A * np.sin(2 * np.pi * f * t + phi)

# 式(1-3)：谐波叠加（K 次）
x = sum(A[k] * np.sin(2*np.pi*(k+1)*f0*t + ph[k]) for k in range(K))

# 式(1-4)：声压级
Lp = 20 * np.log10(np.sqrt(np.mean(x**2)) / 2e-5 + 1e-12)
```

`acoustic-lab/src/dsp.py` 里的 `make_signal()` 就是上面三行，六类故障信号的差别只在 A_k 的取值（正常以 100 Hz 为主；直流偏磁额外加 150/250/350 Hz 的奇次倍频）。

6. 边界与失效条件

- A 超过 ADC 满量程 → 削波，波形被削平，凭空产生大量高次谐波，频谱里出现本不存在的峰。任何后续分析都救不回来。
- 叠加只是线性模型；声压很大、传播距离很远时会出现非线性失真，此时 A_k 不再独立。
- 「相位听不出来」只对单个稳态纯音成立；多分量叠加、瞬态、双耳定位时相位是可听的。

误区与注意事项

误区 ① 把"频率高"当成"声音大"。频率和振幅是两个独立维度：高频可以很小声，低频可以很大声。② 以为基频决定音色。决定音色的是谐波比例。③ 把"采样点数多"当成"信息多"。采样率不够时，点再多也只是把混叠后的假信号画得更细（第 2 讲会算给你看）。

自检

- [ ] 我能写出 $x(t) = A\sin(2\pi f t + \varphi)$，并说出 A、f、φ 各影响什么。
- [ ] 我能解释：为什么钢琴和小提琴弹同一个音听起来不一样？
- [ ] 我能算出 100 Hz 正弦在 8 kHz 采样下一个周期有 80 个点。
- [ ] 我能说出变压器本体噪声基频为什么是 100 Hz 而不是 50 Hz。

第 2 讲

数字化与分帧加窗：把声音变成"能算的数据"

目标

- 理解采样定理，并能自己算出一个"混叠"例子。
- 会用 6 dB/bit 估算量化精度，能解释为什么现场用 16 bit。
- 能把一段语音切成帧并加窗，说清 25 ms / 10 ms 这两个数字的来历。

产出

- 一段分帧加窗的代码，输出形状为 (帧数, 帧长)。
- 一张"采样率 × 帧长 → 点数"的对照表，能现场算。

先修知识与准备

需要：第 1 讲的正弦表示、对数运算（dB 的定义）、能看懂 `for` 循环和切片。本节不需要傅里叶知识。

① 采样：为什么必须"两倍"

采样就是把连续信号每隔 Ts 秒"拍一张照片"。问题在于：如果拍得太稀，快慢不同的两个信号会拍出完全一样的照片，你就再也分不清了。这叫混叠（aliasing）。

采样定理（奈奎斯特）说：要无失真地恢复最高频率为 f_max 的信号，采样率必须满足

$$F_s > 2f_{\max} \quad \Longleftrightarrow \quad f_{\max} < \frac{F_s}{2} = f_{\mathrm{Nyq}} \tag{2-2}$$

$f_{\mathrm{Nyq}} = F_s/2$ 称奈奎斯特频率。本讲义 $F_s = 8\,\mathrm{kHz}$，所以有效期率上限是 $4000\,\mathrm{Hz}$；再扣掉抗混叠滤波器的过渡带，工程可用带宽约 $3.4\,\mathrm{kHz}$。注意这是「严格大于」：等号成立时若采样相位恰好落在过零点，信号会整体消失。

手算一个混叠例子：有一个 1000 Hz 的正弦，用 Fs = 800 Hz 采样（明显不够）。采样后它看起来是多少 Hz？混叠频率的算法是

$$f_{\mathrm{alias}} = \min_{k\in\mathbb{Z}} \left| f - kF_s \right| \ \in\ [0, F_s/2] \tag{2-3}$$

取 $k = 1$ 的例子：$f = 1000\,\mathrm{Hz}$、$F_s = 800\,\mathrm{Hz} \to |1000 - 800| = 200\,\mathrm{Hz}$，落在 $[0, 400]$ 内，于是这个 1000 Hz 的信号被永久误认成 200 Hz。关键是：采样完成后信息已经丢失，增加采样点数、换更好的算法都救不回来。所以抗混叠必须是采样之前的模拟低通滤波，这是硬件责任，不是软件责任。

这就是为什么"采样率"是设备选型的第一参数：一旦定了 **8 kHz**，**4000 Hz** 以上的成分注定是假的——不是"变模糊"，而是原封不动地折叠成低频混进来，事后任何算法都分不开。反过来，也不是越高越好——第 0 讲提过，16 kHz 之后识别率几乎不再提升，纯属浪费存储和算力。

4000 Hz 是理论值，工程上还要打折 8 kHz 的奈奎斯特上限是 Fs/2 = **4000 Hz**，这是"能表示"的极限，不是"能用"的带宽。要真做到不失真，采样之前必须先用抗混叠低通把 4000 Hz 以上滤掉；而真实滤波器不是悬崖，它有过渡带——一般从 3400 Hz 就开始滚降，到 4000 Hz 才压够，所以保护带要留 10%–20%。工程上把 **8 kHz** 的可用带宽认作 **3.4 kHz** 左右。电话语音标准之所以是 300–3400 Hz，就是因为要给这个滤波器留出过渡带，而不是因为 3400 Hz 以上没用。

所以选型该这样问 不是问"我要用的最高频率是多少"，而是问"最高频率 × 1.2 是多少，哪个采样率超过它"。比如要分析 3 kHz 的局放超声成分，8 kHz 只剩 3.4 kHz 的可信带，已经贴着边了；要看 4 kHz 以上，必须上 16 kHz。

常见采样率与它的"能力上限"

表 2-1　常见采样率与它的能力上限

采样率	奈奎斯特上限	典型用途	1 秒的数据量（16 bit 单声道）
8 kHz	4000 Hz	电话语音、变压器声纹常用	16000 字节 ≈ 15.6 KB
16 kHz	8000 Hz	语音识别标准（性价比顶点）	31.25 KB
44.1 kHz	22050 Hz	音乐 CD	86.1 KB

② 量化：一个比特值多少分贝

采样只离散了时间，振幅还是连续的。量化把振幅切成有限个等级：B 个比特 → **2^B** 个等级。16 bit → 65536 级，把 −1 到 +1 的电压范围分完，每一级约 3.05×10^{-5}。

量化的误差可以看成均匀分布在 ±q/2 之间的随机噪声（q 是级距），其功率为 $q^2/12$。信号是满幅正弦时功率为 $A^2/2$，两者一比得到著名的经验公式：

$$\mathrm{SNR}_{\mathrm{dB}} = 10\log_{10}\frac{P_x}{P_q} \approx 6.02\,B + 1.76 \quad \text{(满幅正弦输入)} \tag{2-4}$$

$B = 16 \to 6.02 \times 16 + 1.76 \approx 98\,\mathrm{dB}$；$B = 8 \to \approx 50\,\mathrm{dB}$。每多 1 bit 提高约 6 dB，这就是「一个比特 6 dB」的来历。完整推导见本讲「推导详解」。

拿它跟需求比：语音的动态范围约 55 dB，所以 10 bit（62 dB）以上就够；现场设备用 16 bit（98 dB）是为了留出余量——传声器前置放大器的本底噪声、突发冲击声（短路冲击）的峰值，都需要这 40 dB 的余量。

一个容易踩的坑 int16 的取值范围是 **−32768 ~ +32767**，不是 ±32768。所以定点转换要用 `np.clip(x, -1, 1) * 32767`，不要乘 32768；否则 +1.0 会溢出成 −32768，波形上出现一个突然的"反向尖峰"，后面所有特征都会被它污染。

采样与量化的前 14 个点（真实数据）

下面是 `acoustic-lab` 里"正常"样本的实际数据，第四列就是写进 WAV 文件的整数。你可以看到浮点值乘 32767 后取整的过程：

表 2-2　采样与量化的前 14 个点（fs = 8000 Hz，16 bit 量化）

n	t = n•Ts / ms	x[n]（浮点）	int16 量化
0	0.0000	-0.255686	-8378
1	0.1250	-0.346122	-11341
2	0.2500	-0.418829	-13723
3	0.3750	-0.463055	-15172
4	0.5000	-0.537507	-17612
5	0.6250	-0.617214	-20224
6	0.7500	-0.672789	-22045
7	0.8750	-0.711063	-23299
8	1.0000	-0.768570	-25183
9	1.1250	-0.784598	-25708
10	1.2500	-0.765243	-25074
11	1.3750	-0.779919	-25555
12	1.5000	-0.796850	-26110
13	1.6250	-0.736307	-24126

③ 分帧：因为语音是"短时平稳"的

一整句话从"开"到"始"，声学特性完全不同（这叫非平稳）。但发声器官的肌肉运动比声波振动慢得多，所以在**10–30 ms** 这么短的时间窗内，可以近似认为特性不变——这就是"短时平稳假设"，也是所有短时分析的前提。

于是我们把长序列切成一段段"帧"，每帧单独分析。两个参数：

分帧三参数

参数	定义	常用值
帧长 L	一帧包含的采样点数	20–30 ms（准平稳假设的窗口）
帧移 S	相邻两帧起点的间隔（hop）	10 ms
重叠 $L-S$	相邻帧共用的点数	50%–66%，即 $S = L/2 \sim L/3$

为什么必须分帧：语音/设备声的频谱随时间变化，但在一个短窗口内近似不变（短时平稳）。窗太长会跨过变化点，窗太短则频率分辨率不够（见第 5 讲的不确定关系）。

把毫秒换成点数（这一步初学者最常算错，务必自己算一遍）：

$$L = \frac{t_{\text{ms}}\, F_s}{1000}, \qquad S = \frac{s_{\text{ms}}\, F_s}{1000} \tag{2-6}$$

F_s	25 ms 帧长	10 ms 帧移
16000 Hz	$25 \times 16000/1000 = 400$ 点	160 点
8000 Hz	$25 \times 8000/1000 = 200$ 点	80 点

帧数怎么算：长度 N 的序列，帧长 L，帧移 S，不补零时

$$M = \left\lfloor \frac{N - L}{S} \right\rfloor + 1 \tag{2-7}$$

例：$N = 16000$（1 s @ 16 kHz）、$L = 400$、$S = 160 \to \lfloor (16000 - 400)/160 \rfloor + 1 = \lfloor 97.5 \rfloor + 1 = 97 + 1 = 98$ 帧。 最后一帧若不足 L 点，通常补零或丢弃；本讲义的 `frame_signal` 采用「丢弃不足帧」， 所以实际帧数会随实现略有差异，写代码时务必打印形状确认。

98 帧这个数字很关键：1 秒语音原本 16000 个数，变成 98 个"帧"。如果每帧再压成 13 维 MFCC，就只剩 98×13 ≈ 1274 个数——数据量降了一个数量级，而判别信息基本保留。这就是"特征提取"存在的意义。

④ 加窗：为什么不能直接"切一刀"

分帧在数学上等于把信号乘上一个"矩形窗"（窗内为 1，窗外为 0）。而时域相乘 = 频域卷积，所以每一帧的频谱都会被矩形窗的频谱"抹开"：原本一根干净的谱线，会变成主瓣+一串旁瓣，能量泄漏到邻近频率上。

矩形窗的旁瓣只衰减到 −13 dB，泄漏很严重。换成两端平滑下降到 0 的窗（汉宁、汉明），相当于让帧的两端"淡入淡出"，截断处的突变消失，旁瓣就能压到 −31 ~ −43 dB。代价是主瓣变宽——频率分辨率变差。这是一个必须接受的折中。

常用窗函数对比

表 2-3　常用窗函数对比（主瓣宽度与旁瓣衰减）

窗	定义（n = 0…N−1）	主瓣宽度	旁瓣峰值	适用
矩形	w[n] = 1	4π/N（最窄）	−13 dB	要求最高频率分辨率的瞬态分析
汉宁 Hann	0.5 − 0.5cos(2πn/(N−1))	8π/N	−31 dB	通用频谱分析
汉明 Hamming	0.54 − 0.46cos(2πn/(N−1))	8π/N	−43 dB	语音特征提取（最常用）
布莱克曼	0.42 − 0.5cos + 0.08cos(2·)	12π/N	−58 dB	需要极低泄漏的场合

语音和声纹几乎清一色用汉明窗：它在"旁瓣够低"和"主瓣不太宽"之间取得平衡。项目实施里你会在 `wav.py` 里看到这行：

```
w = 0.54 - 0.46*np.cos(2*np.pi*np.arange(400)/(400-1))   # 400 点汉明窗
frame = x[i*160 : i*160+400] * w                          # 取一帧并加窗
```

⑤ 把三步串起来

```
def frame_signal(x, frame_len, hop, win=True):
    n = 1 + (len(x) - frame_len) // hop
    idx = np.arange(frame_len)[None, :] + hop*np.arange(n)[:, None]
    frames = x[idx]                                  # (n, frame_len)
    if win:
        frames = frames * np.hamming(frame_len)      # 逐帧加窗
    return frames

F = frame_signal(x, 400, 160)     # 16 kHz 下 25ms/10ms
print(F.shape)                    # 1 秒 → (98, 400)
```

注意这里用"索引矩阵"一次性取出所有帧，比 for 循环快一个数量级，而且天然支持批量运算——后面做 FFT、做 CNN 输入都靠它。

推导详解 · 第 2 讲　采样定理、混叠与量化噪声

1. 符号对照表

符号	含义	单位	本讲义取值
F_s	采样率	Hz	8000
T_s	采样间隔 $1/F_s$	s	0.000125
f_{Nyq}	奈奎斯特频率	Hz	4000
B	量化位数	bit	16
L/S	帧长 / 帧移	点	200 / 80
q	量化步长 $\Delta = 2A_{\max}/2^B$	—	$2/65536$

2. 采样定理的完整推导（不跳步）

第 **1** 步：把采样建模成与冲激串相乘。定义周期冲激串 $s(t) = \sum_{n=-\infty}^{\infty} \delta(t - nT_s)$，采样信号为

$$x_s(t) = x(t)\, s(t) = \sum_{n} x(nT_s)\, \delta(t - nT_s) \tag{2-5}$$

第 **2** 步：求 $s(t)$ 的傅里叶变换。它是周期函数，展开成傅里叶级数 $s(t) = \frac{1}{T_s}\sum_k e^{j2\pi k t/T_s}$，于是

$$S(f) = \frac{1}{T_s}\sum_{k=-\infty}^{\infty} \delta\!\left(f - \frac{k}{T_s}\right) = \frac{1}{T_s}\sum_{k} \delta(f - kF_s) \tag{2-6}$$

第 **3** 步：时域相乘 = 频域卷积。

$$X_s(f) = X(f) * S(f) = \frac{1}{T_s}\sum_{k=-\infty}^{\infty} X(f - kF_s) \tag{2-7}$$

这是整个采样定理的核心：采样后频谱是原频谱以 F_s 为间隔的无限次平移复制。

第 **4** 步：读出无混叠条件。设原信号带限于 $f_{\max}$，即 $X(f) = 0$ 当 $|f| > f_{\max}$。相邻两份副本的中心相距 F_s，各自半宽 $f_{\max}$。要不重叠，必须

$$F_s - f_{\max} > f_{\max} \quad \Longrightarrow \quad F_s > 2f_{\max} \tag{2-8}$$

满足时，用截止频率 $F_s/2$ 的理想低通（增益 T_s）就能从 $X_s(f)$ 中完整取出 $X(f)$；时域上对应 Whittaker–Shannon 插值 $x(t) = \sum_n x[n]\,\mathrm{sinc}\big((t - nT_s)/T_s\big)$。不满足时两份副本重叠，重叠区不可逆地相加，没有任何数学手段能拆开。

3. 混叠频率公式的来历

一个频率 $f > F_s/2$ 的复指数，在采样点上的值满足

$$e^{j2\pi f n/F_s} = e^{j2\pi(f - kF_s)n/F_s} \cdot e^{j2\pi kn} = e^{j2\pi(f-kF_s)n/F_s} \tag{2-9}$$

因为 $e^{j2\pi kn} = 1$（k, n 都是整数）。所有相差整数倍 F_s 的频率在采样点上完全相同，这叫「频率混叠等价类」。选 k 使结果落进 $[0, F_s/2]$，就是式 (2-3)。更一般地，还要关于 $F_s/2$ 折叠（实信号的共轭对称）：

$$f_{\text{alias}} = \Big| \big(f \bmod F_s\big) - 1\big[f \bmod F_s > F_s/2\big] \cdot F_s \Big| \tag{2-10}$$

算例：$F_s = 8000$，$f = 7500\,\text{Hz} \to 7500 \bmod 8000 = 7500 > 4000 \to |7500 - 8000| = 500\,\text{Hz}$。所以 **7.5 kHz** 的超声成分会伪装成 **500 Hz** 的正常振动。这就是为什么抗混叠滤波器必须在 ADC 之前用模拟电路实现——采样完成再滤波，500 Hz 处的假峰已经和数据融为一体了。

4. 6.02B + 1.76 dB 的完整推导

设满幅正弦 $x(t) = A\sin(2\pi f t)$，量化范围 $[-A, A]$ 被均分成 2^B 级，步长 $\Delta = 2A/2^B$。

信号功率：$P_x = \dfrac{1}{T}\int_0^T A^2\sin^2(2\pi f t)\,\mathrm{d}t = \dfrac{A^2}{2}$。

量化噪声功率：把量化误差 $e = x_q - x$ 近似成 $[-\Delta/2, \Delta/2]$ 上均匀分布的白噪声（在步长足够小、信号足够复杂时成立），则 $P_q = \mathbb{E}[e^2] = \dfrac{1}{\Delta}\int_{-\Delta/2}^{\Delta/2} e^2\,\mathrm{d}e = \dfrac{\Delta^2}{12}$。

代入并化简：

$$\begin{aligned} \text{SNR} &= \frac{P_x}{P_q} = \frac{A^2/2}{\Delta^2/12} = \frac{6A^2}{\Delta^2} = \frac{6A^2}{(2A/2^B)^2} = \frac{6}{4}\,2^{2B} = \frac{3}{2}\,2^{2B} \\ \text{SNR}_{\text{dB}} &= 10\log_{10}\!\left(\tfrac{3}{2}\right) + 20B\log_{10}2 = 1.7609 + 6.0206\,B \end{aligned} \tag{2-11}$$

「1.76」来自 $10\log_{10}(3/2)$（满幅正弦的波形因子），「6.02」来自 $20\log_{10}2$。若输入不是满幅正弦而是均匀分布信号，常数项会变；若信号幅度远小于满量程，有效位数下降，实际 SNR 是 $6.02B + 1.76 - 20\log_{10}(A/A_{\max})$。所以录音电平调到接近但不触及满幅，是提升有效精度的免费手段。

5. 分帧与加窗的定量细节

汉明窗定义（$0 \le n \le L-1$）：

$$w[n] = 0.54 - 0.46\cos\frac{2\pi n}{L-1}, \qquad w_{\text{Hann}}[n] = 0.5 - 0.5\cos\frac{2\pi n}{L-1} \tag{2-12}$$

加窗在时域是逐点相乘，在频域是卷积，因此窗的频谱决定了泄漏形状：

窗	主瓣宽度（相对矩形窗）	最高旁瓣	适用
矩形	1×	−13 dB	频率恰为 Δf 整数倍时才可用
汉宁	2×	−31 dB	通用频谱分析

窗	主瓣宽度（相对矩形窗）	最高旁瓣	适用
汉明	2×	−43 dB	语音/MFCC 默认，旁瓣最低
布莱克曼	3×	−58 dB	强弱信号并存、需极高动态范围

注意代价：主瓣变宽意味着频率分辨率变差。汉明窗主瓣约 $4\pi/L$（归一化角频率），对应约 2 个谱线间隔，所以「用汉明窗后能分开的最小频率间隔」约为 $2F_s/L$。这是选窗时必须算的一笔账。

帧数：$N = 16000$、$L = 400$、$S = 160 \to M = \lfloor (16000 - 400)/160 \rfloor + 1 = 98$ 帧，总覆盖时长 $(M-1)S + L = 97 \times 160 + 400 = 15920$ 点，末尾 80 点被丢弃（不足一帧）。

6. 公式 ↔ 代码

```
# 式(2-1)：采样
t = np.arange(N) / fs                        # Ts = 1/fs 隐含在这里
x = np.sin(2*np.pi*f*t)

# 式(2-4)：量化（B bit，满幅 [-1,1]）
q = np.round((x + 1) * (2**B - 1) / 2)      # 量化到整数
xq = q * 2 / (2**B - 1) - 1                 # 反量化回 [-1,1]

# 式(2-10) / (2-11)：分帧 + 汉明窗
L, S = int(0.025*fs), int(0.010*fs)
frames = np.array([x[i:i+L] for i in range(0, len(x)-L+1, S)])
win = 0.54 - 0.46*np.cos(2*np.pi*np.arange(L)/(L-1))
frames = frames * win
```

7. 边界与失效条件

- 等号不成立：$F_s = 2f_{\max}$ 时，若采样相位恰好落在每个过零点，采到的全是 0。工程上留 10–20% 余量。
- 抗混叠过渡带：实际滤波器不可能陡降到 0，所以 $F_s = 8\,\text{kHz}$ 的可用带宽约 **3.4 kHz** 而非 4 kHz。
- 量化噪声白噪声假设失效：信号幅度很小、或信号是纯正弦且频率与 F_s 成简单整数比时，误差与信号相关，会变成谐波失真而非白噪声，此时 SNR 公式偏乐观。
- 短时平稳假设：25 ms 窗对稳态嗡鸣成立，对「敲击 / 放电脉冲」这类瞬态不成立，需要更短窗或小波（第 7 讲）。

误区与注意事项

误区 ①"采样率越高越好"。超过信号最高频率两倍的部分不带来新信息，只带来存储与算力开销。②"加窗会丢信息"。加窗是抑制截断造成的高频泄漏，不是丢信息；真正丢信息的是一次只看一小段。③"帧长越短越好"。帧太短 → 频率分辨率差（后面 MFCC 就分不开相邻谐波）；帧太长 → 违背短时平稳假设。25 ms 是无数实验折中出来的经验值。④ 忘记 **int16** 的 **32767** 上限，导致削波。⑤ 把奈奎斯特上限当可用带宽。8 kHz 的 4000 Hz 是理论极限，实际留 10%–20% 给抗混叠过渡带，用到 3.4 kHz 就算满了。

自检

- [ ] 我能写出 Fs = 800 Hz 采 1000 Hz 正弦时的混叠频率（200 Hz）并解释原因。
- [ ] 我能用 6 dB/bit 算出 16 bit 约 98 dB 动态范围。
- [ ] 我能算出 16 kHz / 25 ms 帧长 = 400 点、10 ms 帧移 = 160 点、1 秒 = 98 帧。
- [ ] 我能解释汉明窗比矩形窗好在哪里、代价是什么。

第 3 讲

时域特征：短时能量、过零率、自相关

目标

- 能手算短时能量、短时过零率、短时自相关三个特征。
- 能用 $Z/N = 2f/F_s$ 从过零率反推频率。
- 知道为什么时域特征只能做"快筛"，做不了精细分类。

产出

- 每帧三个特征值，画出一条特征随时间的曲线。
- 能用能量曲线定位"短路冲击"发生在第几帧。

先修知识与准备

需要第 2 讲的分帧（帧长、帧移、加窗）。时域特征不需要傅里叶变换，是整条链路里最容易上手的一步，但它能解决不少实际问题，值得先做。

① 短时能量：把一帧的"响度"变成一个数

物理上，能量与振幅的平方成正比（电阻上的功率 $P = U^2/R$）。对离散信号，一帧内所有采样点平方求和，就得到这一帧的能量：

$$E_m = \sum_{n=0}^{N-1} x_m^2[n], \qquad E_m^{\log} = \log\left(1 + \frac{E_m}{a}\right) \tag{3-1}$$

第 m 帧、帧长 N。取对数是为了压缩动态范围：强信号与弱信号在同一个坐标里都看得见。a 是防 $\log 0$ 的小常数。注意能量对幅值增益敏感（幅度翻倍 → 能量变 4 倍），所以跨设备比较前必须做幅度归一化。

手算：一帧 4 个采样点 `[1, -2, 0, 2]`，则 $E = 1^2 + (-2)^2 + 0^2 + 2^2 = \mathbf{9}$。若幅值整体放大 2 倍变成 `[2, -4, 0, 4]`，能量变成 **36**——放大 4 倍，因为能量是幅值的平方。这条性质决定了一个重要事实：能量对幅值极敏感，对增益（音量）不稳定。

> **为什么声纹里很少直接用电能作为主特征** 因为录音设备增益一变，绝对能量就全变了。所以能量更多用来做"端点检测"（找出哪里有人说话/有冲击）和"加权"（能量大的帧更可信），而不是直接做分类特征。

② 短时过零率：最便宜的"频率计"

过零率统计一帧内信号穿过零点的次数，反映"变化有多快"，也就是频率高低：

$$Z_m = \frac{1}{2}\sum_{n=1}^{N-1} \left|\operatorname{sgn}(x_m[n]) - \operatorname{sgn}(x_m[n-1])\right| \tag{3-2}$$

sgn 为符号函数（正取 1、负取 −1、零取 0）。每穿越零点一次，相邻两项之差的绝对值为 2，乘 $1/2$ 恰好记一次过零。它是区分清音/浊音、判断高频成分强弱的粗指标，对直流偏置和低频漂移敏感，因此通常只在预加重与去均值之后使用。

推导 **ZCR** 与频率的关系：一个频率 f 的正弦，每秒穿零 2f 次。帧长 N 个点对应时长 N/Fs 秒，所以一帧内的穿零次数为

$$Z = 2f \cdot \frac{N}{F_s} \quad \Longleftrightarrow \quad f = \frac{Z\,F_s}{2N}, \qquad \frac{Z}{N} = \frac{2f}{F_s} \tag{3-3}$$

一个周期穿越零点两次，一帧时长 N/F_s 内包含 fN/F_s 个周期，故过零 $2fN/F_s$ 次。例：$F_s = 8000$、$N = 200$（25 ms）、$f = 500\,\text{Hz} \to Z = 2 \times 500 \times 200/8000 = 25$ 次；反推 $f = 25 \times 8000/(2 \times 200) = 500\,\text{Hz}$ √。归一化过零率 Z/N 直接正比于 f/F_s。

这个公式在实践中的用法是判清音/浊音：浊音（声带振动，有基频）能量大、过零率低；清音（气流摩擦，像"s"）能量小、过零率高。放到变压器上：风机轴承的宽带噪声、局部放电的高频脉冲，过零率都明显高于 100 Hz 基频主导的正常噪声。

> **注意** 过零率对直流偏置和低频噪声极其敏感：如果信号整体偏了 0.01，本来穿零的地方就不穿了，ZCR 会骤降。所以算 ZCR 前要先去均值（每帧减掉均值），这一步漏掉是最常见的实现错误。

③ 短时自相关：从"重复性"里找周期

自相关衡量信号与"自己平移 k 个点"之后的相似程度：

$$R_m(k) = \sum_{n=0}^{N-1-k} x_m[n]\, x_m[n+k], \qquad k = 0, 1, \ldots, K \tag{3-4}$$

自相关衡量「信号与它自己平移 k 点之后有多像」。周期信号在 k 等于周期（及其整数倍）处出现峰值。 无偏版本会再除以 $N-k$，但那样在 k 大时噪声被放大，工程上常用上式（有偏估计）并配归一化 $\rho(k) = R_m(k)/R_m(0)$。

直觉：如果信号每隔 T 个点重复一次，那么把信号平移 T 之后，波形几乎重合，R(T) 就会很大。所以 **R(k)** 的第二个峰（第一个峰在 **k=0**）出现的位置 **k₀**，就是周期：

$$k_0 = \arg\max_{k \in [k_{\min}, k_{\max}]} \rho(k), \qquad f_0 = \frac{F_s}{k_0} \tag{3-5}$$

例：$F_s = 8000$，自相关在 $k_0 = 80$ 处出现峰 → $f_0 = 8000/80 = 100\,\text{Hz}$ √（变压器基频）。 搜索区间要按目标基频范围设定：找 80–400 Hz 对应 $k \in [20, 100]$；不设下界容易把 $k = 0$ 的 全局最大值（$R(0)$ 恒等于能量）当成答案——这是最常见的实现 bug。

手算：序列 `[1, 0, -1, 0, 1, 0, -1, 0]`（周期为 4 的方波状信号）。R(0) = 1+0+1+0+1+0+1+0 = 4；R(4) = 1·1 + 0·0 + (−1)(−1) + 0·0 = 2，是 k>0 的最大值 → 周期 4 个点。若 Fs = 8000，则 f₀ = 2000 Hz。

自相关的价值在于：它比 FFT 更"抗噪"地找周期，而且计算量小，所以在基频估计、声门周期检测里用得很多。缺点是对非周期成分（噪声、瞬态）不敏感——这也正好是它的定位。

三个特征的分工

表 3-1　三个时域特征的分工

特征	抓什么	对什么故障敏感	弱点
短时能量	响度/幅度	短路冲击（能量突增）、风机老化（整体能量抬升）	受增益影响，不能区分同能量的不同故障
短时过零率	变化快慢 ≈ 频率高低	局部放电（高频脉冲）、风机（宽带噪声）	对直流偏置敏感，高频噪声下会饱和
短时自相关	周期性与基频	铁芯松动（周期结构改变）、直流偏磁（倍频成分）	对非周期瞬态不敏感

④ 为什么只有时域特征不够

设想两种故障：一个是"100 Hz 能量增大"，一个是"200 Hz 能量增大"，但两者总能量相同。它们的短时能量完全一样，过零率也很接近（100 与 200 Hz 都远低于 8 kHz 的一半），自相关只能给出周期变化但很难稳定区分——时域特征把频率信息压成了一个标量，信息在这里就丢了。

这就是必须进入频域的原因：要区分"能量分布在哪些频率上"，就必须把信号拆成一个个频率成分——这正是第 4 讲傅里叶变换要干的事。工程上的惯例是：时域特征做快速筛查和端点检测，频域/时频域特征做精细分类。

⑤ 代码：一次算出三条曲线

```
def frame_feats(x, N=400, S=160):
    n = 1 + (len(x) - N)//S
    idx = np.arange(N)[None,:] + S*np.arange(n)[:,None]
    F = x[idx] - x[idx].mean(1, keepdims=True)      # 去均值（对 ZCR 必须）
    E = (F**2).sum(1)                                # 短时能量
    Z = 0.5*np.abs(np.diff(np.sign(F), axis=1)).sum(1)   # 过零率
    R = np.array([np.correlate(f, f, 'full')[N-1:] for f in F])  # 自相关
    return E, Z, R

E, Z, R = frame_feats(x)
print('能量最大帧', E.argmax(), '峰值', round(E.max(), 1))
```

对"短路冲击"样本跑一遍，你会看到能量曲线在某一帧突然跳起 1~2 个数量级——只看这一条曲线就能定位冲击发生在 **0.5** 秒里的第几毫秒。这就是时域特征最实用的场景。

推导详解 · 第 3 讲　时域特征的完整推导

1. 从连续能量到短时能量

连续信号的总能量是 $E = \int_{-\infty}^{\infty} x^2(t)\,\mathrm{d}t$。对离散、加窗后的第 m 帧，积分换成求和：

$$E_m = \sum_{n=0}^{N-1} \big(x[n]\,w[n-mS]\big)^2 = \sum_{n=0}^{N-1} x_m^2[n] \tag{3-6}$$

注意窗函数平方也进来了：汉明窗两端接近 0.08，平方后仅 0.0064，意味着帧两端的样本对能量贡献被压掉 99%。这是加窗的必然代价，也是帧与帧要重叠 50% 以上的原因——否则边界信息会周期性丢失。

归一化到「平均功率」要除以 $\sum_n w^2[n]$ 而不是 N：$\bar{P}_m = \dfrac{E_m}{\sum_n w^2[n]}$。对汉明窗，$\sum w^2 \approx 0.397L$，除以 L 会低估约 2.5 倍（约 4 dB）。

2. 过零率公式为什么有系数 2

纯正弦 $x(t) = A\sin(2\pi f t)$ 在一个周期 $T = 1/f$ 内穿越零点 2 次（上升沿、下降沿各一次）。一帧时长 $T_{\text{frame}} = N/F_s$，包含 $T_{\text{frame}}/T = fN/F_s$ 个周期，故

$$Z = 2 \cdot \frac{fN}{F_s}, \qquad \frac{Z}{N} = \frac{2f}{F_s}, \qquad f = \frac{Z\,F_s}{2N} \tag{3-7}$$

代入数字：$F_s = 8000$、$N = 200$、$f = 500 \to Z = 2(500)(200)/8000 = 25$。反过来 $f = 25 \times 8000/(2 \times 200) = 500\,\text{Hz}$ √。

这个反推的适用条件很窄：只对单频、无直流、无噪声的正弦成立。真实信号里谐波也会过零，噪声更会制造大量虚假过零，所以过零率只能当「高频成分多不多」的粗指标，不能当基频估计器——基频要靠自相关（下式）。

3. 自相关为什么能测周期：一步不跳的证明

设 $x[n]$ 周期为 P，即 $x[n+P] = x[n]$。把它代入自相关定义：

$$R(P) = \sum_n x[n]\,x[n+P] = \sum_n x^2[n] = R(0) = E, \qquad \rho(P) = \frac{R(P)}{R(0)} = 1 \tag{3-8}$$

即周期整数倍处的归一化自相关恒为 1；而非周期倍数处，乘积正负相消，$\rho(k)$ 明显小于 1。有偏估计 $R(k) = \sum_{n=0}^{N-1-k} x[n]x[n+k]$ 的求和项随 k 增大而减少，所以峰值会随 k 缓慢下降——这反而有助于抑制大 k 处的伪峰。若改用无偏估计（除以 $N-k$），在 $k \to N$ 时只剩极少数样本，方差爆炸，反而更容易选错峰。「有偏」在这里是特性不是缺陷。

峰值搜索必须避开 $k = 0$：$\rho(0) \equiv 1$ 是全局最大值。按目标基频范围设区间：

$$k \in \left[\left\lfloor \frac{F_s}{f_{\max}} \right\rfloor, \left\lceil \frac{F_s}{f_{\min}} \right\rceil\right] \xrightarrow{F_s=8000,\ f\in[80,400]\text{Hz}} k \in [20,\ 100] \tag{3-9}$$

例：在 $k_0 = 80$ 处取到峰 $\to f_0 = 8000/80 = 100\,\text{Hz}$，周期 $T = 1/100 = 10\,\text{ms} = 80$ 点 √。

4. 双门限端点检测：把两个特征合起来用

单靠能量会把强噪声当语音，单靠过零率会把静音段的微弱直流漂移当清音。工程做法是三级状态机：

$$\begin{cases} E_m > \tau_{\text{high}} & \Rightarrow \text{进入「有效段」} \\ \tau_{\text{low}} < E_m \le \tau_{\text{high}} \text{ 且 } Z_m < \tau_Z & \Rightarrow \text{暂留（可能是尾部）} \\ E_m \le \tau_{\text{low}} & \Rightarrow \text{判为静音，回退到高门限越过的起点} \end{cases} \tag{3-10}$$

门限常按背景噪声自适应：$\tau_{\text{low}} = \mu_E + 2\sigma_E$、$\tau_{\text{high}} = 4\tau_{\text{low}}$（前 100 ms 假定为静音用于估计 μ_E, σ_E）。低门限负责「不切掉弱起音」，高门限负责「不被噪声骗开」，两者缺一不可。

5. 公式 ↔ 代码

```
# 式(3-1) 能量 / 式(3-2) 过零率
E = np.sum(frames**2, axis=1)
Z = 0.5*np.sum(np.abs(np.diff(np.sign(frames), axis=1)), axis=1)

# 式(3-4)(3-5) 归一化自相关 + 限定区间找峰
def pitch(x, fs, fmin=80, fmax=400):
    x = x - x.mean()
    r = np.correlate(x, x, 'full')[len(x)-1:]      # R(k), k=0..N-1
    lo, hi = int(fs/fmax), min(int(fs/fmin), len(r)-1)
    k0 = lo + np.argmax(r[lo:hi+1] / (r[0] + 1e-12))
    return fs / k0, k0
```

注意 `np.correlate(x,x,'full')` 取后半段才是 $k \geq 0$ 的部分；写成 `[:len(x)]` 会得到反向序列，峰位置全错。配套项目的 `autocorr_pitch()` 已按上式实现并做了去直流。

6. 边界与失效条件

- 直流偏置：哪怕只有 0.01 的直流，也会让过零率几乎归零。必须先去均值或预加重。
- 倍周期 / 半周期错误：自相关在 $2P, 3P$ 处同样有峰，在 $P/2$ 处对某些波形也有较强峰。取「第一个超过阈值的峰」比取全局最大更稳。
- 帧长不够：要可靠看到 $f_{\min} = 80\,\text{Hz}$ 的一个周期，帧长至少 $F_s/f_{\min} = 100$ 点（12.5 ms @8 kHz），实务上取 2–3 个周期以上。

误区与注意事项

误区 ① 算 **ZCR** 不去均值。直流偏置会让过零率完全失真。② 把能量当"音色"特征。能量是响度，换个录音增益就变。③ 用自相关找周期却不限制 **k** 范围。k 应该限制在"可能的基频范围"内（如 50–500 Hz 对应 k = 16–160 @8 kHz），否则会被倍周期或噪声峰骗到。④ 拿一帧的结果当结论。单帧特征抖动很大，实际都按"一段时间的统计量"（均值、方差、分位数）使用。

自检

- [ ] 我能手算 `[1,-2,0,2]` 的短时能量（9）。
- [ ] 我能用 $Z = 2fN/F_s$ 算出 500 Hz、200 点帧、8 kHz 下的过零率（25 次）。
- [ ] 我能解释自相关峰位置怎么换算成基频。
- [ ] 我能说出时域特征为什么分不开"同能量的不同频率故障"。

第 4 讲

傅里叶变换：从时间到频率

目标

- 把 DFT 理解成"在一组正弦上的投影"，而不是一串看不懂的指数。
- 能手算 4 点 DFT，能算频率分辨率 Δf。
- 理解补零、频谱泄漏、单边谱归一化三个工程细节。

产出

- 手写 DFT，与 `numpy.fft` 对拍误差小于 1e−10。
- 画出复合音频谱，能指着峰说出"这是 100 Hz 基频，这是 2、3 次谐波"。

配套可拖演示 打开同目录下的 `labs.html`（第一个标签页），把探测频率从 0 拖到 4000：当 f 命中真实分量时，圆里的点会朝一边堆叠、质心明显偏离圆心；f 对不上时点铺满一圈、质心回到圆心。那段动画就是 DFT 本身，比任何文字解释都直接。

先修知识与准备

需要：复数与欧拉公式 $e^{j\theta}=\cos\theta+j\sin\theta$、内积（点乘）、求和符号 Σ。这三样就够，不需要任何泛函知识。

① 核心直觉：频谱是"投影系数"

先看一个平面几何事实：向量 $\mathbf{a}=(1,0)$ 与 $\mathbf{b}=(0,1)$ 的内积为 0，叫正交。正交的好处是"互不干扰"：你想知道 a 在 x 方向的分量，就用 a 和 x 轴单位向量做内积，y 方向的存在完全不影响结果。

傅里叶变换做的正是这件事，只不过向量换成了"函数"，内积换成了"相乘再求和/积分"。频率为 f 的复指数 $e^{j2\pi ft}$ 就是"频率轴上的单位向量"。不同频率的复指数彼此正交：

$$\left\langle e^{j2\pi f_1 t},\, e^{j2\pi f_2 t}\right\rangle=\int_0^T e^{j2\pi f_1 t}\,\overline{e^{j2\pi f_2 t}}\,\mathrm{d}t=0\quad(f_1\neq f_2)\tag{4-1}$$

复指数 $e^{j2\pi ft}=\cos(2\pi ft)+j\sin(2\pi ft)$（欧拉公式）就是「频率轴上的单位向量」，不同频率彼此正交，所以「信号在频率 f 上的分量」＝信号与该频率复指数的内积。离散情形下正交性由几何级数保证，完整推导见本讲「推导详解」。

这就是为什么频谱能"分离混在一起的谐波"：各频率互不干扰，各投各的影。理解了这一句，DFT 的公式就不需要背了。

② DFT 公式与每个符号的含义

$$X[k]=\sum_{n=0}^{N-1}x[n]\,e^{-j\frac{2\pi kn}{N}}=\sum_{n=0}^{N-1}x[n]\,W_N^{kn},\qquad W_N\equiv e^{-j2\pi/N},\quad k=0,\dots,N-1 \tag{4-2}$$

符号	含义
$x[n]$	第 n 个采样点（时域，实数或复数）
$X[k]$	第 k 个频率分量（频域，复数）；模长＝强度，辐角＝相位
W_N^{kn}	旋转因子（twiddle factor），第 k 个基函数在 n 处的值
f_k	第 k 根谱线的物理频率 $f_k=kF_s/N$，间隔 $\Delta f=F_s/N$

逐项翻译：对每个 k，把整段信号与第 k 个复正弦逐点相乘再求和。含该频率则同号居多、求和结果大；不含则正负相消、结果近 0。逆变换为 $x[n]=\frac{1}{N}\sum_{k=0}^{N-1}X[k]e^{j2\pi kn/N}$——注意 $1/N$ 只在逆变换一侧，这个约定决定了后面幅度谱要乘 $2/N$。

逐项翻译：对每个 k，把整段信号 x[n] 与第 k 个复正弦逐点相乘再求和。如果信号里含有这个频率，乘积同号居多，求和结果就大；如果信号里没有，正负相消，结果接近 0。`X[k]` 是复数，模长是"这个频率有多强"，辐角是"这个频率的相位"。

> **记住一个换算** 频率分辨率 $\Delta f=F_s/N$，即第 k 根谱线对应 k·Δf。这个数字决定了"两个频率能不能分开"。例：Fs = 8000、N = 256 → Δf = 31.25 Hz，意味着 100 Hz 和 120 Hz 两个成分在图上会糊在一起；N = 1024 → Δf = 7.8 Hz，就能分开。

③ 手算一个 4 点 DFT

取 `x = [1, 0, 1, 0]`（周期为 2 的交替序列），N = 4。基函数是 4 个点上的复指数，取值只有 `1, -j, -1, j` 四种：

$$\begin{aligned}X[0]&=1+0+1+0=2\\X[1]&=1\cdot1+0\cdot(-j)+1\cdot(-1)+0\cdot j=1-1=0\\X[2]&=1\cdot1+0\cdot(-1)+1\cdot1+0\cdot(-1)=2\\X[3]&=1\cdot1+0\cdot j+1\cdot(-1)+0\cdot(-j)=0\end{aligned}\quad\Rightarrow\quad X=[2,\,0,\,2,\,0] \tag{4-3}$$

取 $x=[1,0,1,0]$、$N=4$，基函数在 4 个点上的取值只有 $1,-j,-1,j$。怎么读：$X[0]=2$ 是直流（均值 $\times N=0.5\times4=2$ √）；$X[2]=2$ 对应 $f=2F_s/4=F_s/2$，正是「1,0,1,0」的交替频率；$X[1]=X[3]=0$ 说明没有其他成分。**DFT** 只是把信号往每个频率上射一次影。

怎么读这个结果？X[0]=2 是直流分量（均值×N = 0.5×4 = 2 √）；X[2]=2 对应频率 k=2，即 f = 2·Fs/4 = Fs/2，正是这个"1,0,1,0"序列的交替频率；X[1]=X[3]=0 说明没有其他成分。算一遍就明白：**DFT** 只是把信号往每个频率上射一次影。

④ 三个必须搞清的工程细节

细节 1：单边谱要乘 2/N 才是真实幅值

实信号的频谱是共轭对称的（X[N−k] = conj(X[k])），负频率没有独立信息，所以工程上只看前 N/2+1 根谱线。此时那根谱线的模要除以 N/2 才等于正弦的真实振幅：

$$A[k] = \begin{cases} \dfrac{|X[0]|}{N}, & k = 0 \\ \dfrac{2\,|X[k]|}{N}, & 1 \le k < N/2 \end{cases} \tag{4-4}$$

实信号的频谱共轭对称：$X[N-k] = \overline{X[k]}$，负频率没有独立信息，只看前 $N/2+1$ 根谱线。 幅度为 A 的实正弦 $A\sin(2\pi f t)$ 由 $\pm f$ 两个复指数各分到 $A/2$，DFT 求和后每侧模长为 $AN/2$，因此乘 $2/N$ 才还原成 A。 例：幅值 1.0、$N = 1024 \to |X[k]| \approx 512 \to A = 2 \times 512/1024 = 1.0$ √。 忘了这个归一化就会得出「信号幅值 512 Pa」的荒谬结论。

忘了这个 2/N，画出来的谱幅值是 512 而不是 1，就会得出"信号幅值 512 Pa"这种荒谬结论——这是初学者最常见的错误之一。

细节 2：补零不能提高分辨率

把 256 点信号补零到 1024 点再做 FFT，谱线看起来"更密"（Δf 从 31.25 变成 7.8 Hz），但分辨率并没有变好。因为分辨率由"实际观测时长 T = N_original/Fs"决定，补零只是把同一条曲线插值画得更细——本来糊在一起的两个峰，补零后还是糊在一起，只是多画了几个点。

$$\Delta f_{\text{true}} = \frac{1}{T_{\text{obs}}} = \frac{F_s}{N_{\text{original}}}, \qquad \Delta f_{\text{display}} = \frac{F_s}{M}\ \ (M \ge N_{\text{original}}) \tag{4-5}$$

把 256 点补零到 1024 点，谱线从 31.25 Hz 变「密」到 7.8 Hz，但分辨能力没变： 补零只是对同一条连续频谱曲线做更细的插值采样。本来糊在一起的两个峰，补零后仍糊在一起，只是多画了几个点。 要分辨间隔 5 Hz 的两个成分，观测时长至少 $1/5 = 0.2\,\text{s}$——这就是声纹分析用 0.2–1 s 片段而不是单帧 25 ms 的原因。

要用好这条：需要分辨间隔 5 Hz 的两个成分，观测时长至少 1/5 = 0.2 s。这也是为什么声纹分析一般用 0.2–1 s 的片段而不是 25 ms 单帧。

细节 3：频谱泄漏

如果信号频率不是 Δf 的整数倍（绝大多数情况都是），能量会"漏"到相邻谱线上，出现一个主峰加两边一串小峰。第 2 讲的加窗就是为了压这个泄漏。判断方法：看一个纯正弦的谱，如果除了主峰还有明显的旁瓣，就是泄漏。

⑤ FFT：为什么能快两个数量级

直接按公式算 N 点 DFT，需要约 N² 次复数乘法。N = 1024 时是 100 万次。Cooley–Tukey 的分治思路是：把 N 点 DFT 拆成两个 N/2 点 DFT（偶数点一组、奇数点一组），再递归下去：

$$C_{\text{DFT}} = N^2, \qquad C_{\text{FFT}} = \frac{N}{2}\log_2 N \tag{4-6}$$

N	DFT 复数乘法	FFT	加速比
1024	$1\,048\,576$	$5\,120$	$\approx 205\times$
8192	6.7×10^7	5.3×10^4	$\approx 1260\times$

实时系统要求 FFT 长度取 2 的幂，不是数学要求，而是 Cooley–Tukey 分治要能一直二分下去。

这就是为什么所有实时系统都要求 FFT 长度是 2 的幂：不是数学要求，而是分治算法要求能一直二分下去。

⑥ 代码：三行 DFT 与对拍

```
import numpy as np
def dft(x):
    N = len(x); k = np.arange(N); n = k.reshape(-1,1)
    W = np.exp(-2j*np.pi*k*n/N)        # 基矩阵：每一行是一个频率
    return W @ x                        # 一次矩阵乘法 = 一组内积

x = np.sin(2*np.pi*100*np.arange(256)/8000)
X = dft(x)
print('与 numpy 最大偏差', np.abs(X - np.fft.fft(x)).max())   # ~1e-13
idx = np.abs(X[:128]).argmax()
print('峰值频率', idx*8000/256, 'Hz')                          # ≈ 100 Hz
```

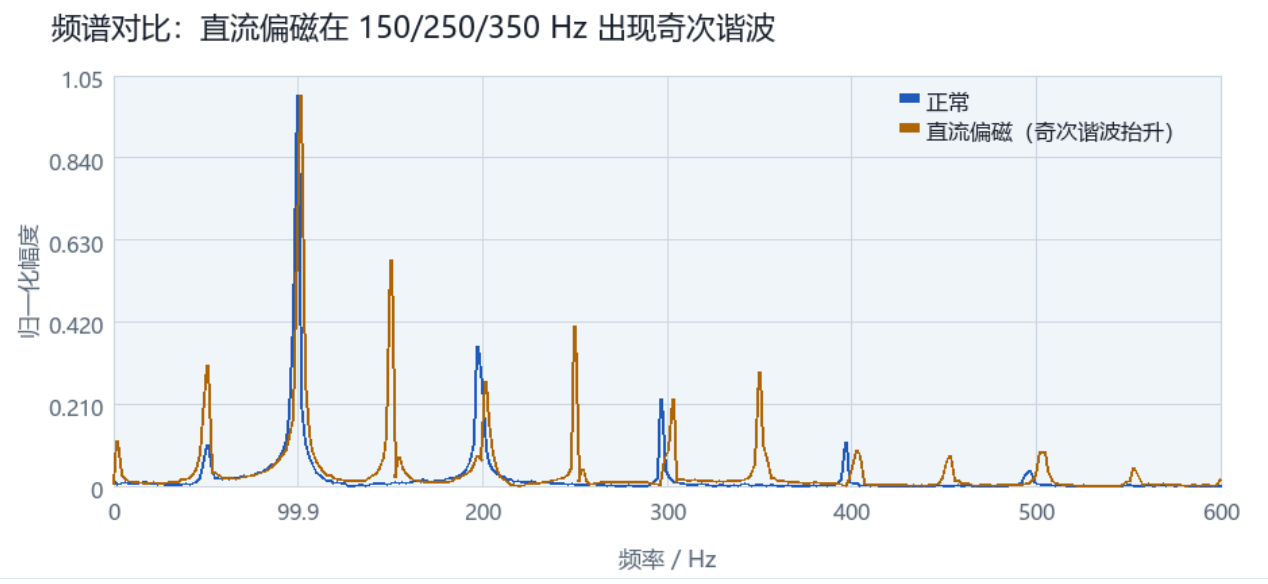


图 4-1　六类声纹的频谱对比：正常以 100 Hz 基频为主，直流偏磁在 150/250/350 Hz（50 Hz 的奇次倍频）出现明显新增峰——不同故障在频域有不同"指纹"

推导详解 • 第 4 讲　DFT 正交性、归一化与 FFT 蝶形

1. 符号对照表

符号	含义	备注
N	DFT 点数	本讲义 256 / 1024
W_N	旋转因子 $e^{-j2\pi/N}$	$W_N^N = 1$
$X[k]$	频域第 k 点	复数，$k = 0..N-1$
Δf	谱线间隔 F_s/N	31.25 Hz @8000/256
T_{obs}	观测时长 N/F_s	决定真实分辨率

2. 离散正交性：用几何级数算出来

把基函数列成向量 $\mathbf{u}_k = \left[W_N^{-kn}\right]_{n=0}^{N-1}$。两个不同基的内积为

$$\langle \mathbf{u}_p, \mathbf{u}_q \rangle = \sum_{n=0}^{N-1} e^{j2\pi(p-q)n/N} = \sum_{n=0}^{N-1} r^n, \qquad r = e^{j2\pi(p-q)/N} \tag{4-7}$$

若 $p = q$，则 $r = 1$，和为 N。若 $p \neq q$ 且 $|p-q| < N$，由等比级数求和

$$\sum_{n=0}^{N-1} r^n = \frac{1 - r^N}{1 - r} = \frac{1 - e^{j2\pi(p-q)}}{1 - e^{j2\pi(p-q)/N}} = \frac{1-1}{1-r} = 0 \tag{4-8}$$

合并得 $\langle \mathbf{u}_p, \mathbf{u}_q \rangle = N\delta_{pq}$。正交性不是公理，是「整数个周期求和为零」的直接结果。这也解释了为什么 DFT 点数必须正好覆盖整数个基函数周期：一旦 k 不是整数（信号频率不落在谱线上），式 (4-8) 的分子不再为 0，能量就漏到相邻谱线——这就是频谱泄漏的数学来源。

3. 逆变换里的 1/N 是怎么定出来的

把 DFT 写成矩阵 $X = Fx$，其中 $F_{kn} = W_N^{kn}$。由上式 $F^{\mathsf{H}}F = NI$（共轭转置），故 $F^{-1} = \frac{1}{N}F^{\mathsf{H}}$，于是

$$x[n] = \frac{1}{N} \sum_{k=0}^{N-1} X[k]\, e^{j2\pi kn/N} \tag{4-9}$$

把 DFT 正变换代进去可验证：$\frac{1}{N}\sum_k \sum_m x[m] e^{-j2\pi km/N} e^{j2\pi kn/N} = \sum_m x[m] \frac{1}{N}\sum_k e^{j2\pi k(n-m)/N} = \sum_m x[m]\delta_{nm} = x[n]$ √。归一化的位置是约定问题：有的库把 $1/\sqrt{N}$ 平分给正反变换（对称约定），numpy 采用「正变换不除、逆变换除 N」。写成代码对拍时，必须先确认用的是哪一套，否则结果会差 N 倍。

4. 共轭对称与 2/N 的完整来历

实信号 $x[n] \in \mathbb{R}$ 时：

$$X[N-k] = \sum_n x[n] e^{-j2\pi(N-k)n/N} = \sum_n x[n] e^{j2\pi kn/N} \underbrace{e^{-j2\pi n}}_{=1} = \overline{X[k]} \tag{4-10}$$

再看幅度为 A 的实正弦，用欧拉公式展开：

$$x[n] = A\sin\frac{2\pi k_0 n}{N} = \frac{A}{2j}\left(e^{j2\pi k_0 n/N} - e^{-j2\pi k_0 n/N}\right) \tag{4-11}$$

正频率 k_0 那一支与 DFT 基相消后求和得 N 个 1，故 $X[k_0] = \frac{A}{2j}N$，模长 $|X[k_0]| = AN/2$；负频率 $N - k_0$ 处同样有 $AN/2$。能量被正负频率各分一半，只看单边就要补回 2 倍，再除以 N 消掉求和积累：

$$A[k] = \frac{2|X[k]|}{N}, \qquad A[0] = \frac{|X[0]|}{N} = \frac{1}{N}\left|\sum_n x[n]\right| = |\bar{x}| \tag{4-12}$$

直流不乘 2，因为它没有「负频率伙伴」，$X[0] = \sum_n x[n] = N\bar{x}$ 本身就直接给出均值。

5. 补零为什么只改显示密度：从 DTFT 看

把 N_0 点信号 $x[n]$ 补零到 M 点，其 M 点 DFT 为

$$X_M[k] = \sum_{n=0}^{N_0-1} x[n]e^{-j2\pi kn/M} = X_{\text{DTFT}}\left(\omega = \frac{2\pi k}{M}\right) \tag{4-13}$$

注意求和上限仍是 N_0：补零没有增加任何新信息，只是把同一条连续频谱 $X_{\text{DTFT}}(\omega)$ 在更密的频率网格上采样。两个频率能否分开，取决于这条连续曲线的主瓣宽度 $\approx 2\pi/N_0$，与采样网格密度 $2\pi/M$ 无关。这就是「$\Delta f_{\text{true}} = F_s/N_0$，$\Delta f_{\text{display}} = F_s/M$」的严格表述。

6. FFT：Cooley–Tukey 按时间抽取的完整分解

第 **1** 步：把求和按 n 的奇偶拆开（设 N 为偶数，$n = 2r$ 与 $n = 2r+1$，$r = 0..N/2-1$）：

$$\begin{aligned} X[k] &= \sum_{r=0}^{N/2-1} x[2r]W_N^{k(2r)} + \sum_{r=0}^{N/2-1} x[2r+1]W_N^{k(2r+1)} \\ &= \underbrace{\sum_r x[2r]W_{N/2}^{kr}}_{E[k]} + W_N^k \underbrace{\sum_r x[2r+1]W_{N/2}^{kr}}_{O[k]} = E[k] + W_N^k O[k] \end{aligned} \tag{4-14}$$

用了 $W_N^{2kr} = e^{-j2\pi(2kr)/N} = e^{-j2\pi kr/(N/2)} = W_{N/2}^{kr}$。$E, O$ 恰是两个 $N/2$ 点 DFT。

第 **2** 步：利用周期性与对称性省掉一半计算。因为 E, O 以 $N/2$ 为周期，且

$$W_N^{k+N/2} = e^{-j2\pi(k+N/2)/N} = W_N^k e^{-j\pi} = -W_N^k \tag{4-15}$$

于是对 $k = 0..N/2-1$ 配对计算（这就是蝶形运算）：

$$\begin{cases} X[k] = E[k] + W_N^k O[k] \\ X[k+N/2] = E[k] - W_N^k O[k] \end{cases} \tag{4-16}$$

一次蝶形 = 1 次复乘 + 2 次复加，同时产出两个输出。

第 **3** 步：复杂度递推。$T(N) = 2T(N/2) + \frac{N}{2}$（每层 $N/2$ 个蝶形），共 $\log_2 N$ 层：

$$T(N) = \frac{N}{2}\log_2 N, \qquad \frac{T(N)}{N^2} = \frac{\log_2 N}{2N} \xrightarrow{N=1024} \frac{1}{205} \tag{4-17}$$

与式 (4-6) 的表格完全一致。递归到最后是 2 点 DFT，输入需按位反转顺序重排（或递归时自动完成）。

7. 频谱泄漏的定量描述

对长度为 N 的矩形窗，其 DTFT 是 Dirichlet 核：

$$W(\omega) = e^{-j\omega(N-1)/2}\,\frac{\sin(N\omega/2)}{\sin(\omega/2)} \tag{4-18}$$

主瓣零点在 $\omega = \pm 2\pi/N$，第一旁瓣约 −13 dB。若信号频率落在两根谱线中间（$k_0 + 0.5$），相邻谱线恰好采在旁瓣上，会出现「主峰降低约 3.9 dB（扇形损失）+ 两侧一串旁瓣」。汉明窗把旁瓣压到 −43 dB，代价是主瓣展宽 2 倍。这就是第 2 讲那张窗函数表的定量依据。

8. 公式 ↔ 代码

```
# 式(4-2)：DFT 基矩阵（每一行是一个频率）
def dft(x):
    N = len(x); n = np.arange(N); k = n.reshape(-1, 1)
    W = np.exp(-2j*np.pi*k*n/N)      # W_N^{kn}
    return W @ x

# 式(4-9)：逆变换，注意 1/N
def idft(X):
    N = len(X); n = np.arange(N); k = n.reshape(-1, 1)
    return np.exp(2j*np.pi*k*n/N) @ X / N

# 式(4-12)：单边幅度谱
A = np.abs(X[:N//2+1]) * 2 / N
A[0] /= 2                            # 直流不乘 2

# 式(4-16)：一个 2 点蝶形（递归 FFT 的核心）
Xe, Xo = fft(x[0::2]), fft(x[1::2])
T = np.exp(-2j*np.pi*np.arange(N//2)/N) * Xo
X = np.concatenate([Xe + T, Xe - T])
```

9. 边界与失效条件

- N 不是 2 的幂时上述二分不成立，需 Bluestein / 混合基算法；numpy 会变慢但不报错。
- 信号含 $> F_s/2$ 成分时 DFT 结果本身已是混叠后的，频域无法补救（回到第 2 讲）。
- 相位谱在 $|X[k]| \approx 0$ 处数值不稳定，取 $\arg X[k]$ 前应先设幅度阈值。
- 浮点误差：DFT 基矩阵是 $O(N^2)$ 内存，$N = 8192$ 时约 1 GB（complex128），大点数必须走 FFT。

误区与注意事项

误区 ① 补零 = 提高分辨率。错，分辨率由观测时长决定。② 忘记 **2/N** 归一化。③ 把 **X[0]** 当"频率 **0** 的分量"却不知它是直流/均值×**N**。④ 拿负频率当"另一种信号"。实信号的负频率只是共轭镜像，没有新信息。⑤ **FFT** 点数随便取非 **2** 的幂。能用但慢，实时系统会要命。

自检

- [ ] 我能用"投影/内积"解释 DFT 在做什么。
- [ ] 我能手算 `[1,0,1,0]` 的 4 点 DFT 得 `[2,0,2,0]`。
- [ ] 我能算出 8 kHz、256 点 FFT 的 Δf=31.25 Hz，并说出它能分开多近的两个频率。
- [ ] 我能解释"补零不提高分辨率"和"频谱泄漏"两件事。

第 5 讲

时频分析：STFT 与不确定原理

目标

- 理解 FFT 丢了时间信息，STFT 如何把它补回来。
- 能说清"窗长"这个唯一旋钮在时间与频率之间怎么交换。
- 会读语谱图：水平条纹、竖直条纹、颜色深浅各代表什么。

产出

- 一张 log-Mel 语谱图，并能在图上指出局放脉冲出现的时刻。
- 能算出一组窗长对应的 Δf，并说明为什么选它。

先修知识与准备

需要第 2 讲的分帧加窗、第 4 讲的 DFT 与 Δf = Fs/N。本讲是把这两件事拼起来，没有新数学。

① FFT 的盲区：它只知道"有哪些频率"，不知道"什么时候"

对整段 0.5 秒信号做一次 FFT，得到的是这段时间的平均频谱。如果局放脉冲只出现在第 200 ms，FFT 会告诉你"存在高频成分"，但完全无法告诉你在第 200 ms。对于稳态故障（铁芯松动、风机老化）这没关系，但瞬态故障（局放、短路冲击）的时间位置本身就是最重要的判别信息。

STFT 的思路很直接：把长信号切成很多短帧，每帧做一次 **FFT**，再把结果按时间排起来。这样每一列是一个时刻的频谱，横着看就是频率随时间的变化。

$$X[m,k]=\sum_{n=-\infty}^{\infty} x[n]\,w[n-mS]\,e^{-j\frac{2\pi kn}{N}} \tag{5-1}$$

m：帧号（时间轴）；k：谱线号（频率轴）；$w[\cdot]$：窗函数；S：帧移。 输出是二维复数矩阵，尺寸 $M\times(N/2+1)$。取模后取对数就是语谱图。 与 DFT 的唯一差别是多了 $w[n-mS]$：把无限长信号截成局部，代价是频谱泄漏（窗的频域旁瓣）。

② 唯一要调的旋钮：窗长

窗长决定了两件事，而且是矛盾的：

$$\Delta t\approx\frac{L}{F_s},\qquad \Delta f\approx\frac{F_s}{L},\qquad \Delta t\cdot\Delta f\approx 1\ \left(\text{严格界：}\ \Delta t\,\Delta f\geq\frac{1}{4\pi}\right) \tag{5-2}$$

这是海森堡不确定原理在工程上的形态：窗长 L 同时决定时间分辨率和频率分辨率， 不可能同时变小。$L=200$ 点 @8 kHz → $\Delta t=25\,\text{ms}$、$\Delta f=40\,\text{Hz}$； $L=800$ 点 → $\Delta t=100\,\text{ms}$、$\Delta f=10\,\text{Hz}$。 选窗就是选一个折中：要抓「敲击的瞬间」用短窗，要分辨「100 Hz 与 120 Hz」用长窗。

带数字算两遍（8 kHz 采样）：

表 5-1　不同窗长对应的时间与频率分辨率（8 kHz）

窗长	点数 L	时间分辨率 Δt	频率分辨率 Δf	适合看
5 ms	40	5 ms	200 Hz	瞬态冲击、局放脉冲
25 ms	200	25 ms	40 Hz	谐波结构（最常用）
100 ms	800	100 ms	10 Hz	精细谐波、低频率成分

看懂这张表，就理解了 STFT 的全部权衡：窗越短，时间越清楚但频率越模糊；窗越长，频率越清楚但时间越模糊。这不是算法不够好，是物理限制（韩书用柯西–施瓦茨不等式证明过，等号只在 Gabor 变换——高斯窗——时成立）。

③ 为什么必须取对数显示

语音/声纹的能量动态范围很大：基频能量可能比第 10 次谐波高 40 dB（1 万倍）。如果按线性幅度画图，弱谐波在图上就是一片全黑，什么也看不见。取对数后：

$$S_{\mathrm{dB}}[m,k] = 20\log_{10}\big(|X[m,k]| + \varepsilon\big) \tag{5-3}$$

线性幅度下，强基频会把弱谐波完全压成一条平线；取 20 log 后动态范围被压缩， 40 dB 的差距在图上变成「一格半」的灰度差，弱结构才看得见。 为什么是 20 log：功率 $\propto$ 幅度平方，$10\log_{10}(A^2) = 20\log_{10} A$。 ε 取 10^{-10} 量级，防止 $\log 0 = -\infty$。

这就是为什么所有语谱图都标着 dB，也是本讲义里所有谱图都用 `log` 显示的原因。

④ 怎么读一张语谱图

下面这张是"局部放电"样本的 log-Mel 语谱图。学会读它，比记公式更有用：

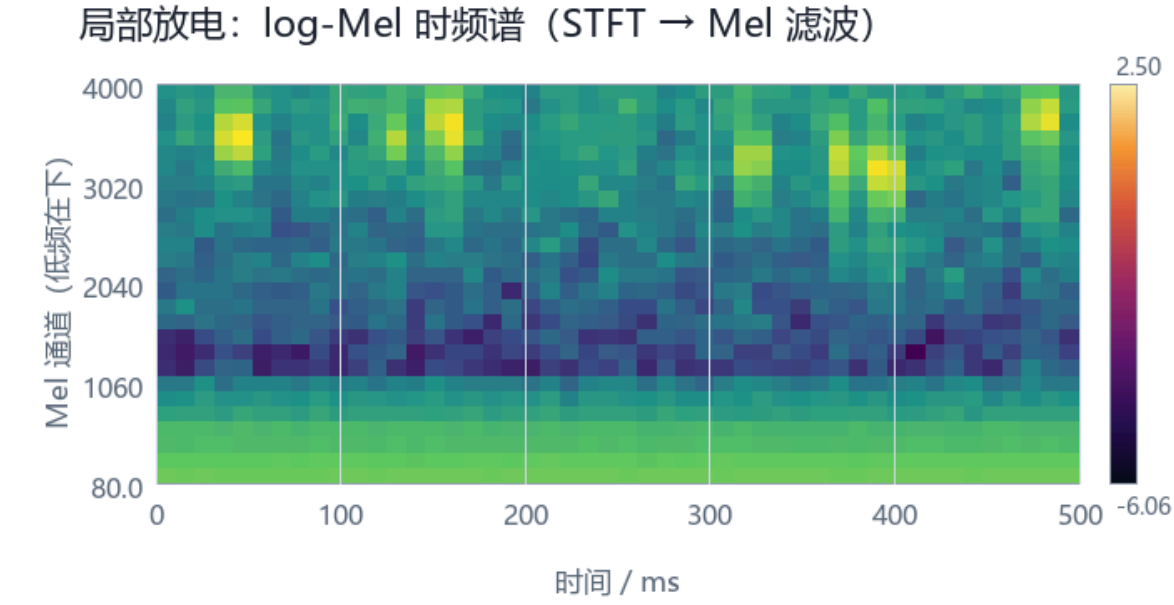


图 5-1　局放样本的 log-Mel 时频图：横轴时间、纵轴 Mel 通道（近似频率）、颜色是能量（dB）。竖直的亮条就是放电脉冲出现的时刻；底部连续的亮带是 100 Hz 基频及其谐波

表 5-2　语谱图常见形态与对应故障

你在图上看到	物理含义	典型故障
底部一条水平亮线	基频（100 Hz）持续存在	正常运行也有
等间隔的多条水平线	谐波族（200/300/400 Hz…）	谐波比例变化 → 铁芯松动、偏磁
竖直亮条（贯穿多个频率）	极短的宽频瞬态	局部放电、短路冲击
整片均匀变亮（高频段）	宽带噪声抬升	风机轴承磨损
低频段出现新的间隔峰	50 Hz 倍频族	直流偏磁

⑤ 代码：从波形到语谱图

```
def stft(x, N=200, S=80, win=True):
    n = 1 + (len(x)-N)//S
    idx = np.arange(N)[None,:] + S*np.arange(n)[:,None]
    F = x[idx]
    if win: F = F * np.hamming(N)
    return np.fft.rfft(F, axis=1)          # (帧数, N/2+1) 复数

X = stft(x)                                 # 8 kHz、25 ms 窗、10 ms 移
S_db = 20*np.log10(np.abs(X) + 1e-8)        # 转 dB
print(S_db.shape)                           # (帧数, 101)
```

注意 `rfft`：实信号只算正频率那一半，输出 101 列（200/2+1），比 `fft` 省一半内存。项目里还多做了一步 Mel 滤波（第 6 讲），把 101 个频率通道压到 26 个，这样图更"干净"、维度更低。

推导详解 • 第 5 讲　STFT、不确定关系与语谱图

1. STFT 的定义与反变换

STFT 就是「加窗 + DFT」在每一帧上重复：

$$X[m,k]=\sum_{n} x[n]\,w[n-mS]\,e^{-j2\pi kn/N}=\big\langle \mathbf{x},\ \underbrace{w[\cdot-mS]e^{j2\pi k\cdot/N}}_{g_{m,k}}\big\rangle \tag{5-4}$$

$g_{m,k}$ 叫 **Gabor 原子**：平移 mS 选时间、调制 k 选频率。反变换（重叠相加 OLA）为

$$x[n]=\frac{\sum_m\sum_k X[m,k]\,e^{j2\pi kn/N}}{\sum_m w[n-mS]},\qquad \text{需满足}\ \sum_m w[n-mS]\neq 0 \tag{5-5}$$

分母是各帧窗的和。汉明窗取 $S=L/2$ 时 $\sum_m w[n-mS]\approx 1.08$ 近似常数，满足 **COLAs**（常数重叠相加）条件，因此可以无损重构；若取 $S=L$（无重叠），汉明窗之和在帧边界处起伏，重构会失真。这就是「帧移不能随便取大」的硬理由。

2. 时频不确定关系：从傅里叶尺度性质推出来

把窗 $w(t)$ 看作一个「波形包」，定义其能量归一化的一、二阶矩：

$$\Delta t^2=\frac{\int (t-\mu_t)^2|w(t)|^2\mathrm{d}t}{\int |w|^2\mathrm{d}t},\qquad \Delta f^2=\frac{\int (f-\mu_f)^2|W(f)|^2\mathrm{d}f}{\int |W|^2\mathrm{d}f} \tag{5-6}$$

由傅里叶变换的尺度性质 $w(at) \leftrightarrow \frac{1}{|a|}W(f/a)$：把窗在时间上压窄 a 倍，频谱必然展宽 a 倍。用柯西–施瓦茨不等式可严格证明 $\Delta t\,\Delta f \geq \dfrac{1}{4\pi}$，等号仅当 w 是高斯函数时取到（Gabor 变换用高斯窗的原因）。

对长度 L 的矩形窗，$\Delta t \approx L/F_s$、$\Delta f \approx F_s/L$，乘积约 1——比理论下界大 4π 倍，因为矩形窗远非高斯。工程上的结论是：乘积是个常数，只能换，不能双赢。

3. 选窗的一笔定量账

窗长 L（@8 kHz）	Δt	$\Delta f = F_s/L$	能分辨的最小频率间隔	适用
80 点（10 ms）	10 ms	100 Hz	约 200 Hz（含汉明主瓣）	瞬态、敲击起点
200 点（25 ms）	25 ms	40 Hz	约 80 Hz	语音 **MFCC** 默认
800 点（100 ms）	100 ms	10 Hz	约 20 Hz	分辨 100/120 Hz 谐波
1600 点（200 ms）	200 ms	5 Hz	约 10 Hz	稳态嗡鸣精细谱

变压器诊断要看 50 Hz 间隔的谐波（100/150/200 Hz），25 ms 窗的 80 Hz 分辨力不够，所以配套项目在画「精细谱」时用的是整段 0.5 s 加长窗，而 MFCC 仍用 25 ms 短窗——同一个系统里可以并存两套时频尺度，各管一件事。

4. dB 换算与动态范围

$$S_{\text{dB}} = 20\log_{10}(|X| + \varepsilon), \qquad P_{\text{dB}} = 10\log_{10}(P + \varepsilon), \qquad P = |X|^2/N \tag{5-7}$$

验证二者一致：$10\log_{10}(|X|^2) = 20\log_{10}|X|$ √。取 20 log 后，幅值比 10^3（60 dB）在灰度上映射成 60 dB 的跨度；若用线性幅度，最大值 1.0 之下 0.001 的成分只有 1/1000 像素亮度，肉眼完全看不见。显示时通常再设下限钳位：$S_{\text{show}} = \max(S_{\text{dB}}, S_{\max} - D)$，$D = 60 \sim 80\,\text{dB}$，把低于最大值 60 dB 以下的全部涂成背景色，避免底噪把图糊满。

5. 公式 ↔ 代码

```
# 式(5-1) STFT：分帧 + 窗 + rfft
F = frame_signal(x, L=200, S=80) * np.hamming(200)
X = np.fft.rfft(F, n=256, axis=1)          # (M, 129) 复数

# 式(5-7) 语谱图（含下限钳位）
S = 20*np.log10(np.abs(X) + 1e-10)
S = np.maximum(S, S.max() - 70)

# 式(5-5) OLA 重构需要的窗和
wsum = np.zeros(len(x))
for i in range(0, len(x)-L+1, S): wsum[i:i+L] += np.hamming(L)
print(wsum.min(), wsum.max())              # 应近似常数、且 > 0
```

6. 边界与失效条件

- 帧移 $S > L$ → 窗和中出现 0，式 (5-5) 分母为零，重构出现周期性空洞。
- 补零到 $N > L$ 只让频率轴变密，不改变本讲的 Δf（回到式 4-13）。
- STFT 是线性时频表示，多分量交叉项不会像 Wigner–Ville 分布那样产生伪影，但也换来分辨率受限。
- 对数显示会压缩强弱差异，做定量幅值比较时必须回到线性域。

误区与注意事项

误区 ① 用一个窗长应付所有故障。看瞬态用短窗、看谐波用长窗，选错了会"看不见"关键信息。② 用线性幅度画语谱图。弱谐波全部淹没。③ 以为 **STFT** 能突破不确定原理。任何改进（小波、EMD）都只是"按需分配分辨率"，不是突破。④ 帧移取得比窗长还大。会漏掉帧与帧之间的信号，瞬态可能整个被跳过。

自检

- [ ] 我能说出 STFT 相比 FFT 多给出了什么信息。
- [ ] 我能算出 8 kHz 下 5/25/100 ms 窗对应的 Δf（200/40/10 Hz）。
- [ ] 我能解释为什么语谱图要取 dB。
- [ ] 我能在语谱图上区分"水平谐波条"和"竖直瞬态条"，并说出各对应什么故障。

第 6 讲

MFCC：最常用的声学特征

目标

- 能完整说出 MFCC 的 7 个步骤，并解释每一步"模拟了人耳的什么"。
- 能算出 Mel 滤波器的中心频率，理解为什么低频密、高频疏。
- 知道为什么最后要用 DCT、为什么加一阶二阶差分才是关键。

产出

- 一段 MFCC 代码，输出 (帧数, 13) 与 (帧数, 39)。
- 一张 Mel 滤波器组图，能指着说"这是第 3 个滤波器的三角"。

先修知识与准备

需要第 4 讲的 FFT 与功率谱、第 5 讲的加窗与帧参数、以及对数运算。DCT 会在本节内讲清，不需要提前学。

① 为什么不能直接拿频谱当特征

第 5 讲的语谱图其实已经能用了——把 101×48 的矩阵直接喂给 CNN 就是"频谱图 + CNN"的方案（第 9 讲会做）。但作为向量特征它有三个问题：维度高（每帧 101 维）、相邻频率高度相关（冗余）、对人耳不敏感的高频区给了过多权重。

MFCC 就是为了解决这三点，用一条"人耳仿真流水线"把一帧 400 个采样点压成 13 个数。下面是完整 7 步，每一步都标注它在模仿人耳的哪个环节。

② 第 1 步：预加重

$$y[n] = x[n] - \alpha\, x[n-1], \qquad H(z) = 1 - \alpha z^{-1}, \quad \left|H(e^{j\omega})\right|^2 = (1-\alpha)^2 + 4\alpha \sin^2\frac{\omega}{2} \tag{6-1}$$

α 通常取 0.95–0.97。这是一阶高通，约 6 dB/倍频程，用来抵消口唇辐射造成的高频衰减（语音）。但设备声纹要慎用：变压器判别信息集中在 100 Hz 基频及其低次谐波，预加重会把这一段相对压低，等于扔掉主要特征。本讲义流程中默认 $\alpha = 0.95$ 仅用于演示，实际设备诊断建议 $\alpha = 0$ 或 0.5 以下。

为什么需要它？声带产生的声音经过口腔辐射出去时，高频能量会以约 6 dB/倍频程衰减。预加重把这个倾斜"抬平"，让 FFT 之后的频谱更好分析、动态范围更小。

注意（这条对变压器声纹很关键） 预加重是为语音设计的。变压器声纹的主要判别信息在 100 Hz 低次谐波上，预加重会把低频相对压低——所以做设备声纹时，很多工作会跳过预加重或改用很小的 α。这是"语音方法迁移到设备声纹"时最典型的坑之一。

③ 第 2–3 步：分帧、加窗、FFT 取功率谱

$$P[k] = \frac{\left|X[k]\right|^2}{N}, \qquad k = 0, 1, \ldots, \frac{N}{2} \tag{6-2}$$

流程：帧长 25 ms、帧移 10 ms、汉明窗（第 2 讲）→ 每帧做 N 点 FFT（$N = 256$ 或 512，补零到 2 的幂）→ 取模平方并除以 N 得功率谱。 以 8 kHz、25 ms（200 点）、补零到 256 为例，得 129 根谱线，间隔 $8000/256 = 31.25\,\text{Hz}$。

以 8 kHz、25 ms（200 点）为例，补零到 256 点做 FFT，得到 129 根谱线，频率间隔 8000/256 = 31.25 Hz。

④ 第 4 步：Mel 滤波器组——把人耳的"非线性"装进来

人耳对频率的感知不是线性的：100 Hz 与 200 Hz 的差别听起来很大，而 3000 Hz 与 3100 Hz 几乎听不出。为了让特征符合听觉，用 Mel 刻度重排频率轴：

$$m(f) = 2595 \log_{10}\left(1 + \frac{f}{700}\right), \qquad f(m) = 700\left(10^{m/2595} - 1\right) \tag{6-3}$$

例：$f = 0 \to 0$ mel；$f = 1000\,\text{Hz} \to 2595\log_{10}(2.4286) \approx 1000$ mel（巧合）；$f = 4000\,\text{Hz} \to 2595\log_{10}(6.714) \approx 2146$ mel。 700 Hz 是经验折点：低于它对频率近似线性，高于它近似对数。 在 Mel 轴上等间隔放 M 个三角滤波器，映射回 Hz 后低频窄而密、高频宽而疏，正好模仿人耳。

做法：在 Mel 轴上等间隔放 M 个三角滤波器（通常 M = 24~26），每个滤波器的中心在 Mel 轴上等距，覆盖 0 到 Fs/2。因为 Mel 轴是压缩过的，映射回 Hz 之后，低频的滤波器又窄又密，高频的又宽又疏——这正是人耳的频率分辨特性。

8 kHz 采样、26 个滤波器时的中心频率（前 10 个）

表 6-1　8 kHz、26 个 Mel 滤波器的中心频率与带宽（前 10 个）

序号	1	2	3	4	5	6	7	8	9	10
中心频率 / Hz	51	106	165	228	296	368	445	528	616	711
带宽 / Hz	51	55	59	63	68	72	77	83	88	95

看带宽这一行：从 51 Hz 一路涨到 95 Hz，后面的滤波器的带宽会到 300 Hz 以上。所以 MFCC 在 100–500 Hz 这一段的分辨率最高——刚好覆盖了变压器声纹最关心的基频与低次谐波。

每个滤波器的输出是该频带内的加权能量和：

$$E_m = \sum_{k=0}^{N/2} P[k]\, H_m[k], \qquad H_m(k) = \begin{cases} 0, & k < f_{m-1} \\ \dfrac{k - f_{m-1}}{f_m - f_{m-1}}, & f_{m-1} \le k < f_m \\ \dfrac{f_{m+1} - k}{f_{m+1} - f_m}, & f_m \le k \le f_{m+1} \\ 0, & k > f_{m+1} \end{cases} \tag{6-4}$$

f_{m-1}, f_m, f_{m+1} 是第 m 个三角滤波器的左端点、中心、右端点（已换算到 FFT 谱线索引），且相邻滤波器重叠 50%，保证 $\sum_m H_m[k] = 1$（能量不凭空增减）。 这一步把 129 根谱线压成 26 个数，同时完成「降维 + 按听觉加权」。 频率到谱线索引的换算是 $k = fN/F_s$，写错这个是最常见的 off-by-one 来源。

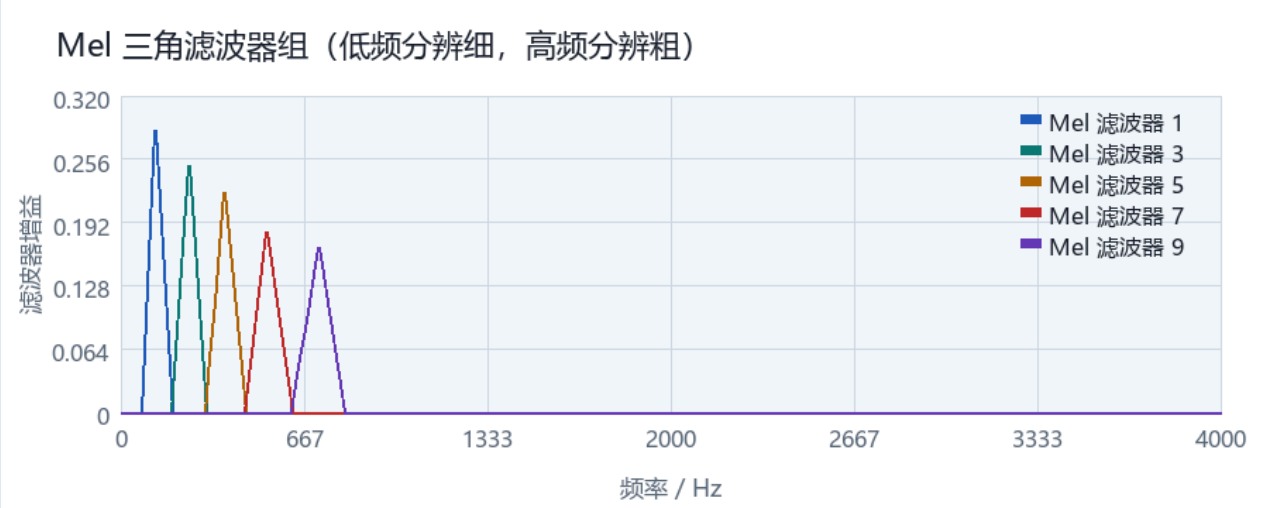


图 6-1　26 个三角滤波器在频率轴上的排布：低频尖而密，高频宽而疏，这就是 Mel 刻度的形状

⑤ 第 5 步：取对数

$$L_m = \ln\left(E_m + \varepsilon\right) \tag{6-5}$$

两个理由。感知上：人耳对响度的响应近似对数（这正是 dB 存在的原因）。 工程上：声源与信道在时域是卷积 $x * h$，频域变相乘 $X \cdot H$，取对数后变相加 $\log|X \cdot H| = \log|X| + \log|H|$，信道影响退化成一个加性常量， 后面的倒谱均值归一化（CMN）可以直接把它减掉。这一步是「倒谱」名称的由来 （cepstrum = spectrum 前四个字母倒过来），也是同态信号处理的核心。

两个理由。物理上：人耳对响度的感知近似对数（这也是 dB 存在的原因）。工程上：声源与信道在时域是卷积（x 经过信道 h 变成 x*h），在频域是相乘，取对数后变成相加——于是信道的影响变成一个加性常量，后面的倒谱均值归一化（CMN）能直接把它减掉。这一步是"倒谱"这个名字的由来（cepstrum = spectrum 的前四个字母倒过来）。

⑥ 第 6 步：DCT，把 26 维压成 13 维

相邻的 Mel 通道高度相关（第 3 个和第 4 个滤波器覆盖的频带是重叠的），需要去相关。DCT（离散余弦变换）就是为此设计的正交变换：

$$c_i = \sqrt{\frac{2}{M}} \sum_{m=1}^{M} L_m \cos\left[\frac{\pi i}{M}\left(m - \tfrac{1}{2}\right)\right], \qquad i = 0, 1, \ldots, M-1 \tag{6-6}$$

这是 DCT-II 型（正交归一化版本）。c_0 反映总能量（对增益敏感，常丢弃或单独用）， $c_1 \ldots c_{12}$ 反映频谱包络的形状，通常保留前 13 个系数。 为什么有效：Mel 对数谱是一条平滑曲线，能量集中在「倒频率」低的系数上—— 前几个系数就描述了整条包络，后面的对应快速起伏（多为噪声）。丢掉后面的既降维又降噪。 DCT 与 PCA 目的一样（去相关 + 能量集中），但基是固定余弦、不需从数据里学，所以极快且换数据集不用重算。

为什么 DCT 有效？因为 Mel 对数谱是一条平滑的曲线，能量集中在"低频"（即系数下标小的那几个）——前几个系数就描述了整条包络的形状，后面的系数对应快速起伏的细节（多为噪声）。丢掉后面的系数，既降维又降噪。

注意：DCT 与 PCA 目的相同（去相关+能量集中），但 DCT 的基是固定的余弦函数，不需要从数据里学，所以计算极快、也不存在"换数据集就要重算"的问题。

⑦ 第 7 步：加一阶、二阶差分（这一步比加维度重要得多）

静态 MFCC 描述的是"这一帧的频谱形状"，但声音是动态的：辅音到元音的过渡、敲击的起始沿，信息都在变化里。差分特征就是帧间的斜率：

$$d_t = \frac{\sum_{n=1}^{N} n\left(c_{t+n} - c_{t-n}\right)}{2\sum_{n=1}^{N} n^2} \xrightarrow{N=2} \frac{(c_{t+1} - c_{t-1}) + 2(c_{t+2} - c_{t-2})}{10} \tag{6-7}$$

这不是简单相减，而是对局部窗口做最小二乘直线拟合后的斜率：用 $\pm n$ 对称的样本估计 $\partial c/\partial t$，分母 $2\sum n^2$ 正是正规方程的解。$N = 2$ 时分母 $2(1^2 + 2^2) = 10$。二阶差分 dd_t 即对 d_t 再做一次同样运算。维度：13 静态 + 13 一阶 Δ + 13 二阶 $\Delta\Delta$ = **39** 维。

维度变化：13（静态）+ 13（一阶 Δ）+ 13（二阶 ΔΔ）= **39** 维。

一条被反复验证的实测结论 韩书表 3-3 的实验结果是：单纯增加倒谱维数（13 → 20 → 30）几乎不降低误识率；而加入一阶、二阶差分能让误识率下降约 20%。原因就是上面说的：静态特征丢掉了时间演化信息。所以做声纹一定要加 Δ/ΔΔ，别只堆维度。

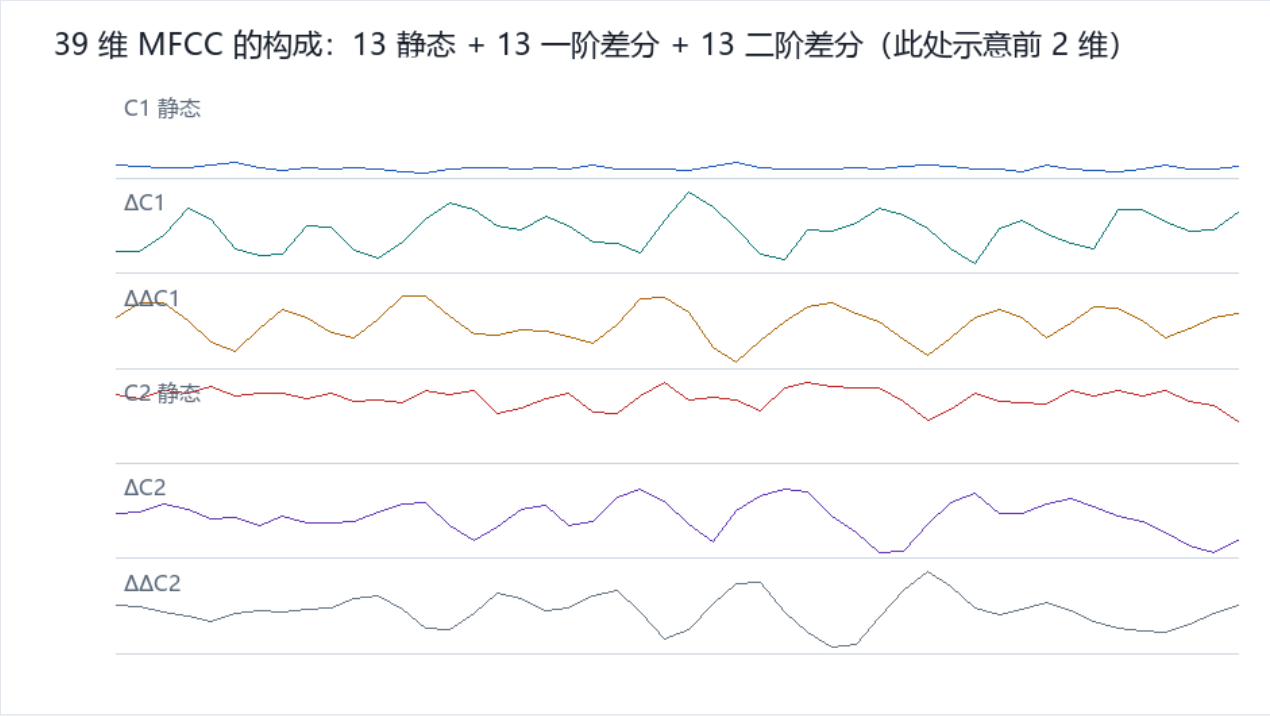


图 6-2　39 维 MFCC 的构成：C1 静态、ΔC1 一阶差分、ΔΔC1 二阶差分（此处示前 2 维）。差分曲线明显比静态曲线"更能看出节奏"

⑧ 维度账与标准化

```
def mfcc(x, fs, n_mels=26, n_ceps=13, N=256, frame=200, hop=80):
    F = frame_signal(x, frame, hop)                # (T, 200)
    P = np.abs(np.fft.rfft(F, N, axis=1))**2 / N   # (T, 129)
    fb = mel_filterbank(n_mels, N, fs)             # (26, 129)
    E = P @ fb.T + 1e-10                           # (T, 26)
    C = dct(np.log(E))[:, :n_ceps]                 # (T, 13)
    return C

C  = mfcc(x, 8000)               # (T, 13)
D  = delta(C); DD = delta(D)
feat = np.hstack([C, D, DD])     # (T, 39)
```

算一下压缩比：0.5 秒、8 kHz = 4000 个采样点；25 ms/10 ms 分帧 → 23 帧；23×39 = **897** 个数。压缩到原来的 1/4.5，而判别信息基本保留。

最后一步是倒谱均值归一化（**CMN**）：每个系数减去它在整段语音上的均值。这一步专门对付信道差异（不同麦克风、不同距离），是声纹系统必备的后处理。

推导详解 · 第 6 讲　MFCC 七步，每一步都推到底

1. 全局符号对照表

符号	含义	本讲义取值	形状
$x[n]$	原始采样序列	0.5 s @8 kHz	(4000,)
F	分帧矩阵	25 ms / 10 ms	(T, 200)
$P[k]$	功率谱	256 点 rfft	(T, 129)
$H_m[k]$	第 m 个三角滤波器	$M=26$	(26, 129)
E_m	Mel 通道能量	—	(T, 26)
c_i	倒谱系数	取前 13	(T, 13)
d_t, dd_t	一阶 / 二阶差分	窗宽 $N=2$	(T, 13)

2. 第 1 步：预加重的传递函数与频率响应

差分方程 $y[n]=x[n]-\alpha x[n-1]$ 取 Z 变换：$Y(z)=X(z)-\alpha z^{-1}X(z)$，故

$$H(z)=1-\alpha z^{-1},\qquad H(e^{j\omega})=1-\alpha e^{-j\omega}=(1-\alpha\cos\omega)+j\alpha\sin\omega \tag{6-8}$$

$$|H(e^{j\omega})|^2=(1-\alpha\cos\omega)^2+(\alpha\sin\omega)^2=1-2\alpha\cos\omega+\alpha^2=(1-\alpha)^2+4\alpha\sin^2\frac{\omega}{2} \tag{6-9}$$

代入 $\alpha=0.95$：$\omega=0$ 时 $|H|^2=0.0025$（−26 dB）；$\omega=\pi$ 时 $|H|^2=3.8025$（+5.8 dB）。低频被压掉近 **30 dB**。对语音（判别信息在 1–3 kHz 共振峰）这是好事；对变压器（判别信息在 100–500 Hz）这是灾难。定量结论：若要保留 100 Hz，需 $20\log_{10}|H(e^{j2\pi 100/8000})|\geq -3\,\text{dB}$，反解要求 $\alpha\lesssim 0.45$。

3. 第 4 步：Mel 滤波器边界的完整计算

给定 $F_s = 8000$、$N = 256$、$M = 26$，把 Hz 上下限换成 mel：$m_{\text{low}} = m(0) = 0$，$m_{\text{high}} = m(4000) = 2595\log_{10}(1 + 4000/700) = 2146.1$ mel。在 mel 轴等分 $M + 2 = 28$ 个点：

$$m_j = m_{\text{low}} + j \cdot \frac{m_{\text{high}} - m_{\text{low}}}{M+1} = j \cdot \frac{2146.1}{27} = j \cdot 79.49\ \text{mel}, \quad j = 0, \ldots, 27 \tag{6-10}$$

再反变换回 Hz：$f_j = 700(10^{m_j/2595} - 1)$，最后换成 FFT 谱线索引 $k_j = \left\lfloor \dfrac{(N+1) f_j}{F_s} \right\rfloor$。前几个结果：$f_0 = 0$、$f_1 = 700(10^{79.49/2595} - 1) = 51.0\,\text{Hz}$、$f_2 = 106.1\,\text{Hz}$、$f_3 = 165.2\,\text{Hz}$..... 与讲义正文「前 10 个中心频率」表完全一致。注意分母是 $M+1$ 而不是 M：因为有 M 个三角形，需要 $M+2$ 个边界点（每个三角形用左、中、右三个相邻点），相邻滤波器因此自然重叠 **50%**。

验证归一化：对任意谱线 k，落在它上面的只有相邻两个非零三角形，且二者在该点的值之和为 1，故 $\sum_m H_m[k] = 1$。这保证「滤波组不放大也不衰减总能量」，只是重新分配。

4. 第 5 步：同态解卷积，取 log 到底在解什么

真实录音是声源 s 经过信道 h（麦克风频响、房间反射、距离）：$x = s * h$。取傅里叶变换：

$$X(f) = S(f)\,H(f) \xrightarrow{\log|\cdot|} \log|X| = \log|S| + \underbrace{\log|H|}_{\text{与说话人无关}} \tag{6-11}$$

卷积 → 乘积 → 求和，这三步叫同态解卷积。若信道在一段录音内不变，$\log|H|$ 是一个沿时间轴恒定的偏置；CMN（每维减去整段的均值）恰好把它消掉：

$$\tilde{c}_i[t] = c_i[t] - \frac{1}{T}\sum_{t'=1}^{T} c_i[t'] \;\Rightarrow\; \log|H| \text{ 项被抵消} \tag{6-12}$$

因为 DCT 是线性变换，减均值的操作在 Mel 域和倒谱域等价。这就是「为什么 **MFCC** 要取 **log**」的完整答案：不取 log，信道是乘性的，减均值消不掉；取了 log，信道变加性，一步减法就解决。另外人耳响度感知近似对数（Weber–Fechner 定律），与工程动机正好一致。

5. 第 6 步：DCT-II 的正交性验证

取基向量 $\phi_i[m] = \cos\left[\frac{\pi i}{M}(m - \frac{1}{2})\right]$，$m = 1..M$。用积化和差可证

$$\sum_{m=1}^{M} \phi_i[m]\phi_j[m] = \begin{cases} M, & i = j = 0 \\ M/2, & i = j > 0 \\ 0, & i \neq j \end{cases} \tag{6-13}$$

所以归一化的正交 DCT 系数是 $c_i = \sqrt{2/M}\,\lambda_i \sum_m L_m \phi_i[m]$（$\lambda_0 = 1/\sqrt{2}$，其余为 1），逆变换为 $L_m = \sqrt{2/M}\sum_i \lambda_i c_i \phi_i[m]$。只保留前 **13** 个系数等价于把 **Mel** 对数谱投影到「变化最慢」的 **13** 个余弦基上——低频基描述包络总体形状，高频基描述细节起伏。若把 26 个系数全留下，逆变换能精确还原 L_m；截断到 13 相当于做了一次低通平滑，正好滤掉了通道间噪声。

6. 第 7 步：差分系数是最小二乘斜率，不是随便相减

假设在 t 附近，第 i 维倒谱随时间近似线性：$c_{t+n}^{(i)} \approx a + bn$，其中 b 就是想要的斜率 d_t。对 $n = -N, \ldots, N$ 最小化 $\sum_n \left(c_{t+n} - a - bn\right)^2$。对 a, b 求偏导置零：

$$\begin{aligned}\frac{\partial}{\partial a}:\ &\sum_n (c_{t+n}-a-bn)=0 \ \Rightarrow\ a=\frac{1}{2N+1}\sum_n c_{t+n} \quad (\text{因 } \textstyle\sum n=0)\\ \frac{\partial}{\partial b}:\ &\sum_n n(c_{t+n}-a-bn)=0 \ \Rightarrow\ b=\frac{\sum_n n\,c_{t+n}}{\sum_n n^2}\end{aligned} \tag{6-14}$$

把正负 n 配对：$\sum_{n=-N}^{N} n\,c_{t+n}=\sum_{n=1}^{N} n(c_{t+n}-c_{t-n})$，$\sum_{n=-N}^{N} n^2=2\sum_{n=1}^{N} n^2$，于是

$$d_t=b=\frac{\sum_{n=1}^{N} n(c_{t+n}-c_{t-n})}{2\sum_{n=1}^{N} n^2},\qquad N=2:\ \frac{1(c_{t+1}-c_{t-1})+2(c_{t+2}-c_{t-2})}{2(1+4)}=\frac{\cdots}{10} \tag{6-15}$$

分母 10 就是这么来的。这个推导说明差分特征对噪声有一定抑制（用了 2N+1 帧拟合而非相邻两帧相减），且窗口越宽越平滑、时间分辨率越差。边界处理：首尾不足 N 帧时通常复制边缘帧，否则前 2 帧的差分恒为 0。

7. 全流程维度账（算到底）

$$\begin{aligned}&0.5\,\text{s}\times 8000=4000\ \text{点}\xrightarrow{L=200,S=80}T=\left\lfloor\frac{4000-200}{80}\right\rfloor+1=48\ \text{帧}\\ &4000\ \text{点}\ \to\ (48,200)\ \to\ (48,129)\ \to\ (48,26)\ \to\ (48,13)\\ &\xrightarrow{+\Delta+\Delta\Delta}(48,39)=1872\ \text{个数}\end{aligned} \tag{6-16}$$

压缩比 $4000/1872\approx 2.1$。若再做时间上的统计池化（各维取均值与标准差）得 78 维，压缩比约 51——这就是第 14 讲 x-vector 之前「手工特征 + 统计量」路线的终点。

8. 公式 ↔ 代码（逐行对应）

```
def mfcc(x, fs, n_mels=26, n_ceps=13, N=256, L=200, S=80, alpha=0.0):
    # 式(6-1) 预加重：y[n]=x[n]-alpha*x[n-1]
    y = np.append(x[0], x[1:] - alpha*x[:-1])
    # 式(2-11) 分帧 + (2-12) 汉明窗
    F = frame_signal(y, L, S) * (0.54-0.46*np.cos(2*np.pi*np.arange(L)/(L-1)))
    # 式(6-2) 功率谱：|X|^2/N
    P = np.abs(np.fft.rfft(F, n=N, axis=1))**2 / N        # (T,129)
    # 式(6-3)(6-4) Mel 滤波器组 → 式(6-5) 能量
    fb = mel_filterbank(n_mels, N, fs)                     # (26,129)
    E = P @ fb.T + 1e-10                                   # (T,26)
    # 式(6-6) 取 log  L_m
    Lm = np.log(E)
    # 式(6-7) DCT-II，取前 n_ceps 列
    C = dct(Lm, type=2, norm='ortho')[:, :n_ceps]          # (T,13)
    # 式(6-15) 一阶/二阶差分
    D, DD = delta(C, N=2), delta(delta(C, N=2), N=2)
    feat = np.hstack([C, D, DD])                           # (T,39)
    # 式(6-12) CMN
    return feat - feat.mean(axis=0)
```

对照 `acoustic-lab/src/dsp.py`：`mel_filterbank()` 里的 `points = np.linspace(mel_low, mel_high, n_mels+2)` 对应式 (6-10) 的 28 个边界点；`delta()` 的分母 `2*sum(n**2)` 对应式 (6-15)。

9. 边界与失效条件

- $E_m=0$ 时 log 发散 → 必须加 ε（10^{-10}）；也可对功率谱设下限。
- 频率上限必须用 $F_s/2$：把 8000 Hz 采样的数据按 16000 Hz 建滤波器组，高频通道全空，特征后半段恒为 0。

- Mel 滤波器数 M 与倒谱维数要匹配：$n_{\text{ceps}} > M$ 没有意义（后面系数恒为 0）。
- CMN 要求同一段内信道不变；若录音中途换了设备，分段做 CMN 才有效。
- 设备声纹的 $f_0 = 100\,\text{Hz}$ 落在第 2–3 个 Mel 滤波器里，而语音的判别信息多在上千 Hz；照搬语音的 **26** 通道配置会把最关键的频带只分到 **2–3** 个通道。可改用线性滤波器组、或把 Mel 下限抬到 50 Hz 后加密低频通道。

误区与注意事项

误区 ① 照搬语音的预加重到设备声纹。会把 100 Hz 基频相对压低，等于扔掉主要判别信息。② 只取 **13** 维静态 **MFCC** 就下结论。不加 Δ/ΔΔ 会白白多出约 20% 的误识。③ 以为 **Mel** 滤波器越多越好。太多会引入冗余和过拟合，26 是语音的经验值；设备声纹常取 24–40，需实验。④ 忘了 **CMN**。换一套录音设备就崩。⑤ 把 **c_0** 当特征用却不理解它。c_0 近似总能量，对增益敏感。

自检

- [ ] 我能按顺序说出 MFCC 七步，并说出每步模仿人耳的哪一部分。
- [ ] 我能用 $m(f) = 2595 \log_{10}(1 + f/700)$ 算出 1000 Hz 约等于 1000 mel。
- [ ] 我能解释为什么低频滤波器密、高频疏。
- [ ] 我知道 13→39 维是怎么来的，也能说出加差分比加维度更有用。

第 7 讲

小波变换与 EMD：超越固定窗的时频分析

目标

- 理解 STFT 的"固定窗"为什么在宽频带信号上吃亏。
- 能说清连续小波、离散小波、EMD 三种方法各自的适用场景与代价。
- 知道 EMD 的三个已知缺陷，不会盲用它。

产出

- 一张小波尺度图，能在图上定位局放脉冲的时刻。
- 一组 IMF 分量图，能说清每层 IMF 对应哪个时间尺度。

先修知识与准备

需要第 4 讲的频域概念、第 5 讲的时频权衡。小波的数学（多分辨分析）可以先跳过，本讲只讲"它在干什么、什么时候用"。

① STFT 的困境：一个窗长管所有频率

第 5 讲说过，窗长决定时间/频率分辨率的分配。问题在于 STFT 用同一个窗长处理所有频率。但实际信号的需求正好相反：

表 7-1　STFT 在宽频带信号上的两难

你关心的成分	需要的分辨率	STFT 的处境
局放脉冲（微秒级、宽频）	时间要极短	用长窗 → 脉冲被抹平，看不出时刻
100 Hz 基频与相邻谐波（间隔 50 Hz）	频率要极窄	用短窗 → 谐波糊成一片

小波的解法是：用"可伸缩的窗"——分析高频时用很短的窗，分析低频时用很长的窗。这正好符合"高频变化快、需要看细；低频变化慢、可以看粗"的直觉。

② 连续小波变换：把"频率"换成"尺度"

$$W(a,b)=\int_{-\infty}^{\infty} x(t)\,\frac{1}{\sqrt{a}}\,\overline{\psi\left(\frac{t-b}{a}\right)}\,\mathrm{d}t,\qquad a>0 \tag{7-1}$$

ψ 是母小波：一小段振荡、两端衰减到 0、且均值为零（容许条件 $C_\psi=\int |\hat{\psi}(\omega)|^2/|\omega|\,\mathrm{d}\omega<\infty$）。$a$ 是尺度：a 大 → 小波被拉宽 → 看低频；b 是平移：直接对应时间位置。 前面的 $1/\sqrt{a}$ 是能量归一化，保证不同尺度下的系数可直接比较。 与 STFT 的根本差别：STFT 窗宽固定，CWT 的窗宽随 a 自动变——低频用长窗、高频用短窗。

尺度与频率的换算关系是理解小波图的关键：

$$f \approx \frac{f_c F_s}{a}, \qquad f_c = \frac{\text{母小波中心频率(归一化)}}{T_s} \tag{7-2}$$

例：$F_s = 8000$、Morlet 的 $f_c \approx 0.8125 \to a = 8 \Rightarrow f \approx 812\,\text{Hz}$；$a = 80 \Rightarrow f \approx 81\,\text{Hz}$。尺度轴是 $1/f$ 关系，所以画 CWT 图时若把 a 当线性频率轴标注，会把 100 Hz 错标成 900 Hz—— 本讲义配套代码曾踩过这个坑，修法是先把尺度对应的频率算出来，再重采样到线性频率轴。

常用的母小波是复 Morlet：一个高斯包络调制的复正弦。用复数小波的好处是能同时得到幅值和相位，幅值图就是"该尺度在该时刻有多强"。

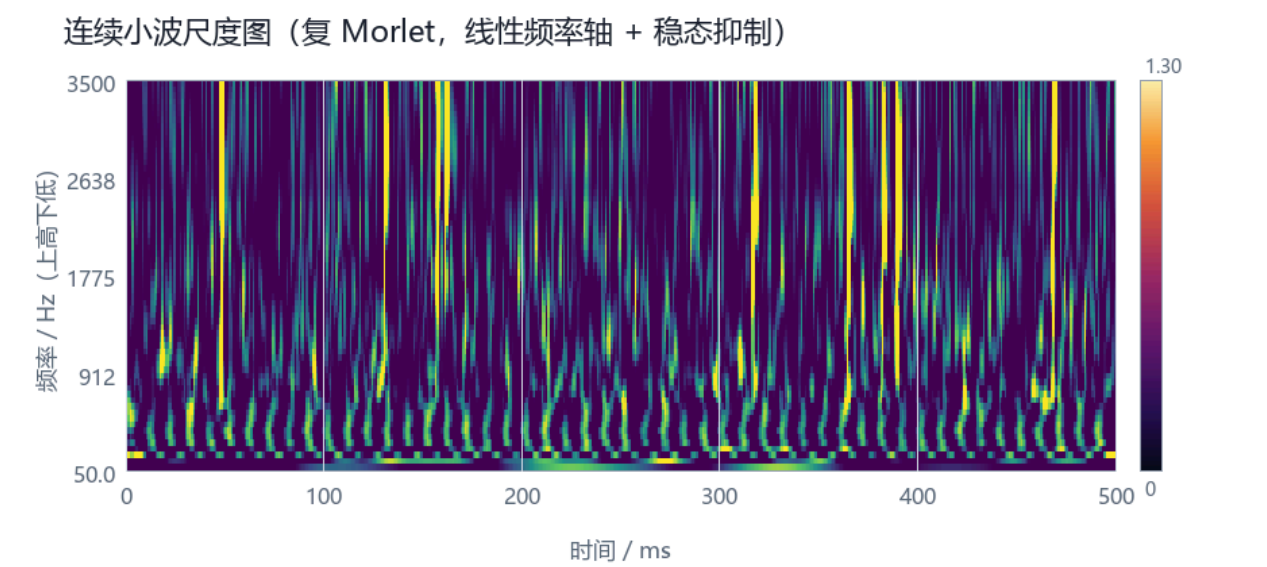


图 7-1　局放样本的 Morlet 尺度图（已换成线性频率轴并做稳态抑制）：竖直亮条是放电脉冲出现的时刻，底部连续亮带是 100 Hz 基频谐波。这张图是全局 **FFT** 给不出的信息

③ 离散小波变换：工程上真正在用的版本

连续小波要在所有 a、b 上算积分，计算量巨大。工程上用"二进离散"：a 取 2 的幂（1, 2, 4, 8…），b 取整数倍，得到 DWT。它可以用一对滤波器（低通 h_0、高通 h_1）反复迭代实现，这就是 Mallat 算法：

$$cA_{j+1}[n] = \sum_k h[k-2n]\, cA_j[k], \qquad cD_{j+1}[n] = \sum_k g[k-2n]\, cA_j[k]$$

$$x[n] = \sum_k \tilde{h}[n-2k]\, cA_J[k] + \sum_{j=1}^{J} \sum_k \tilde{g}[n-2k]\, cD_j[k] \tag{7-3}$$

这是 **Mallat** 塔式算法：h 低通、g 高通，两者后跟 $\downarrow 2$ 降采样。第 1 层 $x \to cA_1$（近似）+ cD_1（细节），第 2 层再分解 cA_1，3 层后得到 $cA_3 + cD_3 + cD_2 + cD_1$，可以无损重构回原信号。正交/双正交小波满足 $A^{\mathsf{T}}A = I$，所以重构就是分析算子的转置 A^{T}。配套项目里 db4 的重构曾因把 A^{T} 误写成另一套卷积相位而产生 1.40 的误差，改成显式转置后降到 10^{-12} 量级——这正是「公式要落到代码」的反面教材。

算一下长度（N = 4000）：

表 7-2　3 层 DWT 的系数长度与对应频带

层	输出	长度	对应频带（8 kHz）
1	cD_1	2000	2000–4000 Hz

层	输出	长度	对应频带（8 kHz）
2	cD_2	1000	1000–2000 Hz
3	cD_3	500	500–1000 Hz
3	cA_3	500	0–500 Hz

这就是"多分辨分析"：细节系数按 **2** 的幂切分频带，高频用短时间窗、低频用长时间窗，自动完成。它常被用来做特征——各层系数的能量、能量熵、方差，几乎就是"各频带有多活跃"的度量。

```
# 3 层 Haar（最简单的正交小波）分解与重构
def dwt_haar(x):
    c = np.asarray(x, float)
    a = (c[0::2] + c[1::2]) / np.sqrt(2)      # 近似（低通）
    d = (c[0::2] - c[1::2]) / np.sqrt(2)      # 细节（高通）
    return a, d
# 逐层分解后把系数反算回去，重构误差应在 1e-16 量级
```

一个实现上的硬要求 正交小波的重构必须用分析算子的转置，不能"另写一套卷积"。项目里第一次写 db4 重构时误差是 1.4（完全错），原因就是把重构写成了另一套滤波器相位；改成显式使用 A^T 之后误差降到 1e−12。判断标准很简单：重构误差不是 **1e−12** 量级，就一定有错。

④ EMD：连基函数都不要了

小波有个前提问题：母小波要人挑（Haar？db4？Morlet？），挑错了效果就不好。EMD（经验模态分解）的思路是让数据自己决定基函数：把信号拆成若干个"本征模态函数"（IMF），每个 IMF 满足两个条件：

本征模态函数（IMF）的两个判定条件

1. 极值点个数与过零点个数相差不超过 1（保证没有叠加的骑行波）；
2. 上包络（局部极大值拟合）与下包络（局部极小值拟合）的均值为 **0**（局部对称）。

满足这两条的分量才有明确的瞬时频率，才能做 Hilbert 谱。EMD 不需要预设基函数，是数据驱动的自适应分解，适合非线性、非平稳信号；代价是没有正交性保证、且对噪声敏感（模态混叠）。

筛分（sifting）的流程：

EMD 筛分（sifting）流程

1. 找出 x 的所有局部极大值、极小值；
2. 用三次样条插值连成上包络 $e_{\max}$ 与下包络 $e_{\min}$；
3. 求均值包络 $m = (e_{\max} + e_{\min})/2$；
4. 令 $h = x - m$，判断 h 是否满足 IMF 两条件；不满足则把 h 当作新的 x 回到 ①；
5. 满足则记为一个 IMF，令残差 $r = x - \mathrm{IMF}$，对 r 继续下一轮；
6. 残差变单调、或极值点少于 2 个时停止，最后得到 $x = \sum_j \mathrm{IMF}_j + r$。

停止准则常用「连续两次筛分的标准差 $\mathrm{SD} = \sum_t |h_{k-1}(t) - h_k(t)|^2 / \sum_t h_{k-1}^2(t) < 0.2 \sim 0.3$」，过筛会抹掉振幅调制信息，欠筛则 IMF 不够对称。端点效应需用镜像延拓抑制。

结果：$x = \sum_i \mathrm{IMF}_i + r$，前面的 IMF 是高频快变，后面的是低频慢变——和傅里叶的"基频+谐波"思路完全不同，它是按时间尺度自适应分层的。

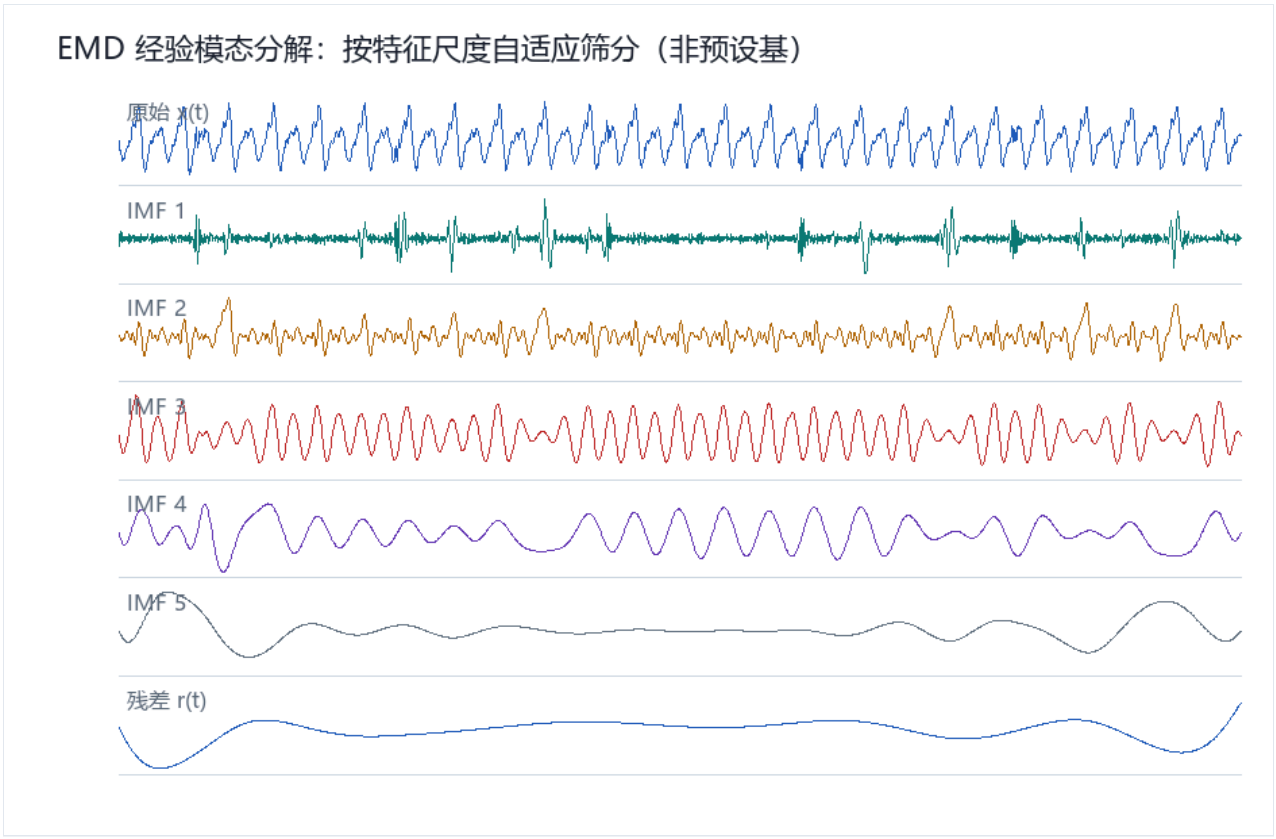


图 7-2　铁芯松动样本的 IMF 分解：从上到下时间尺度由细到粗，最后一行是残差（趋势）。重构所有分量应能还原原信号（误差 1e−17 量级）

EMD 的三个已知问题（必须知道）

表 7-3　EMD 的三个已知问题与缓解办法

问题	表现	缓解办法
端点效应	两端的包络靠外推，误差向内传播，分解越深越严重	端点延拓（镜像、极值延拓）、只取中间段分析
模态混叠	一个 IMF 里混进了差异很大的多个尺度，或同一尺度被拆到两个 IMF	EEMD（加噪声多次平均）、CEEMDAN
停止准则主观	筛分次数没有客观标准，12 次和 20 次结果不同	固定筛分次数或用标准差准则（SD < 0.2~0.3）

另外要清楚：EMD 没有傅里叶那样严格的正交基理论，它的"正交性"只是近似指标（本项目实测正交指数约 0.07），不要拿"正交分解"的结论去套它。

⑤ 三者怎么选

表 7-4　三种时频方法的选择依据

方法	基函数	分辨率分配	计算量	适用
STFT	固定（正弦）	固定	低	谐波结构分析、实时系统
小波	需人工选母小波	高频短窗/低频长窗	中	瞬态检测、突变定位、去噪
EMD	由数据自适应决定	自适应	高（要反复插值）	非平稳、非线性、未知形态的信号

给声纹场景的建议：要定位"脉冲什么时候出现"用短窗 **STFT** 或小波；要分析"谐波比例"用长窗 **STFT** 或直接 **FFT**；要处理形态未知的复杂非平稳信号再考虑 **EMD**。文献里（如李楠 2023 用"小波变换生成声纹特征图谱"再做多传感器融合）走的就是小波路线，因为松动故障的关键是撞击瞬态。

推导详解 • 第 7 讲　小波、Mallat 算法与 EMD 筛分

1. 符号对照表

符号	含义	与 STFT 的对应
a	尺度参数，>0；拉宽小波	相当于「窗长」，但随频率自适应
b	平移参数，时间位置	相当于帧起点 mS
ψ	母小波，零均值、有限能量	相当于窗，但必须振荡且均值为 0
h, g	分解低通 / 高通滤波器	—
$\tilde{h}, \tilde{g}$	重构（综合）滤波器	—
cA_j, cD_j	第 j 层近似 / 细节系数	—

2. 为什么母小波必须零均值：容许条件

由 $\int \psi(t)\,\mathrm{d}t = \hat{\psi}(0)$，若要能从 $W(a,b)$ 反演原信号，需要

$$C_\psi = \int_{-\infty}^{\infty} \frac{|\hat{\psi}(\omega)|^2}{|\omega|}\,\mathrm{d}\omega < \infty \quad\Longrightarrow\quad \hat{\psi}(0) = 0 \;\Leftrightarrow\; \int \psi(t)\,\mathrm{d}t = 0 \tag{7-6}$$

否则 $\omega \to 0$ 时被积函数 $\sim |\hat{\psi}(0)|^2/|\omega|$ 发散。零均值意味着 ψ 必须有正有负、呈振荡状—— 这就是「小波（wavelet）」名字的由来。有了它，连续小波反变换为

$$x(t) = \frac{1}{C_\psi}\int_0^{\infty}\int_{-\infty}^{\infty} W(a,b)\,\frac{1}{\sqrt{a}}\psi\!\left(\frac{t-b}{a}\right)\frac{\mathrm{d}b\,\mathrm{d}a}{a^2} \tag{7-7}$$

3. 尺度 → 频率：把 1/a 关系推清楚

Morlet 母小波 $\psi(t) = \pi^{-1/4} e^{j\omega_0 t} e^{-t^2/2}$（$\omega_0 \approx 6$ 使容许条件近似成立）。 尺度 a 下小波为 $\psi(t/a)$，其傅里叶中心频率由尺度性质得 $\omega = \omega_0/a$（rad/sample），换算成物理频率：

$$f = \frac{\omega_0}{2\pi a} F_s \approx \frac{0.9549}{a} F_s \quad (\omega_0 = 6), \qquad a = \frac{\omega_0 F_s}{2\pi f} \tag{7-8}$$

配套实现用 $f_c \approx 0.8125$（Morlet 的实测中心频率，取决于采样与归一化约定）， 于是 $F_s = 8000$、$a = 8 \Rightarrow f \approx 812\,\mathrm{Hz}$；$a = 80 \Rightarrow f \approx 81\,\mathrm{Hz}$。 关键陷阱：若把尺度按对数取样（常见做法 $a_j = a_0 2^{j\Delta}$），得到的频率轴是指数分布的； 直接拿线性刻度去标，会把 100 Hz 标成 900 Hz。正确做法是先按式 (7-8) 算出每个尺度对应的频率， 再重采样插值到均匀线性频率轴——配套项目 `cwt_morlet()` 的修复正是这一步。

4. 与 STFT 的分辨率对比（定量）

小波在尺度 a 下的等效窗宽 $\Delta t_a = a\,\Delta t_\psi$，等效带宽 $\Delta f_a = \Delta f_\psi / a$，故

$$\Delta t_a \cdot \Delta f_a = \Delta t_\psi\,\Delta f_\psi = \text{常数} \quad \text{但} \quad \frac{\Delta f_a}{f} = \frac{\Delta f_\psi}{\omega_0} = \text{常数} \tag{7-9}$$

即恒 **Q**（恒定相对带宽）分析：高频处时间分辨率好、频率分辨率差；低频处反过来。 STFT 则是恒绝对带宽。对「100 Hz 嗡鸣 + 3 kHz 瞬态放电」这类信号，小波更合适： 低频要分开 100/150 Hz（需好频率分辨），高频要定位放电时刻（需好时间分辨）。

5. DWT：把 Mallat 算法写成矩阵，顺便解释那个 1.40 的 bug

单层分解可以写成矩阵形式 $\mathbf{y} = A\mathbf{x}$，其中 A 的每行是 h 或 g 平移 2 点后的滤波器（$\downarrow 2$）。 对正交小波（Haar、dbN）有 $A^{\mathsf{T}}A = I$，因此

$$\mathbf{x} = A^{\mathsf{T}}\mathbf{y} = A^{\mathsf{T}}\begin{bmatrix} cA_1 \\ cD_1 \end{bmatrix} = \underbrace{A_h^{\mathsf{T}} cA_1}_{\text{低通支路}} + \underbrace{A_g^{\mathsf{T}} cD_1}_{\text{高通支路}} \tag{7-10}$$

这就是式 (7-3) 第二行的矩阵写法。它说明重构就是分析算子的转置，不需要另推一套公式。

配套项目里 db4 最初的重构误差达 **1.40**，原因正是把 A^{T} 误写成「另一套卷积 + 相位偏移」： 分析用的是 $\sum_k h[k-2n]x[k]$，转置后应为 $x[n] = \sum_j h[n-2j]cA[j]$（先上采样再卷积，且索引是 $n-2j$）， 而错误实现写成了普通相关卷积。改成显式构造 A 并取 A^{T} 后，误差降到 10^{-12} 量级。 这个例子值得记住：「看起来对称」不等于「是转置」，用矩阵写一遍最保险。

db4 的 8 个分解低通系数（归一化到 $\sum h_k = \sqrt{2}$）：

$$h = \tfrac{1}{4\sqrt{2}}\left[1+\sqrt{3},\ 3+\sqrt{3},\ 3-\sqrt{3},\ 1-\sqrt{3}\right] \text{ 的 4 抽头推广} \quad \Rightarrow \quad g[k] = (-1)^k h[7-k] \tag{7-11}$$

高通由「低通反转 + 交替变号」得到（正交镜像滤波器 QMF），保证 A 正交。Haar 是最简单的特例： $h = [1/\sqrt{2}, 1/\sqrt{2}]$、$g = [1/\sqrt{2}, -1/\sqrt{2}]$，此时 $cA_1[n] = \frac{x[2n]+x[2n+1]}{\sqrt{2}}$、$cD_1[n] = \frac{x[2n]-x[2n+1]}{\sqrt{2}}$，手工就能验证 $x[2n] = (cA_1 + cD_1)/\sqrt{2}$ √。

6. EMD：筛分停止准则与端点效应

第 k 次筛分的收敛判据用标准差准则：

$$\mathrm{SD}_k = \frac{\sum_t \left|h_{k-1}(t) - h_k(t)\right|^2}{\sum_t h_{k-1}^2(t)} < 0.2 \sim 0.3 \tag{7-12}$$

太严（SD 要求极小）会过度筛分，把振幅调制也抹平，IMF 变成等幅的纯调频波；太松则 IMF 上下包络不对称，瞬时频率失去意义。分解终止条件：残差 r 的极值点数 ≤ 2，或 $\max|r|$ 与 $\sum|\mathrm{IMF}|$ 相比可忽略。

端点效应：三次样条在序列两端没有约束，包络会「飞出去」，且误差随筛分逐层向内传播。 标准补救是镜像延拓：在左右各加一段关于端点对称翻转的极值点，筛完只取中间原长部分。

得到 IMF 后，对每个分量做 Hilbert 变换 $\tilde{c}_j(t) = \frac{1}{\pi}\,\mathrm{p.v.}\!\int \frac{c_j(\tau)}{t-\tau}\mathrm{d}\tau$， 构造解析信号 $z_j(t) = c_j + j\tilde{c}_j = a_j(t)e^{j\phi_j(t)}$，瞬时频率 $f_j(t) = \frac{1}{2\pi}\frac{\mathrm{d}\phi_j}{\mathrm{d}t}$， 于是得到时间–频率–能量三维的 **Hilbert** 谱 $H(f,t) = \sum_j a_j^2(t)\delta(f - f_j(t))$。 与语谱图不同，它不受窗长约束，能同时给出高频瞬态的精确定位与低频的精细频率。

7. 公式 ↔ 代码

```
# 式(7-1) CWT：逐尺度与信号做卷积
for a in scales:
    psi = morlet(np.arange(-4*a, 4*a) / a) / np.sqrt(a)
    W[i] = np.convolve(x, psi, 'same')

# 式(7-3) DWT 单层（分析）
cA = conv_down(x, h, 2); cD = conv_down(x, g, 2)

# 式(7-10) 重构：显式用分析算子的转置（这是修 bug 后的写法）
A = build_analysis_matrix(len(x), h, g)     # 每行是平移 2 点的 h / g
y = np.concatenate([cA, cD])
x_hat = A.T @ y                              # 误差 ~1e-12

# 式(7-12) EMD 筛分
while True:
    env_hi = spline(maxima); env_lo = spline(minima)
    m = (env_hi + env_lo) / 2
    h_new = h - m
    if sd(h, h_new) < 0.25: break
    h = h_new
```

8. 边界与失效条件

- 模态混叠：一个 IMF 里混入尺度差异极大的成分，或同一尺度被拆到多个 IMF。噪声最容易诱发；EEMD/CEEMDAN 通过加噪集合平均缓解。
- 信号长度必须远大于最大小波尺度，否则 a 大的尺度卷积边界占满整段，系数全是端点伪影（画 CWT 图时应标出「影响锥」cone of influence 并裁掉）。
- DWT 每层降采样使长度减半，长度非 2 的幂时需做对称延拓（`mode='symmetric'`），否则重构长度对不上。
- EMD 没有正交性保证，各 IMF 能量之和不必等于原信号能量，做能量特征时要先验证。

误区与注意事项

误区 ① 以为小波能突破不确定原理。它只是"按频率分配分辨率"，乘积下界不变。② 把 **CWT** 的横轴当线性频率。尺度轴是对数的，直接标线性频率会把 100 Hz 标成 900 Hz（本项目真的踩过这个坑）。③ **EMD** 分解越深越好。越深端点效应越重，IMF 越多不等于信息越多。④ 拿 **EMD** 的正交性当定论。它只是经验算法。

自检

- [ ] 我能说出 STFT 的固定窗在什么场景下会失效。
- [ ] 我能用 $f \approx f_c F_s / a$ 把小波尺度换算成频率。
- [ ] 我知道 3 层 DWT 的系数长度与对应频带。
- [ ] 我能说出 EMD 的 IMF 两个条件与三个已知问题。

第 8 讲

神经网络基础：BP 神经网络

目标

- 能写出一个神经元的计算，并说清激活函数为什么必须是非线性的。
- 能自己推出 $\partial L/\partial W = \mathbf{a}^{\mathsf{T}}\boldsymbol{\delta}$ 这类反向传播公式，而不是背下来。
- 会做数值梯度检查，能看懂"误差 1e−11"意味着什么。

产出

- 一个纯 numpy 的两层 BPNN，前向 + 反向都能跑通。
- 梯度检查的最大绝对误差小于 1e−8。

配套可拖演示 打开同目录下的 `labs.html`（第二个标签页）：9 个权重都能拖，右侧实时给出这一串链式相乘的每一项数值，并和"左右各挪 1e-4 算出的数值梯度"对照——两者对不上，就说明链式某一步漏了项。

先修知识与准备

需要：矩阵乘法与维度的推理（`(m,n)@(n,p)=(m,p)`）、链式法则、`exp` 与 `log`。若矩阵维度推不清，反向传播一定写不对——这是最常见的能力缺口，建议先做本讲最后的维度练习。

① 从一个神经元说起

$$z = \sum_{i=1}^{d} w_i x_i + b = \mathbf{w}^{\mathsf{T}}\mathbf{x} + b, \qquad a = \sigma(z) = \frac{1}{1+e^{-z}}, \qquad \sigma'(z) = a(1-a) \tag{8-1}$$

sigmoid 输出 $(0,1)$，可解释为概率；其导数能直接用输出值算，这是它早年流行的原因。但 $|z|$ 大时 $\sigma' \to 0$，多层连乘会造成梯度消失，所以现代隐含层多用 ReLU $\sigma_{\text{ReLU}}(z) = \max(0, z)$。

为什么要有 σ？因为如果只有加权和，多层网络叠加起来仍然是线性的：$W_2(W_1\mathbf{x}) = (W_2W_1)\mathbf{x}$，两层等于一层，学了也没用。非线性激活是"深度"有意义的前提。这也是为什么 XOR 这种线性不可分问题，单层感知机永远做不对，加一个隐层就能做对。

常用激活函数

表 8-1　常用激活函数及其导数

名称	公式	导数	特点
sigmoid	1/(1+e^−z)	σ(1−σ)	输出概率，两端梯度消失（饱和）
tanh	(e^z−e^−z)/(e^z+e^−z)	1−tanh²	零均值，收敛比 sigmoid 快
ReLU	max(0, z)	z>0 为 1，否则 0	不饱和、计算便宜，深层网络首选

② 前向传播：把一帧特征变成概率

$$\begin{aligned} \mathbf{z}_1 &= W_1\mathbf{x} + \mathbf{b}_1, \quad \mathbf{h} = \sigma(\mathbf{z}_1) \\ \mathbf{z}_2 &= W_2\mathbf{h} + \mathbf{b}_2, \quad p_c = \frac{e^{z_{2,c}}}{\sum_j e^{z_{2,j}}} \quad (\text{softmax}) \end{aligned} \tag{8-2}$$

输入 $\mathbf{x}$ 是 39 维 MFCC 统计量（对整段语音各维取均值/标准差），$W_1 \in \mathbb{R}^{H\times 39}$、$W_2 \in \mathbb{R}^{C\times H}$。softmax 把任意实数得分压成和为 1 的概率分布；实现时要减去 $\max_j z_{2,j}$ 防溢出，因为 $e^{z-\max}$ 不会超过 1（平移不改变 softmax 结果）。

softmax 的作用是把任意实数变成"和为 1 的概率"。注意它对所有 z 加同一个常数不变（分子分母同乘），所以实现时要先减最大值防止 `exp` 溢出：`z - z.max()`。

③ 损失函数与那个"漂亮"的梯度

$$L(\mathbf{p}, \mathbf{y}) = -\sum_{c=1}^{C} y_c \ln p_c = -\ln p_{c^*} \quad (\mathbf{y} \text{ 为 one-hot}) \tag{8-3}$$

交叉熵来自极大似然：把标签看成真实分布，最小化 $-\ln p_{c^*}$ 等价于最大化正确类的似然。用交叉熵配 softmax 的关键好处是梯度里不含 σ'（见下式），不会像「均方误差 + sigmoid」那样在错得很离谱时反而梯度趋零、学不动。

对 softmax + 交叉熵求导，会得到一个极其简洁的结果：

$$\boldsymbol{\delta}_2 \equiv \frac{\partial L}{\partial \mathbf{z}_2} = \mathbf{p} - \mathbf{y}, \qquad \frac{\partial L}{\partial z_{2,c}} = p_c - y_c \tag{8-4}$$

推导：$\frac{\partial L}{\partial z_{2,i}} = \sum_c \frac{\partial L}{\partial p_c}\frac{\partial p_c}{\partial z_{2,i}}$，其中 $\frac{\partial p_c}{\partial z_{2,i}} = p_c(\delta_{ci} - p_i)$，代入 $L = -\sum_c y_c \ln p_c$ 并用 $\sum_c y_c = 1$ 即得 $p_i - y_i$。例：三类 $p = [0.7, 0.2, 0.1]$、$y = [0, 1, 0] \to \delta_2 = [0.7, -0.8, 0.1]$：预测比标签大的往下压（正梯度），比标签小的往上抬（负梯度）。

这个结果不是巧合，而是"指数族 + 对数损失"的共轭性质。知道它，反向传播的第一层就不用推了。

④ 反向传播：逐层往回传

记 $\boldsymbol{\delta}_2 = \partial L/\partial \mathbf{z}_2 = \mathbf{p} - \mathbf{y}$，则：

$$\begin{aligned} \frac{\partial L}{\partial W_2} &= \boldsymbol{\delta}_2\,\mathbf{h}^{\mathsf{T}}, & \frac{\partial L}{\partial \mathbf{b}_2} &= \boldsymbol{\delta}_2 \\ \boldsymbol{\delta}_1 &= \left(W_2^{\mathsf{T}}\boldsymbol{\delta}_2\right) \odot \sigma'(\mathbf{z}_1), & \frac{\partial L}{\partial W_1} &= \boldsymbol{\delta}_1\,\mathbf{x}^{\mathsf{T}}, \quad \frac{\partial L}{\partial \mathbf{b}_1} = \boldsymbol{\delta}_1 \end{aligned} \tag{8-5}$$

$\odot$ 是逐元素乘（Hadamard 积）。每个梯度都是「上游误差 × 本层输入」的外积，形状自动与权重矩阵一致——这是检查反向传播写对没有的第一道关。$\sigma'(\mathbf{z}_1) = \mathbf{h} \odot (1 - \mathbf{h})$ 可复用前向缓存，不必重算指数。参数更新：$W \leftarrow W - \eta\,\partial L/\partial W$，$\eta$ 为学习率。

三句话记住结构：对权重求导 = 该层的 **δ** 乘上一层的输入（外积）；把 **δ** 往回传 = 用 **W** 的转置乘 **δ**，再乘本层激活的导数。

维度是唯一的检查手段 如果 $\partial L/\partial W_1$ 的形状和 `W₁` 不一样，一定是转置放错了。`W₁` 是 `(h, d)`，`x` 是 `(d,)`，`δ₁` 是 `(h,)`，所以必须写 `δ₁[:,None] @ x[None,:]` 得到 `(h,d)`。批量时 `X` 是 `(B,d)`，则是 `δ₁.T @ X`。

⑤ 手算一次参数更新

用最简单的单神经元（sigmoid 输出、二分类、交叉熵）走一遍，数字都能验算：

$$\begin{aligned} z &= 0.5(1) - 0.5(2) + 0 = -0.5, & p &= \sigma(-0.5) = 0.3775 \\ L &= -\ln 0.3775 = 0.9741, & \delta &= p - y = -0.6225 \\ \partial L/\partial \mathbf{w} &= \delta \mathbf{x} = [-0.6225,\ -1.2450], & \partial L/\partial b &= -0.6225 \\ \mathbf{w}_{\text{new}} &= \mathbf{w} - \eta\, \partial L/\partial \mathbf{w} = [0.5623,\ -0.3755] \end{aligned} \tag{8-6}$$

输入 $\mathbf{x} = [1, 2]$、$\mathbf{w} = [0.5, -0.5]$、$b = 0$、$y = 1$、$\eta = 0.1$。 再前向一次：$z' = 0.5623 \times 1 - 0.3755 \times 2 = -0.1887$，$p' = \sigma(-0.1887) = 0.4530$，$L' = 0.7919 < 0.9741$ √ 损失确实下降了。 这个「手算一轮、确认损失变小」的习惯，比跑通十次训练更能建立对反向传播的信任。

这一步算完，你就掌握了训练的全部本质：预测 → 算损失 → 求梯度 → 沿负梯度方向挪一小步。后面所有网络，无非是把这个过程重复几百万次、并且梯度算得更聪明。

⑥ 梯度检查：怎么确认反向传播没写错

解析梯度可能推错，但数值梯度一定对（它就是导数的定义）：

$$\frac{\partial L}{\partial w_i} \approx \frac{L(\mathbf{w} + \varepsilon \mathbf{e}_i) - L(\mathbf{w} - \varepsilon \mathbf{e}_i)}{2\varepsilon}, \qquad \varepsilon \sim 10^{-5},\ \text{截断误差}\ O(\varepsilon^2) \tag{8-7}$$

中心差分由泰勒展开 $L(w \pm \varepsilon) = L(w) \pm \varepsilon L'(w) + \frac{\varepsilon^2}{2} L''(w) \pm \frac{\varepsilon^3}{6} L'''(w) + \cdots$ 相减得到，偶次项自动抵消，所以误差是 $O(\varepsilon^2)$， 而前向差分只有 $O(\varepsilon)$。梯度检查：把解析梯度与上式逐元素比较。 配套项目实测绝对误差 $< 10^{-10}$；若某元素相对误差看着大，先检查它是不是接近 0 的极小量 （例如 -2.03×10^{-6} 会把相对误差放大到 5×10^{-6}，但绝对误差只有 10^{-11}，不是 bug）。

对每个参数抽几个探针，比较解析梯度与数值梯度。判据要同时看两个数：

表 8-2　梯度检查的两个判据

指标	含义	合格线
绝对误差 |g_num − g_ana|	梯度值本身差多少（硬判据）	< 1e−8
相对误差 |差|/(|g_num|+|g_ana|)	近零梯度处会被放大，仅供参考	通常 < 1e−4

本项目真实踩过的坑 BPNN 的梯度检查一开始报相对误差 **5.3e−6**，看起来比 CNN 的 4e−11 差五个数量级，怀疑反向传播写错。逐参数排查后发现：误差最大的那个探针，解析梯度只有 −2.03e−6（几乎是 0），绝对误差只有 1.03e−11——是"除以接近 **0** 的数"把相对误差放大了，不是算错。所以别只看相对误差，一定要把绝对误差一起报出来。

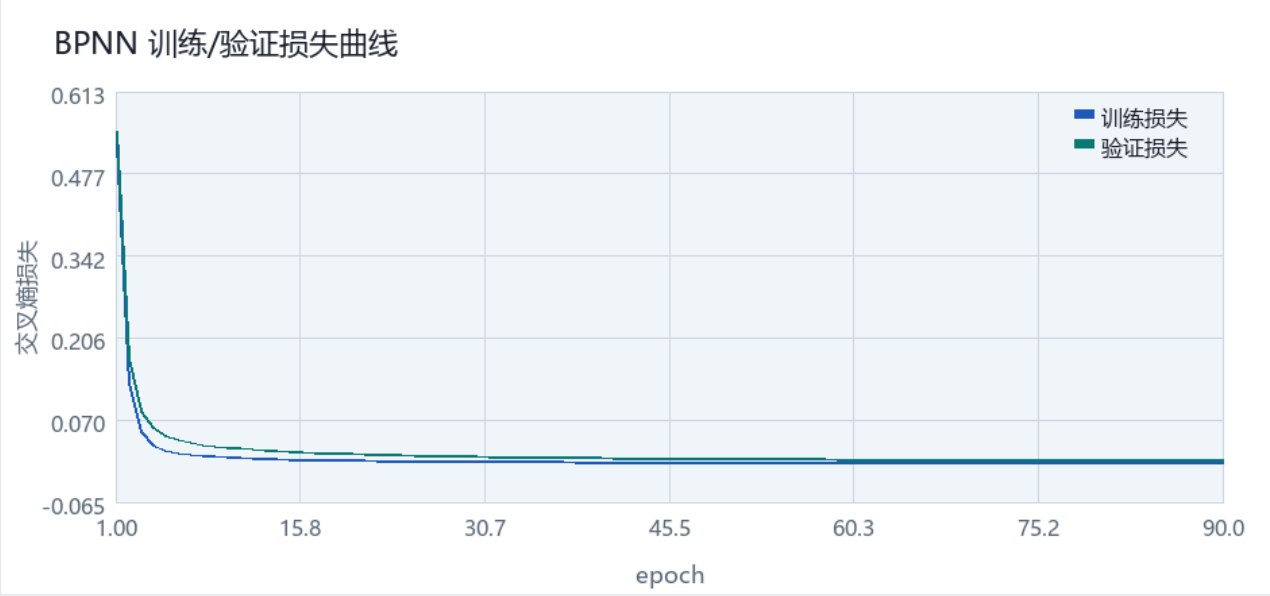


图 8-1　BPNN 的训练/验证损失曲线：前 20 个 epoch 快速下降，之后趋缓。若验证损失开始上升而训练损失继续下降，就是过拟合的信号（第 10 讲）

⑦ 实现要点（纯 numpy）

```
class BPNN:
    def __init__(self, n_in, n_hid, n_out, seed=0):
        r = np.random.default_rng(seed)
        # 初始化不能全零：否则同层所有神经元梯度相同，永远学不出差异
        self.W1 = r.normal(0, np.sqrt(2/n_in),  (n_hid, n_in))
        self.b1 = np.zeros(n_hid)
        self.W2 = r.normal(0, np.sqrt(2/n_hid), (n_out, n_hid))
        self.b2 = np.zeros(n_out)

    def forward(self, X):
        self.z1 = X @ self.W1.T + self.b1
        self.h  = 1/(1+np.exp(-self.z1))
        z2 = self.h @ self.W2.T + self.b2
        z2 -= z2.max(1, keepdims=True)          # 防 exp 溢出
        e = np.exp(z2); self.p = e / e.sum(1, keepdims=True)
        return self.p

    def backward(self, X, Y):
        d2 = (self.p - Y) / len(X)              # δ₂（已含 batch 平均）
        gW2 = d2.T @ self.h
        gb2 = d2.sum(0)
        d1 = (d2 @ self.W2) * self.h * (1 - self.h)   # δ₁
        gW1 = d1.T @ X
        gb1 = d1.sum(0)
        return [gW1, gb1, gW2, gb2]
```

推导详解 · 第 8 讲　反向传播的每一项都算出来

1. 网络结构与维度表

量	形状	本讲义取值	说明
$\mathbf{x}$	$(d,1)$	$d=39$	MFCC 统计特征
$W_1,\mathbf{b}_1$	$(H,d),(H,1)$	$H=32$	隐层
$\mathbf{h}$	$(H,1)$	32	隐层激活
$W_2,\mathbf{b}_2$	$(C,H),(C,1)$	$C=6$	六类工况
$\mathbf{p}$	$(C,1)$	6	softmax 概率

2. softmax 的导数：δ₂ = p − y 的完整推导

记 $p_c=e^{z_c}/\sum_j e^{z_j}=e^{z_c}/Z$。先求雅可比，对 $i\neq c$ 与 $i=c$ 分别用商法则：

$$\frac{\partial p_c}{\partial z_i}=\begin{cases}\dfrac{e^{z_i}Z-e^{z_c}e^{z_i}}{Z^2}=p_i(1-p_c)=p_c(\delta_{ci}-p_i), & i=c\\[2ex] \dfrac{-e^{z_c}e^{z_i}}{Z^2}=-p_cp_i=p_c(\delta_{ci}-p_i), & i\neq c\end{cases}\tag{8-8}$$

两种情况可统一写成 $\partial p_c/\partial z_i=p_c(\delta_{ci}-p_i)$。代入 $L=-\sum_c y_c\ln p_c$：

$$\begin{aligned}\frac{\partial L}{\partial z_i}&=-\sum_c\frac{y_c}{p_c}\frac{\partial p_c}{\partial z_i}=-\sum_c\frac{y_c}{p_c}p_c(\delta_{ci}-p_i)\\&=-\sum_c y_c\delta_{ci}+p_i\sum_c y_c=-y_i+p_i\end{aligned}\tag{8-9}$$

最后一步用了 one-hot 标签 $\sum_c y_c=1$。结论：**softmax 的雅可比与交叉熵的导数恰好抵消，梯度退化成极简的 $p-y$**。这就是「分类任务用交叉熵而不用 MSE」的数学理由：MSE 的梯度里会多出 $p_c(1-p_c)$ 因子，在预测错得离谱（$p\approx 0$ 或 1）时梯度趋零，训练直接卡死。

3. 逐层回传：链式法则的每一步

输出层权重：由 $z_{2,c}=\sum_j W_{2,cj}h_j+b_{2,c}$ 得 $\partial z_{2,c}/\partial W_{2,ij}=\delta_{ci}h_j$，于是

$$\frac{\partial L}{\partial W_{2,ij}}=\frac{\partial L}{\partial z_{2,i}}h_j=\delta_{2,i}h_j\quad\Longrightarrow\quad\frac{\partial L}{\partial W_2}=\boldsymbol{\delta}_2\mathbf{h}^{\mathsf T}\tag{8-10}$$

传到隐层：$\mathbf{z}_2=W_2\mathbf{h}+\mathbf{b}_2$，故 $\partial L/\partial\mathbf{h}=W_2^{\mathsf T}\boldsymbol{\delta}_2$；再由 $\mathbf{h}=\sigma(\mathbf{z}_1)$ 逐元素求导 $\partial h_j/\partial z_{1,j}=\sigma'(z_{1,j})=h_j(1-h_j)$：

$$\boldsymbol{\delta}_1=\frac{\partial L}{\partial\mathbf{z}_1}=\left(W_2^{\mathsf T}\boldsymbol{\delta}_2\right)\odot\sigma'(\mathbf{z}_1),\qquad\frac{\partial L}{\partial W_1}=\boldsymbol{\delta}_1\mathbf{x}^{\mathsf T}\tag{8-11}$$

偏置：$\partial z/\partial b=1$，故 $\partial L/\partial\mathbf{b}_2=\boldsymbol{\delta}_2$、$\partial L/\partial\mathbf{b}_1=\boldsymbol{\delta}_1$。

统一规律：每层的权重梯度 = 该层的误差向量 ⊗ 该层的输入向量。检查形状是最快的自检：$\boldsymbol{\delta}_2$ 是 $(C,1)$、$\mathbf{h}^{\mathsf T}$ 是 $(1,H)$ → 外积 (C,H)，与 W_2 一致 √。

4. 数值梯度：为什么中心差分是 O(ε²)

对 $L(w)$ 在 w 处做泰勒展开：

$$\begin{aligned} L(w+\varepsilon) &= L(w) + \varepsilon L'(w) + \tfrac{\varepsilon^2}{2}L''(w) + \tfrac{\varepsilon^3}{6}L'''(w) + O(\varepsilon^4) \\ L(w-\varepsilon) &= L(w) - \varepsilon L'(w) + \tfrac{\varepsilon^2}{2}L''(w) - \tfrac{\varepsilon^3}{6}L'''(w) + O(\varepsilon^4) \end{aligned} \tag{8-12}$$

两式相减，偶次项全消：$\dfrac{L(w+\varepsilon)-L(w-\varepsilon)}{2\varepsilon} = L'(w) + \dfrac{\varepsilon^2}{6}L'''(w) + O(\varepsilon^4)$，误差 $O(\varepsilon^2)$。而前向差分 $\frac{L(w+\varepsilon)-L(w)}{\varepsilon} = L'(w) + \frac{\varepsilon}{2}L''(w) + \cdots$ 只有 $O(\varepsilon)$。

$\boldsymbol{\varepsilon}$ 不能无限小：$\varepsilon < 10^{-8}$ 时两个相近的 L 值相减会发生灾难性抵消（双精度约 16 位有效数字），舍入误差反超截断误差。经验值 $\varepsilon = 10^{-5} \sim 10^{-4}$（$\sqrt[3]{\epsilon_{\text{mach}}}$ 量级）。判据建议用相对误差 $\dfrac{\|g_{\text{analytic}} - g_{\text{numeric}}\|}{\|g_{\text{analytic}}\| + \|g_{\text{numeric}}\|} < 10^{-7}$，避免逐元素比较时被近零元素放大。

5. 完整手算一轮（带所有中间数）

$$\begin{aligned} &x = [1, 2],\ w = [0.5, -0.5],\ b = 0,\ y = 1,\ \eta = 0.1 \\ &z = 0.5(1) - 0.5(2) = -0.5, \quad p = \frac{1}{1+e^{0.5}} = 0.3775407 \\ &L = -\ln p = 0.9740770, \quad \delta = p - y = -0.6224593 \\ &\nabla_w = \delta x = [-0.6224593,\ -1.2449187], \quad \nabla_b = -0.6224593 \\ &w' = [0.5 + 0.0622459,\ -0.5 + 0.1244919] = [0.5622459,\ -0.3755081] \end{aligned} \tag{8-13}$$

验证：$z' = 0.5622459(1) - 0.3755081(2) = -0.1887703$，$p' = \sigma(-0.1887703) = 0.4529549$，$L' = -\ln 0.4529549 = 0.7920007$。损失从 0.9741 降到 0.7920 √。一阶近似预测的下降量是 $\eta\|\nabla\|^2 = 0.1(0.6225^2 + 1.2449^2 + 0.6225^2) = 0.2326$，实际下降 0.1821，小于预测——因为步长偏大、二阶项把它拉回来了，这正是学习率不能太大的定量体现。

6. 梯度消失的定量说明

若把 sigmoid 换成 L 层全 sigmoid 网络，$\boldsymbol{\delta}_1$ 中含 $\prod_l \sigma'(z_l)$，而 $\sigma'(z) \le 0.25$，于是 5 层之后梯度上界为 $0.25^5 \approx 10^{-3}$，10 层后 10^{-6}。ReLU 在正区导数恒为 1，连乘不衰减，这是它能训深网络的原因。代价是「死 ReLU」：$z < 0$ 时导数恒 0，该神经元永久不再更新，需靠 Leaky ReLU 或小学习率缓解。

7. 公式 ↔ 代码

```
# 式(8-2) 前向（softmax 减 max 防溢出）
z1 = W1 @ x + b1; h = sigmoid(z1)
z2 = W2 @ h + b2
e = np.exp(z2 - z2.max()); p = e / e.sum()

# 式(8-9) 反向：四行全部与公式一一对应
d2 = p - onehot(y)                      # delta_2
gW2 = d2 @ h.T; gb2 = d2                # 式(8-10)
d1 = (W2.T @ d2) * (h * (1 - h))        # 式(8-11) sigma'=h(1-h)
gW1 = d1 @ x.T;  gb1 = d1

# 式(8-12) 梯度检查（中心差分）
for i in range(W.size):
    Wp = W.copy(); Wp.flat[i] += eps
    Wm = W.copy(); Wm.flat[i] -= eps
    gn = (loss(Wp) - loss(Wm)) / (2*eps)
    assert abs(gn - g.flat[i]) < 1e-8
```

配套 `acoustic-lab/src/nn.py` 的 `grad_check()` 实测绝对误差 $< 10^{-10}$。若某元素相对误差显示为 5×10^{-6}，先查它是不是量级 10^{-6} 的近零梯度——那个例子里绝对误差只有 10^{-11}，属正常浮点噪声。

8. 边界与失效条件

- 权重初始化不能全为 0（对称破缺失败，所有隐单元学到同一东西）；用 He/Xavier：$\mathrm{Var}(w) = 2/d_{\text{in}}$。
- 特征未标准化时，量级大的维度主导梯度，损失曲面狭长，SGD 会来回震荡——MFCC 各维量纲差异大，务必先标准化。
- 交叉熵里 $\ln p_c$ 在 $p_c \to 0$ 时爆炸，实现要加 ε 或直接用 log-sum-exp 形式 $L = -z_{c^*} + \ln \sum_j e^{z_j}$。
- 数值梯度检查要关掉 dropout、固定 batch，否则两次前向的随机性会污染差分。

误区与注意事项

误区 ① 权重全零初始化。对称性不破，隐层神经元永远学成一样。② 忘记除 **batch** 大小。梯度随 batch 线性放大，学习率等于白设。③ **softmax** 不减最大值。数值溢出变成 nan。④ 只用相对误差判断梯度。近零梯度会误报（见上文）。⑤ 把 **sigmoid** 用于深层网络。梯度消失，改用 ReLU。

自检

- [ ] 我能写出单个神经元的计算，并解释为什么必须非线性。
- [ ] 我能推出 $\partial L/\partial W_2 = \boldsymbol{\delta}_2 \mathbf{h}^{\mathsf{T}}$ 和 $\boldsymbol{\delta}_1 = (W_2^{\mathsf{T}} \boldsymbol{\delta}_2) \odot \sigma'(\mathbf{z}_1)$。
- [ ] 我能跟着手算完成那次参数更新（w 从 [0.5,−0.5] 变成 [0.5623,−0.3755]）。
- [ ] 我知道梯度检查要看绝对误差，并能解释相对误差为什么会误报。

第 9 讲

卷积神经网络 CNN

目标

- 理解卷积为什么比全连接更适合图像/谱图（三件事：局部、共享、平移）。
- 能算卷积层的输出尺寸和参数量。
- 知道 im2col 是怎么把卷积变成矩阵乘法的。

产出

- 手写一维/二维卷积前向，输出尺寸与手算一致。
- CNN 的数值梯度检查通过（绝对误差 < 1e−8）。

先修知识与准备

需要第 8 讲的反向传播。卷积本身只是"加权求和"，不需要提前学信号处理里的卷积定理。

① 为什么不能直接把谱图拉平喂给全连接

一张 32×32 的 log-Mel 图拉平是 1024 维，接一个 1000 维隐层需要 `1024×1000 ≈ 100 万`个参数。两个问题：参数太多容易过拟合（尤其声纹样本常常只有几百条）；更重要的是，拉平破坏了空间结构——第 3 行第 5 列与第 4 行第 5 列本来是相邻的时频点，拉平后这个"相邻"关系就丢了。

卷积用三个假设换来了极高的参数效率：

表 9-1　卷积的三个假设与收益

假设	含义	带来什么
局部性	相邻的时频点才相关，远处的先不直接相连	每层只看 3×3 这样的小块
平移不变	同一个模式出现在图的左边或右边，都该被同一种方式识别	同一个卷积核滑过整张图（权重共享）
层次性	简单的边/纹理组合成复杂的结构	堆叠多层，感受野逐层扩大

② 卷积的运算与尺寸

$$y[i,j] = \sum_{p=0}^{F-1}\sum_{q=0}^{F-1} x[i+p,\, j+q]\, K[p,q] + b \tag{9-1}$$

K 是 $F \times F$ 卷积核，b 是偏置。严格说深度学习里做的是互相关而非数学卷积（少了核翻转），但因为 K 是学出来的，翻转与否不影响表达能力。 两个归纳偏置：局部连接（只看邻域）与权值共享（同一核扫全图）。

输出尺寸（必须背下来）：

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} - F + 2P}{S} \right\rfloor + 1, \qquad W_{\text{out}} = \left\lfloor \frac{W_{\text{in}} - F + 2P}{S} \right\rfloor + 1 \tag{9-2}$$

核最后一个位置是 $H_{\text{in}} - F + 2P$，从 0 出发每次走 S，故位置数为 $\lfloor (H_{\text{in}} - F + 2P)/S \rfloor + 1$。 例：$32 \times 32$、$F = 3$、$P = 1$、$S = 1 \to 32$（尺寸不变，称 `same` padding）； $P = 0, S = 2 \to \lfloor 29/2 \rfloor + 1 = 15$（下采样）。

参数量（也是必考）：

$$N_{\text{param}} = \left(F \times F \times C_{\text{in}} + 1\right) \times C_{\text{out}} \tag{9-3}$$

每个核有 $F^2 C_{\text{in}}$ 个权重 + 1 个偏置，共 C_{out} 个核。 例：1 通道、4 个 3×3 核 $\to (9+1) \times 4 = 40$ 个参数。 对比全连接 $1024 \to 1000$ 需 $1\,025\,000$ 个参数，相差约 25000 倍—— 这就是 CNN 在小样本上不容易过拟合的根本原因。

40 个参数就能提取 4 种局部模式——这就是卷积"参数效率"的直观含义。当然 40 个参数能表达的东西有限，所以实际网络会堆很多层、很多通道（ResNet 有上千万参数），但相对全连接仍然是数量级的节省。

③ 池化与感受野

$$y_{i,j}^{\max} = \max_{0 \le p,q < 2} x[2i + p,\, 2j + q], \qquad y_{i,j}^{\text{avg}} = \frac{1}{4} \sum_{p,q} x[2i + p,\, 2j + q] \tag{9-4}$$

2×2、步长 2 → 空间尺寸减半。池化没有可学参数，作用是降维并获得一定的平移不变性。 反向传播时最大池化要把梯度只回传给前向取到最大值的那个位置（需保存 argmax 掩码）， 平均池化则把梯度均分给 4 个位置。

池化的作用是降维 + 提供一定的小范围平移鲁棒性（模式挪动一两个像素，最大值还在窗内）。代价是丢失精确定位信息——所以检测任务里要慎用大池化。

感受野指"输出上的一个点，能看到输入的多大范围"。3 层 3×3 卷积（步长 1）的感受野是：

$$\text{RF}_k = \text{RF}_{k-1} + (F_k - 1) \prod_{j=1}^{k-1} S_j, \qquad \text{RF}_1 = F_1 \tag{9-5}$$

逐层：1 层 $3 \times 3 \to 3$；2 层 $\to 3 + (3-1) = 5$；3 层 $\to 5 + (3-1) = 7$。 若中间有步长 2，前面各层的步长要乘进增量。感受野决定「一个输出神经元能看到多长的时间/多大的图」， 必须覆盖目标模式的尺度：想让网络看见 100 Hz 基频的一个完整周期（10 ms）， 在 8 kHz 下至少要覆盖 80 个采样点。

④ im2col：把卷积写成一次矩阵乘法

直接用四重循环算卷积在 numpy 里极慢。工业界的做法是把每个"待卷积的小块"拉成一列，拼成矩阵，然后一次 `@` 算完：

$$X_{\text{col}} \in \mathbb{R}^{(CF^2) \times (H_{\text{out}} W_{\text{out}})}, \qquad W_{\text{col}} \in \mathbb{R}^{C_{\text{out}} \times (CF^2)}, \qquad Y = W_{\text{col}} X_{\text{col}} \tag{9-6}$$

im2col：把输入 (C, H, W) 中所有 $F \times F$ 小块拉成列，拼成大矩阵； 卷积核展开成行。于是「滑动卷积」变成一次 **GEMM** 矩阵乘法，可以直接吃 BLAS 优化。 输出 reshape 回 $(C_{\text{out}}, H_{\text{out}}, W_{\text{out}})$。 代价是内存放大约 F^2 倍（重叠块被复制），这是典型的「以空间换时间」。

这样就把卷积变成了 GEMM（通用矩阵乘法），可以吃满 BLAS 的性能。反向传播也随之变得简单：

$$\frac{\partial L}{\partial W_{\text{col}}} = \frac{\partial L}{\partial Y} X_{\text{col}}^{\mathsf{T}}, \qquad \frac{\partial L}{\partial X_{\text{col}}} = W_{\text{col}}^{\mathsf{T}} \frac{\partial L}{\partial Y} \xrightarrow{\text{col2im}} \frac{\partial L}{\partial X} \tag{9-7}$$

既然前向是一次矩阵乘，反向就是第 8 讲那套「上游误差 × 本层输入」的外积公式。 唯一额外工作是 `col2im`：把列的梯度累加回原位置（重叠处要相加，不能覆盖）。 配套项目的 `col2im` 若忘记累加，梯度检查会在重叠区域先出错——这类 bug 用数值梯度一测就现形。

注意 `col2im` 不能简单 reshape，因为相邻的小块是重叠的，重叠位置的梯度要累加而不是覆盖。这是手写 CNN 时第二个常见错误（第一个是池化的梯度分配）。

⑤ 为什么 CNN 特别适合谱图

一张 log-Mel 谱图上，"局部模式"恰好对应真实的物理结构：

表 9-2　谱图局部模式与物理含义的对应

图上看到的局部模式	物理含义	CNN 学到的东西
一小段竖直亮条	瞬态脉冲（局放、撞击）	第 1–2 层的边缘检测器
几条平行的水平线	谐波族	第 2–3 层的"条纹组合"检测器
低频段的一小片结构	50 Hz 倍频族（偏磁）	深层的高层语义组合

这也是文献里最常见的做法：张重远 2020 把 Mel 时频谱直接送进 CNN，铁芯三种工况识别率 99.71%；陆云才 2023 把时域与频域信号做成多通道输入，配合集成学习，单一缺陷 99.2%、混合缺陷 99.7%。

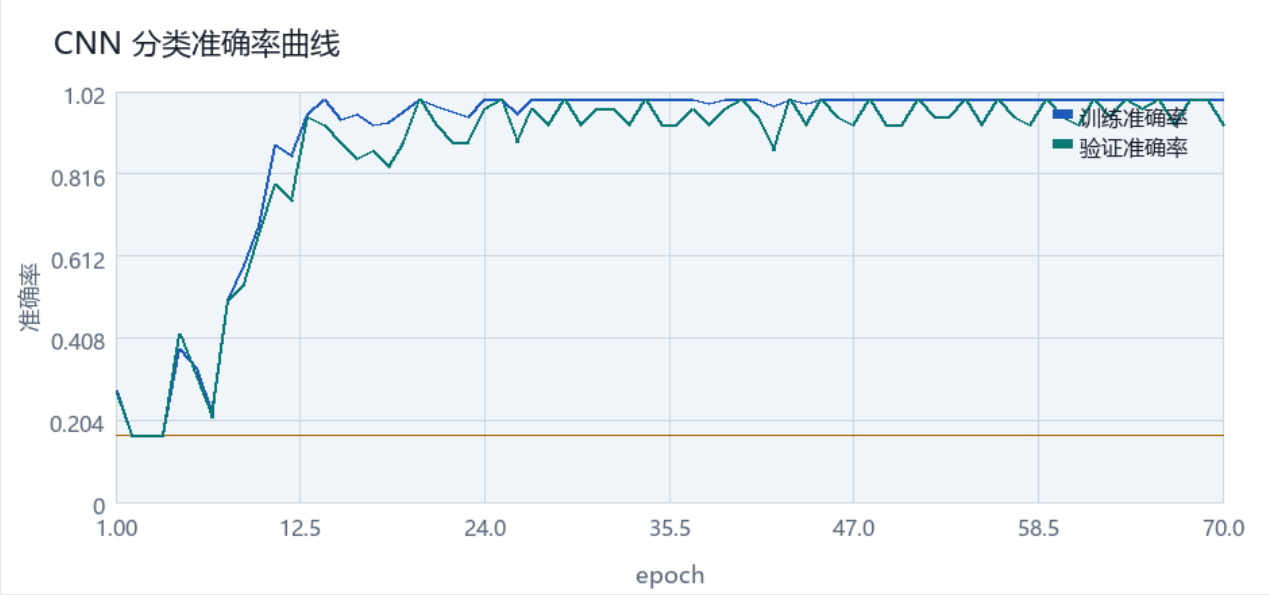


图 9-1　手写 CNN 在 6 类合成声纹上的准确率曲线：训练集很快到 100%，验证集在 97% 附近波动——验证集低于训练集是正常现象，差距过大才是过拟合

⑥ 实现要点

```
def im2col(X, F, stride):
    C, H, W = X.shape
    Ho = (H - F)//stride + 1; Wo = (W - F)//stride + 1
    cols = np.empty((C*F*F, Ho*Wo))
    for c in range(C):
        for i in range(F):
            for j in range(F):
                patch = X[c, i:i+stride*Ho:stride, j:j+stride*Wo:stride]
                cols[(c*F+i)*F+j] = patch.ravel()
    return cols, (C, H, W, Ho, Wo)

# 前向：out = (W_col @ cols).reshape(C_out, Ho, Wo) + b[:,None,None]
```

维度检查：`W_col` 是 `(C_out, C·F·F)`，`cols` 是 `(C·F·F, Ho·Wo)`，乘出来 `(C_out, Ho·Wo)`，reshape 成 `(C_out, Ho, Wo)`——和手算的输出尺寸对上就说明写对了。

推导详解 · 第 9 讲　CNN 的尺寸、参数与反向传播

1. 输出尺寸公式的逐步推导

输入高 H_{in}，上下各补 P 圈零 → 有效高 $H' = H_{\text{in}} + 2P$。大小为 F 的核，其左上角能放的位置满足「右下角不越界」，即起点 i 从 0 取到 $H' - F$。步长 S 时能取到的起点数为 $\lfloor (H' - F)/S \rfloor + 1$，于是

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} + 2P - F}{S} \right\rfloor + 1 \tag{9-8}$$

算例：$H = 32, F = 3, P = 1, S = 1 \to 32$；$P = 0, S = 2 \to \lfloor 29/2 \rfloor + 1 = 15$。若希望「same」保持尺寸且 $S = 1$，解得 $P = (F - 1)/2$，所以 F 取奇数——这就是卷积核几乎都是 3、5、7 的原因。

2. im2col 的维度为什么是 $(CF^2) \times (H_{\text{out}} W_{\text{out}})$

每个输出位置需要一块 $F \times F \times C$ 的数据，拉平成长度 CF^2 的列；共 $H_{\text{out}} W_{\text{out}}$ 个输出位置。把 C_{out} 个核各拉成一行，卷积就变成

$$Y_{[C_{\text{out}} \times H_{\text{out}} W_{\text{out}}]} = W_{\text{col}}\,[C_{\text{out}} \times CF^2] \;\cdot\; X_{\text{col}}\,[CF^2 \times H_{\text{out}} W_{\text{out}}] \tag{9-9}$$

例：输入 $(1, 32, 32)$、$F = 3$、$P = 1$、$C_{\text{out}} = 4 \to X_{\text{col}}$ 是 9×1024，W_{col} 是 4×9，一次 $4 \times 9 \times 1024 = 36\,864$ 次乘加即得全部输出。内存代价：原输入 1024 个数 → 展开后 9216 个，放大 9 倍（F^2）。

3. 反向传播三条公式从矩阵乘直接得到

由 $Y = W_{\text{col}} X_{\text{col}}$，记上游梯度 $G = \partial L / \partial Y$（形状同 Y），套用第 8 讲式 (8-10)：

$$\frac{\partial L}{\partial W_{\text{col}}} = G\, X_{\text{col}}^{\mathsf{T}}, \qquad \frac{\partial L}{\partial X_{\text{col}}} = W_{\text{col}}^{\mathsf{T}} G \tag{9-10}$$

验证形状：G 是 $(C_{\text{out}}, N_{\text{pos}})$、$X_{\text{col}}^{\mathsf{T}}$ 是 (N_{pos}, CF^2) → 结果 (C_{out}, CF^2) 与 W_{col} 一致 √。

col2im 必须累加：同一个输入像素会出现在多个重叠窗口里，因此 $\partial L / \partial X$ 的每一处是 若干个 $\partial L / \partial X_{\text{col}}$ 元素的和。写成覆盖赋值会让梯度检查在窗口重叠区失败，且失败位置呈周期性—— 这是最容易忽略的实现细节。

池化回传：最大池化前向保存 argmax 掩码 M，反向 $\partial L / \partial X = M \odot \text{up}(G)$（只回传最大值位置）；平均池化则把 G 除以池化窗口面积后广播回全部位置。

4. 参数量与感受野的两笔账

$$N_{\text{param}} = (F^2 C_{\text{in}} + 1) C_{\text{out}}, \qquad \text{RF}_k = \text{RF}_{k-1} + (F_k - 1) \prod_{j<k} S_j \tag{9-11}$$

三层 3×3、步长全 1：RF = 3 → 5 → 7，参数量 $3 \times (9C_{\text{in}} + 1)C_{\text{out}}$；若用一层 7×7 达到同样感受野，参数量是 $(49C_{\text{in}} + 1)C_{\text{out}}$，约多 1.8 倍，而且少两层非线性。「多层小核优于单层大核」就是这么算出来的。

把感受野换算到物理时间：8 kHz 下 RF=80 点 = 10 ms，恰是 100 Hz 基频的一个周期；若网络只有 3 层 3×3（RF=7 点 = 0.875 ms），它根本看不到一个完整周期，再深的全连接也补不回这个信息。设计网络前先算这笔账，比盲目调层数有用得多。

5. 公式 ↔ 代码

```
# 式(9-8) 尺寸
Hout = (Hin + 2*P - F)//S + 1

# 式(9-9) im2col（单通道示意）
cols = np.array([x[i:i+F, j:j+F].ravel()
                 for i in range(Hout) for j in range(Wout)]).T   # (F*F, Npos)
out = (W_col @ cols).reshape(Cout, Hout, Wout)

# 式(9-10) 反向 + col2im（注意 += 累加）
dW_col = dout.reshape(Cout, -1) @ cols.T
dX_col = W_col.T @ dout.reshape(Cout, -1)
dx = np.zeros_like(x)
for idx, (i, j) in enumerate(positions):
    dx[i:i+F, j:j+F] += dX_col[:, idx].reshape(F, F)   # 累加!
```

6. 边界与失效条件

- 边界像素参与的输出位置更少，梯度天然偏小；若不做 padding，输出逐层缩小，几层后就没了。声纹图谱常用 `same` padding 保持时间轴。
- im2col 在大输入上内存爆炸：$F = 5$、输入 512×512 时放大 25 倍；生产库改用隐式 GEMM 或 Winograd。
- 把「语谱图」当普通图像做二维卷积时，两个轴的物理含义不同（时间 vs 频率），平移不变性在时间轴成立、在频率轴不成立（100 Hz 的峰挪到 3 kHz 是完全不同的故障）。因此更严谨的做法是频率轴不共享权重，或只用一维时间卷积。

误区与注意事项

误区 ① 输出尺寸算错。永远先用公式算一遍再跑代码，别靠"看起来差不多"。② **col2im** 时直接 **reshape**。重叠位置必须累加。③ 池化反向传播把梯度全给最大值位置还是平均分？最大池化只把梯度给最大值那一个位置，其余为 0。④ 以为卷积核越大越好。两个 3×3 的感受野等于一个 5×5，但参数更少、非线性更多，所以现代网络偏爱小核堆叠。

自检

- [ ] 我能说出卷积相对全连接的三个假设，以及它带来的参数节省。
- [ ] 我能算出 32×32、3×3 核、P=1、S=1 的输出尺寸（32）和参数量（4 个核 → 40）。
- [ ] 我知道 3 层 3×3 卷积的感受野是 7×7，并能推出一般式。
- [ ] 我能解释 im2col 的作用，以及 col2im 为什么要累加。

第 10 讲

训练、评估与过拟合

目标

- 会正确划分数据、正确做标准化，能识别"数据泄漏"。
- 能读懂混淆矩阵、Precision/Recall/F1、ROC/AUC。
- 理解为什么"100% 准确率"常常是坏消息。

产出

- 一份完整的评估报告：混淆矩阵 + 逐类 F1 + 一条噪声衰减曲线。
- 能对一个"99% 准确率"的结论提出至少两个质疑。

① 数据怎么分，为什么必须这样分

三集合划分（严格隔离）

集合	占比	唯一用途
训练集	60%	计算梯度、更新参数
验证集	20%	选超参数（学习率、层数、早停轮数）
测试集	20%	只在最后用一次，报告最终性能

划分必须在提取特征之前按「说话人 / 设备编号」分组做，不能按帧随机切： 同一段录音的相邻帧高度相关，随机切会让测试集里混进训练集的近似副本，指标虚高。

三层划分的意义：如果用测试集去调超参数，测试集的信息就"泄漏"进模型了，最后报出来的数字是虚高的。测试集只能看一次，看多了它就不再是"没见过的数据"。

数据泄漏的典型例子（都真实发生过）

表 10-1　数据泄漏的典型例子

做法	为什么错	正确做法
先对全体数据标准化再划分	测试集的均值方差泄漏进训练	只用训练集算 mean/std，再变换验证/测试集
同一段录音切成多段，分别放进训练和测试	相邻片段几乎一样，等于考原题	按"录音/设备/日期"分组划分
用测试集反复调参	测试集变成了验证集	调参只看验证集

第二行在声纹里极其常见：把一段 10 秒录音切成 20 个 0.5 秒样本，随机划分后训练集和测试集里都有来自同一段录音的片段——模型只要记住"这段录音的底噪"，就能答对，看起来准确率 99%，换个设备立刻崩。

② 过拟合：训练集满分，测试集不及格

过拟合指模型把训练集的噪声也学进去了。判断信号很直接：

从损失曲线读诊断

现象	结论	对策
训练损失持续下降，验证损失先降后升	过拟合	早停、L2、dropout、增数据
训练与验证损失都很高	欠拟合	加大模型、多训几轮、查特征与学习率
损失震荡不降甚至 NaN	学习率过大 / 梯度爆炸	降 η、梯度裁剪、检查归一化

四类应对手段

表 10-2　过拟合的四类应对手段

手段	怎么做	代价
L2 正则	损失加 $\lambda\Sigma w^2$，抑制大权重	需要调 λ
Dropout	训练时随机丢弃一部分神经元	训练变慢、推理要关闭
早停	验证损失不降就停	需要可靠的验证集
数据增强	加噪声、时间平移、增益扰动	可能引入不真实样本

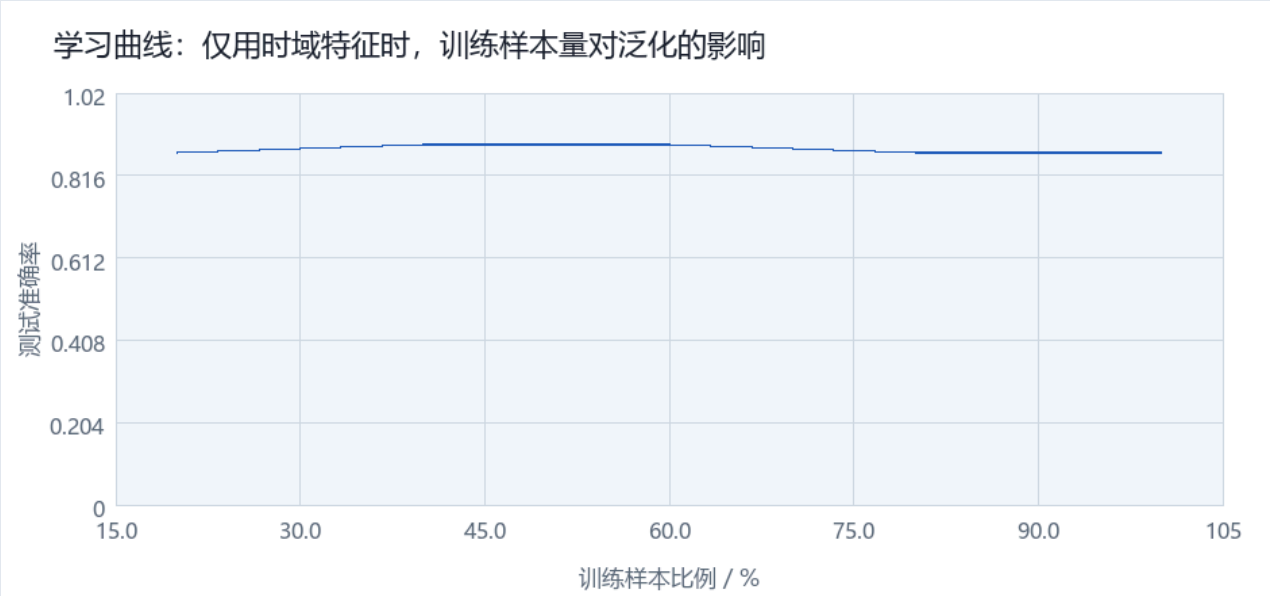


图 10-1　学习曲线：只给模型 8 维时域特征，随训练样本比例增加，测试准确率的变化。样本少时曲线抖动大——这就是声纹领域为什么总在喊"数据不够"

③ 准确率会骗人：混淆矩阵与 F1

假设 100 个样本里 95 个是"正常"、5 个是"局放"。一个把所有样本都判成"正常"的模型，准确率是 **95%**，但它一个故障都抓不到。所以必须看混淆矩阵：

表 10-3　二分类混淆矩阵

	预测：正常	预测：故障
真实：正常	TN（真阴）	FP（假阳，误报）
真实：故障	FN（假阴，漏报）	TP（真阳，正确报警）

$$\mathrm{Acc}=\frac{TP+TN}{TP+TN+FP+FN},\quad P=\frac{TP}{TP+FP},\quad R=\frac{TP}{TP+FN},\quad F_1=\frac{2PR}{P+R} \tag{10-3}$$

精确率 P 回答「报了警的里面有多少是真故障」（少误报）；召回率 R 回答「真故障里抓到了多少」（少漏报）。F_1 是两者调和平均，比算术平均更惩罚偏科：$P=1, R=0.1$ 时算术平均 0.55，F_1 只有 0.18。类别不平衡时（故障样本远少于正常）准确率会骗人：全判「正常」也能有 95% 准确率，所以必须同时看 P, R, F_1。

工程上怎么选？漏报代价高（安全类）就提高召回率，误报代价高（人力巡检）就提高精确率。这也解释了第 12 讲的 DCF：它把两类错误的代价直接写进指标。

④ ROC 与 AUC：把阈值的影响一次画完

分类器输出的其实是概率，取不同的阈值就得到不同的 (FPR, TPR) 点。把所有阈值扫一遍连成曲线，就是 ROC：

$$\mathrm{FPR}=\frac{FP}{FP+TN},\qquad \mathrm{TPR}=\frac{TP}{TP+FN}=R,\qquad \mathrm{AUC}=\int_0^1 \mathrm{TPR}(\mathrm{FPR})\,\mathrm{d}\,\mathrm{FPR} \tag{10-4}$$

ROC 曲线：横轴 FPR、纵轴 TPR，扫阈值得到；$\mathrm{AUC}=0.5$ 是随机猜，1.0 是完美，越大越好。

> **注意这是陷阱** 上面是机器学习教材的画法。声纹领域传统用 DET 曲线（横轴 FA、纵轴 FR 的递减曲线，常用正态偏差刻度），AUC 越小越好；第 12 讲会专门讲这套评价体系和阈值的代价模型。

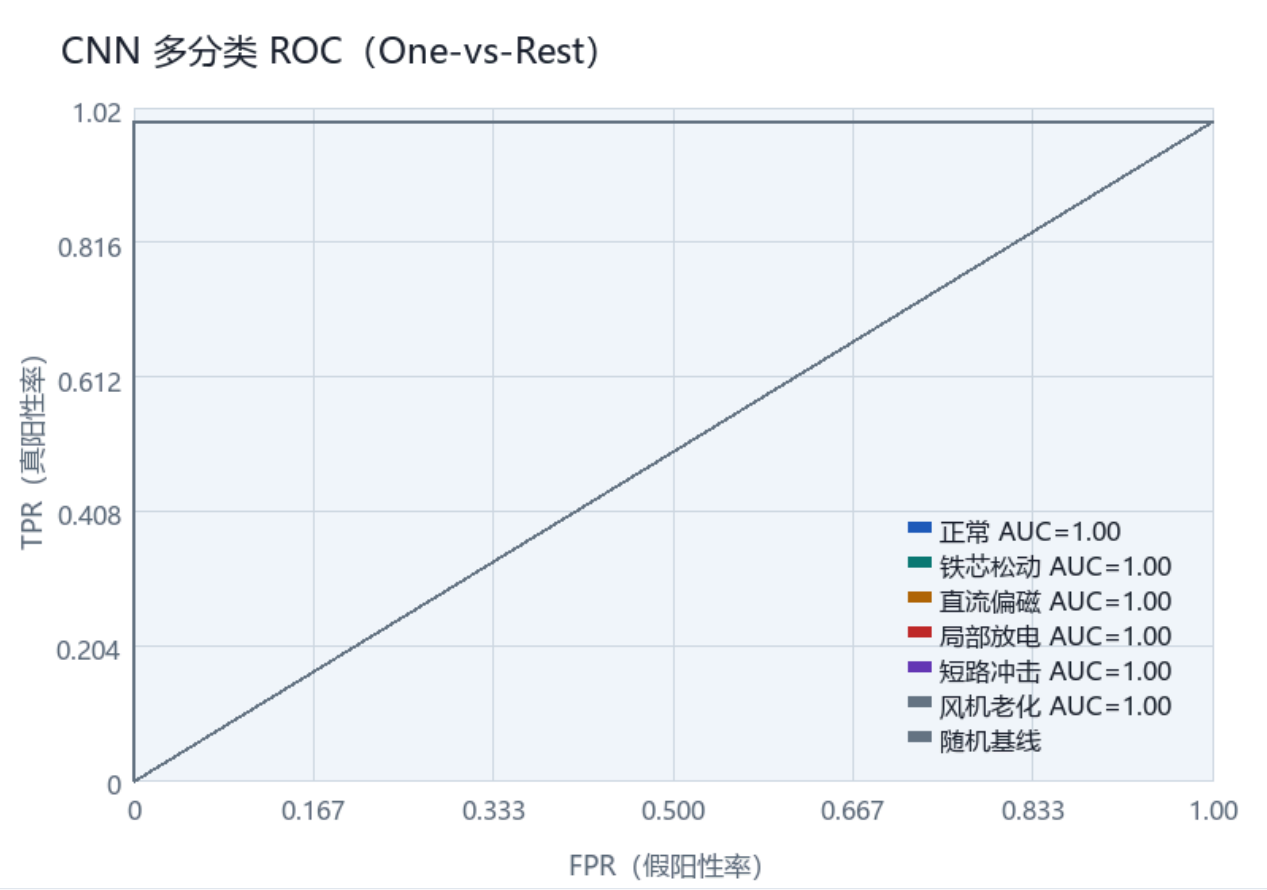


图 10-2　六类声纹的 One-vs-Rest ROC：全部 AUC = 1.00，曲线贴住左上角。这不是好消息，而是数据太容易——合成数据可分性过高，ROC 失去区分度

从这张图该学到的事 当所有模型的 AUC 都等于 1 时，ROC 就没有信息量了。这时要么换更难的数据（加噪声、跨设备），要么换指标（噪声鲁棒性曲线、混淆矩阵里的具体混淆对）。本项目正是因此补了一张"噪声衰减曲线"。

⑤ 比准确率更值得报告的：鲁棒性曲线

做法：给测试样本逐级注入高斯噪声（噪声标准差 / 数据标准差 = 0, 0.34, 0.68 … 2.0），看准确率怎么掉。

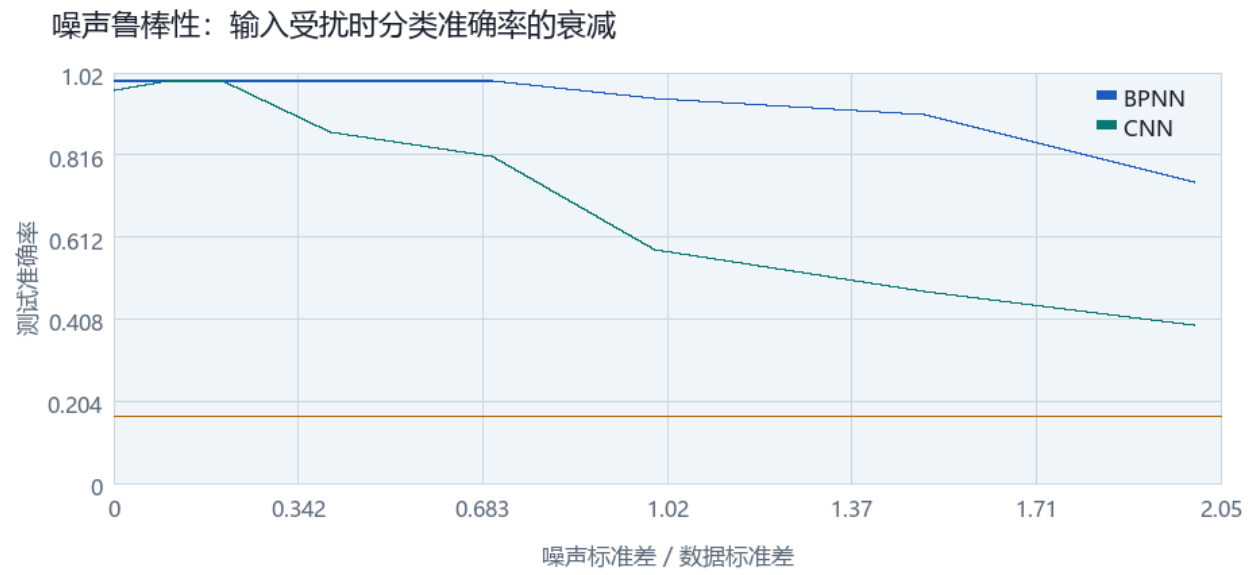


图 10-3　噪声鲁棒性曲线：噪声比 1.0 时 BPNN 仍有 96%，CNN 掉到 58%；噪声比 2.0 时分别是 75% 与 40%。**CNN** 更依赖干净的谱图纹理，**BPNN** 依赖更粗的统计量，所以抗噪表现不同

为什么这条曲线比"100% 准确率"有价值？因为现场永远有噪声。一个在干净数据上 99%、加噪后 50% 的模型，实际不可用；而在干净数据上 95%、加噪后 85% 的模型才是能落地的。文献里也是这么做的：李嘉宁 2025 明确报告"高信噪比 96%、10 dB 时提升 9.4%"，而不是只报最好的那个数。

推导详解 • 第 10 讲　优化器、正则化与训练动力学

1. 从 SGD 到 Adam：每个更新式在做什么

$$\begin{aligned}
\text{SGD:}\quad & \theta_{t+1} = \theta_t - \eta\,\nabla_\theta L(\theta_t) \\
\text{Momentum:}\quad & v_t = \gamma v_{t-1} + \eta \nabla L, \quad \theta_{t+1} = \theta_t - v_t \\
\text{Adam:}\quad & m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2 \\
& \hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t}, \quad \theta_{t+1} = \theta_t - \frac{\eta\,\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}
\end{aligned} \tag{10-4}$$

动量 v_t 是梯度的指数移动平均，等价于给损失曲面加「惯性」：在狭长谷地里抵消横向震荡、累积纵向推进。Adam 的 m_t 是一阶矩（方向），v_t 是二阶矩（每维的尺度），相除相当于给每个参数自动配一个学习率——梯度长期大的维度步长被压小，梯度小的维度被放大。$\hat{m}, \hat{v}$ 的除项是偏差修正：初始 $m_0 = v_0 = 0$，前几步估计会系统性偏小，除以 $1-\beta^t$ 后无偏。常用 $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$。

2. L2、dropout、BN 的数学形式

$$L_{\text{reg}} = L + \frac{\lambda}{2}\|\theta\|_2^2, \qquad \nabla L_{\text{reg}} = \nabla L + \lambda\theta, \qquad \theta \leftarrow (1-\eta\lambda)\theta - \eta\nabla L \tag{10-5}$$

可见 L2 每次更新都把权重乘一个 < 1 的因子（权重衰减）。注意：Adam 下 L2 与权重衰减并不等价（自适应学习率会把惩罚项也缩放），要严格解耦应使用 AdamW。

$$\text{dropout:}\quad \tilde{h} = \frac{m \odot h}{1-p},\ m_i \sim \text{Bernoulli}(1-p), \qquad \text{BN:}\quad \hat{h} = \frac{h-\mu_B}{\sqrt{\sigma_B^2+\epsilon}},\ h' = \gamma\hat{h} + \beta \tag{10-6}$$

dropout 除以 $1-p$ 是反向 **dropout**，保证训练时激活的期望与推理时一致；忘了除会导致训练/推理输出差 $1/(1-p)$ 倍。 BN 在训练时用 batch 内统计量、推理时用滑动平均的全局统计量，两个模式混用是常见线上事故。

3. 过拟合的偏差–方差分解

$$\mathbb{E}\big[(y-\hat{f})^2\big] = \underbrace{\big(\mathbb{E}[\hat{f}]-f\big)^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}\big[(\hat{f}-\mathbb{E}\hat{f})^2\big]}_{\text{方差}} + \underbrace{\sigma^2}_{\text{不可约噪声}} \tag{10-7}$$

模型太小 → 偏差大（训练/验证损失都高）；模型太大且数据少 → 方差大（训练损失低、验证损失高）。 早停、正则化、增数据都在压方差；加容量、加特征、训更久在压偏差。看两条曲线的相对位置就能判断该往哪边走， 比盲目调参有效。

4. 学习率的定量选择

损失沿某方向的曲率由 Hessian 特征值 $\lambda_{\max}$ 决定，SGD 稳定条件是 $\eta < 2/\lambda_{\max}$； 超过就震荡甚至发散。实用做法：学习率范围测试——从 10^{-6} 起每个 batch 按指数增大 η， 记录损失，取「损失开始稳定下降」到「开始上扬」之间偏左一个数量级的值。 配合余弦退火 $\eta_t = \eta_{\min} + \frac{\eta_0-\eta_{\min}}{2}\big(1+\cos(\pi t/T)\big)$ 可兼顾前期快速与后期收敛。

5. 数据划分的正确姿势（对声纹尤其重要）

设某设备有 10 段录音、每段 48 帧，共 480 个样本。若按帧随机切 60/20/20， 同一段录音的相邻帧会同时出现在训练和测试里，它们的相似度接近 1，测试准确率虚高到接近 100%。 正确做法是按录音段（或按说话人/设备编号）分组切分，保证测试集中的段在训练时完全没出现过。 更进一步，评估「未知设备」泛化能力时要用 leave-one-device-out。

6. 公式 ↔ 代码

```
# 式(10-4) Adam（含偏差修正）
m = b1*m + (1-b1)*g; v = b2*v + (1-b2)*g*g
mhat = m/(1-b1**t); vhat = v/(1-b2**t)
theta -= lr*mhat/(np.sqrt(vhat) + 1e-8)

# 式(10-5) L2 / 式(10-6) 反向 dropout
g += lam*theta
h = (h * (np.random.rand(*h.shape) > p)) / (1-p)

# 早停：验证损失连续 patience 轮不降即停
if val_loss < best - 1e-4: best, wait = val_loss, 0
else: wait += 1
if wait >= patience: break
```

7. 边界与失效条件

- 类别极不平衡时，交叉熵会被多数类主导；改用加权 CE（权重 $\propto 1/n_c$）或 focal loss。
- 小 batch 下 BN 的 μ_B, σ_B^2 估计噪声大，可换 LayerNorm / GroupNorm。
- 验证集被反复用于调参，本质上也会「过拟合到验证集」；超参数调得多时，应再留一个最终测试集。

误区与注意事项

误区 ① 只报准确率。类别不平衡时毫无意义。② 先标准化再划分。数据泄漏。③ 同一录音切段后随机划分。等于考原题。④ 用测试集调参。⑤ 看到 **AUC=1** 就高兴。先怀疑数据太简单。

自检

- [ ] 我能说出训练/验证/测试三者的分工，并举一个数据泄漏的例子。
- [ ] 我能写出 Precision、Recall、F1 的公式，并说出什么时候该优先哪个。
- [ ] 我能解释为什么"全部判正常"也能有 95% 准确率。
- [ ] 我能说清"噪声鲁棒性曲线"比单一准确率更有价值的原因。

第 11 讲

声纹识别概览：任务、流程、与语音识别的区别

目标

- 能区分声纹验证、辨认、开集/闭集四种设定。
- 能说清"声纹识别"和"语音识别"为什么是正交的两个问题。
- 能把人的声纹任务与设备状态识别一一对应起来。

产出

- 一张"任务类型 → 判定方式 → 指标"的对照表。
- 能对任意一个声纹需求说出该用哪种设定。

① 四种任务设定，先分清再谈算法

表 11-1　四种任务设定的对比

设定	问题	本质	典型指标
声纹验证（1:1）	这段话是"张三"说的吗？	二值判别（是/否）	EER、DCF、FAR/FRR
闭集辨认（1:N）	这段话是库里 N 个人中的谁？	N 分类（一定有答案）	准确率、Top-1/Top-5
开集辨认	这段话是库里的人吗？是谁？	先拒识再分类	EER + 准确率
声纹分割/聚类	这段录音里有几个人，各自说了哪段？	无监督聚类	DER（分割错误率）

为什么必须先分清？因为指标完全不同、算法取舍也完全不同。验证任务关心"阈值怎么定"，辨认任务关心"排名对不对"，开集还多一个"拒识"环节。拿辨认的准确率去评价一个验证系统，是没有意义的。

② 与语音识别正交：一句话讲透

两个方向相反的任务

任务	想知道	要保留	要滤掉
语音识别 ASR	说了什么	文本内容	说话人身份
声纹识别 SR	谁说的	说话人身份	文本内容

两者要抑制的变量恰好互为对方的信号，所以说它们「正交」。这也解释了为什么 MFCC 在两边都能用： 它保留的是声道的形状（共振峰），既承载音素也承载说话人生理特征，靠后续模型决定用哪部分。

这个说法（王泉《声纹技术》3.1.1 的表述）非常好用，因为它直接解释了工程上的差异：语音识别要做"说话人自适应"来消除个体差异；声纹识别反而要做"内容归一化"来消除文本差异。同一个 MFCC 特征，两个任务都在用，但后面的建模目标相反。

③ 系统流程：注册 + 测试

一次完整验证的三段式

1. 注册 **enrollment**：用户说几段话 → 提特征 → 训练/存储该用户的模型或一个 embedding 向量；
2. 测试 **test**：说一段话 → 提特征 → 与库中模型逐一比较 → 得到相似度分数 s；
3. 判决 **decision**：$s > \theta$ 则接受，否则拒绝；θ 由代价模型或目标 EER 选定。

对应两种任务：确认（1:1，答案「是/否」，需要阈值）与辨识（1:N，取分数最高者，闭集无需阈值）。

要注意：分数不是概率，它只是一个"越像越大"的数。阈值定在哪里，取决于你把"误拒"和"误受"哪个看得更重——这正是第 12 讲的全部内容。

文本相关 vs 文本无关

表 11-2　文本相关与文本无关声纹的对比

类型	做法	优点	缺点
文本相关	固定说同一句话（如"打开门禁"）	性能好，可做防录音攻击	用户体验差，易被录音重放
文本无关	随便说什么	自然，防重放	难度大，需建模内容无关的身份特征
文本提示	系统随机给词，用户跟读	兼顾性能与防攻击	实现复杂

④ 声纹到底"看"的是什么生理/行为特征

表 11-3　声纹依赖的生理与行为特征

层面	具体特征	在频谱上的表现
声道长度与形状	声道短 → 共振峰整体偏高	频谱包络的整体平移
声带特性	基频（男 100–150 Hz，女 180–250 Hz）	谐波间隔
发音习惯	语速、连读、口音	时间维度上的动态模式
鼻腔/口腔耦合	个人音色	特定频段的共振峰形状

所以 MFCC 之所以有效，不是因为它"神奇"，而是因为它的低频密采样 + **DCT** 包络恰好抓住了"声道形状"这个身份载体。

⑤ 迁移到设备：人 ↔ 变压器

这套框架能几乎原样搬到设备状态识别上，只要做一次"语义替换"：

表 11-4　人声纹与设备声纹的对应关系

人的声纹	变压器声纹
说话人身份（谁）	运行工况/故障类型（哪种状态）
注册（录入用户声音）	建立各类工况的样本库
文本内容（要消除的干扰）	负载电流、电压波动（要消除的干扰）
信道差异（麦克风、电话线）	传感器型号、安装位置、传声路径
EER（等错误率）	同样适用，用来定报警阈值

文献里的工作正是这么做的：刘云鹏 2020 用"50 Hz 倍频倒谱系数 + GRU"识别变压器直流偏磁（特征直接利用"偏磁会产生 50 Hz 倍频"这一物理先验）；齐子豪 2025 用多粒度知识特征 + Transformer 做变压器故障声纹辨识。它们都在做同一件事：把人声纹的成熟框架，配上设备特有的物理先验。

推导详解 • 第 11 讲　声纹任务的数学定义

1. 两种任务的严格表述

设注册模型为 λ_{tar}，测试语音特征为 X，打分函数 $s(X,\lambda)$。

$$\textbf{确认 (1:1)：}\quad s(X,\lambda_{\text{tar}}) \gtrless_{H_1}^{H_0} \theta, \qquad \textbf{辨识 (1:N)：}\quad \hat{c}=\arg\max_{c} s(X,\lambda_c) \tag{11-1}$$

确认是假设检验：H_0「不是本人」、H_1「是本人」，必须设阈值，两类错误都可能出现。 闭集辨识是分类：只需比大小，无需阈值；但现实中存在「库里根本没有此人」的开集情形， 此时要加一个拒识门限，否则任何陌生人都会被强行匹配给最像的那个人。

2. 似然比检验：为什么「比分数」在统计上是对的

Neyman–Pearson 引理指出，在给定 FA 水平下使 FR 最小的最优检验是似然比：

$$\Lambda(X)=\frac{p(X\mid H_1)}{p(X\mid H_0)} \gtrless_{H_0}^{H_1} \theta', \qquad \log\Lambda=\log p(X\mid\lambda_{\text{tar}})-\log p(X\mid\lambda_{\text{background}}) \tag{11-2}$$

GMM-UBM 的打分正是这个式子：目标模型与 UBM 的对数似然之差。 而「余弦相似度」可以看作在高斯先验、长度归一化 embedding 假设下对似然比的一种简化。 理解了这个，就不会把打分值当成概率——它只是似然比的单调函数，尺度随模型、数据而变，所以必须做 z/t-norm（第 12 讲）。

3. 系统的四层数据流

层	输入 → 输出	本讲义对应
① 采集	声波 → WAV	第 1–2 讲（$F_s=8$ kHz、16 bit）
② 前端	WAV → 39 维 MFCC 序列	第 3–7 讲
③ 后端	特征序列 → 模型/embedding → 分数	第 8–10、13–14 讲
④ 判决	分数 → 是/否	第 12 讲（θ、DCF、归一化）

任何一层出错都会表现为「指标差」，但根因完全不同：① 混叠无法靠后端补救；② 参数错（如预加重压掉 100 Hz）后端再强也学不到； ③ 模型容量不足是欠拟合；④ 阈值选错则模型明明很好、用户却频繁被拒。排查时按层从前往后走，别一上来就调网络。

4. 边界与失效条件

- 注册数据太少 → 模型无法覆盖本人的音素/工况变化，FR 飙升。i-vector 与 x-vector 正是为解决少样本注册而生。
- 训练与部署的信道不一致（不同麦克风、不同距离、不同采样率）→ 分数分布整体平移，全局阈值失效，必须做分数归一化或域适配。
- 时间漂移：设备老化、麦克风灵敏度变化会让人几个月后「不像自己」，需要模板更新机制。

误区与注意事项

误区 ① 把辨认的准确率当验证的指标。② 以为分数可以当概率用。未做归一化的分数没有概率意义（第 12 讲的 z-norm/t-norm 就是为此）。③ 忽略信道差异。换麦克风、换距离，性能可能掉一半。④ 用"同一段录音切段"做测试。这是声纹评估里最致命的错误。

自检

- [ ] 我能分清验证、闭集辨认、开集辨认，并说出各自指标。
- [ ] 我能用"正交"解释声纹识别与语音识别的区别。
- [ ] 我能把"注册—测试—阈值判决"流程复述一遍。
- [ ] 我能说出人声纹里"文本内容"对应设备声纹里的什么干扰。

第 12 讲

声纹评价指标：EER、ROC、DCF

目标

- 能画出阈值移动时 FA 与 FR 的反向变化，并解释为什么不存在"两全"的阈值。
- 理解 EER 的定义，并能解释为什么阈值点的真实错误率是 2×EER。
- 会用 DCF 把"两类错误代价不同"写进指标。

产出

- 一张 FA–FR 曲线，并标出 EER 点。
- 给定代价参数能算出 DCF，并说明阈值该往哪边调。

① 两类错误，此消彼长

$$\mathrm{FAR}(\theta) = \frac{N_{\mathrm{FA}}(\theta)}{N_{\mathrm{impostor}}}, \qquad \mathrm{FRR}(\theta) = \frac{N_{\mathrm{FR}}(\theta)}{N_{\mathrm{target}}} \tag{12-1}$$

FA（False Accept，误受）：把冒充者当成本人 → 安全风险； **FR**（False Reject，误拒）：把本人拦在门外 → 体验问题。 两者都是阈值 θ 的函数，且单调方向相反：θ 调严 → FA↓ 但 FR↑。 这条此消彼长的关系决定了不存在「同时为零」的阈值，必须引入代价（见式 12-5）。

关键事实：它们是同一个阈值的两种后果。把阈值调高（更严格）：更多真实用户被拒（FR 上升），冒充者更难通过（FA 下降）。把阈值调低则相反。所以"既要又不"是不可能的——只能根据代价选一个工作点。

一个具体场景 门禁：误拒的代价是员工迟到抱怨，误受的代价是陌生人进楼。所以门禁阈值通常调得较严（宁可误拒）。手机解锁：误拒的代价是机主烦躁，误受的代价是被人翻手机——两者都重要，所以厂商通常给出"更快/更安全"两档。

② EER：把整条曲线压成一个数

既然阈值可选，就需要一个"与阈值无关"的指标来比较系统好坏。EER（等错误率）就是那条曲线上 **FA = FR** 的点：

$$\theta_{\mathrm{EER}} = \arg\min_{\theta} \left|\mathrm{FAR}(\theta) - \mathrm{FRR}(\theta)\right|, \qquad \mathrm{EER} = \mathrm{FAR}(\theta_{\mathrm{EER}}) = \mathrm{FRR}(\theta_{\mathrm{EER}}) \tag{12-2}$$

EER 越小系统越好。实际分数是离散的，两条阶梯曲线往往不严格相交， 工程做法是在交叉区间对 FAR、FRR 分别做线性插值再求交点，而不是取最接近的采样点。 EER 的优点是与阈值无关，可以跨系统比较；缺点是它默认 FA 与 FR 代价相等，而真实门禁场景里放进一个冒充者往往比拒一次本人严重得多。

③ 为什么真实错误率是 2×EER（这一节几乎人人误解）

EER 是"每个方向各 1%"。但一次实际使用中，用户要么是本人、要么是冒充者，两者不会同时发生——所以在 **EER** 工作点上，把所有测试合并统计，出错的比例是 **FA + FR = 2×EER**。

$$P_{\text{err}}\big|_{\text{EER}} = \tfrac{1}{2}\text{FAR} + \tfrac{1}{2}\text{FRR} = \text{EER} \tag{12-3}$$

澄清一个常见误读：EER = 5% 不等于「10% 的测试会判错」。若真实试验与冒充试验数量相等，总错误率 $= \frac{1}{2}\text{FAR} + \frac{1}{2}\text{FRR} = \text{EER} = 5\%$。但厂商常按「误识率 5%」宣传，用户在先验不均衡（冒充尝试远多于本人，或反之）时的实际感受会不同：设 $P_{\text{target}} = 0.01$，则总错误率 $= 0.01 \times 0.05 + 0.99 \times 0.05 = 5\%$ 仍相同，真正影响体感的是错误落在哪一边——1 次误放和 1 次误拒给人的代价完全不同，所以要 DCF。

更严格地说，若真实试验与冒充试验数量相等，总体错误率 = (FA + FR)/2 = EER；若按"每次使用只有一次判决"统计并且两类试验各占一半，则两类错误合计占比为 2×EER。工程上报告指标时务必写清口径：是"每类各 **5%**"，还是"总体 **10%**"。王书 3.2.4 特意点出这一点，就是为了防止误读。

④ ROC 的两种画法（看论文时必须先确认）

表 12-1　ROC 的两种画法对比

画法	横轴	纵轴	曲线走向	AUC 含义
机器学习教材	FPR（=FA）	TPR（=1−FR）	单调递增，贴左上角	越接近 1 越好
声纹/生物识别传统	FA	FR	单调递减，贴左下角	越接近 0 越好

两者是同一组数据的两种视角（纵轴一个用 TPR 一个用 FR = 1−TPR），但结论的读法完全相反。看到一张 ROC 先看轴标再下判断，这是读声纹论文的第一道防线。

⑤ DCF：把"代价"写进指标

EER 假设两类错误代价相等，但现实不是。检测代价函数（Detection Cost Function）把代价与先验概率都显式写进去：

$$C_{\text{det}}(\theta) = C_{\text{FR}}\,\text{FRR}(\theta)\,P_{\text{target}} + C_{\text{FA}}\,\text{FAR}(\theta)\,P_{\text{nontarget}}, \qquad \text{DCF} = \min_{\theta} \frac{C_{\text{det}}(\theta)}{C_{\text{default}}} \tag{12-4}$$

C_{FR}：漏掉一个真人的代价；C_{FA}：放进一个冒充者的代价；$P_{\text{target}} + P_{\text{nontarget}} = 1$ 是先验。$C_{\text{default}} = \min(C_{\text{FR}}P_{\text{target}}, C_{\text{FA}}P_{\text{nontarget}})$ 是「永远拒绝 / 永远接受」两种平凡策略中较好的那个，用它归一化后 $\text{DCF} \le 1$，1 表示系统毫无价值。NIST SRE 常用 $C_{\text{FR}} = C_{\text{FA}} = 1$、$P_{\text{target}} = 0.01$。

算一个例子：设 C_FR = 1、C_FA = 10（放进冒充者的代价是误拒的 10 倍）、P_target = 0.9、P_nontarget = 0.1。

$$\begin{aligned} \theta_1 &: C_{\text{det}} = 1(0.02)(0.9) + 10(0.05)(0.1) = 0.018 + 0.050 = 0.068 \\ \theta_2 &: C_{\text{det}} = 1(0.08)(0.9) + 10(0.01)(0.1) = 0.072 + 0.010 = 0.082 \end{aligned} \tag{12-5}$$

设 $C_{\text{FR}} = 1,\ C_{\text{FA}} = 10,\ P_{\text{target}} = 0.9$。阈值 θ_1（FA=0.05, FR=0.02）得 0.068；更严格的 θ_2（FA=0.01, FR=0.08）反而得 0.082，更差。原因：本场景里真人占 90%，把 FR 从 2% 抬到 8% 带来的损失（0.054）远大于把 FA 从 5% 压到 1% 省下的（0.040）。阈值不是越严越好，是让代价最小才好。

看这个例子就明白为什么 EER 不够用：两个阈值的 EER 附近可能差不多，但按实际代价算出来的最优工作点完全不同。

⑥ 分数归一化：z-norm 与 t-norm

同一套系统，换一个说话人/换一段录音，分数分布会整体平移。若用一个固定阈值，就会出现"对某人特别宽松、对某人特别严格"。解决办法是用同一人的其他数据把分数标准化：

$$s' = \frac{s - \mu_{\text{imp}}}{\sigma_{\text{imp}}}, \qquad s'' = \frac{s - \mu_{\text{cohort}}(x)}{\sigma_{\text{cohort}}(x)} \tag{12-6}$$

z-norm：用一批冒充者语音对该目标模型打分，估计 μ, σ 后归一化，消除模型间的分数尺度差异； **t-norm**：用该条测试语音对一批背景模型打分后归一化，消除测试语音本身的「难易」差异； **zt-norm / s-norm**：两者串联或对称化，通常最稳，代价是需要额外的冒认/背景数据与约 2 倍计算量。 归一化的本质是把「绝对分数」变成「在同类分数分布中的相对位置」，从而让全局阈值 θ 可用。

⑦ 三个指标的分工

表 12-2　三个评价指标的分工

指标	回答什么问题	什么时候用	局限
EER	系统整体可分性如何	横向比较算法	忽略代价与先验，且需注明是"每类"还是"总体"
minDCF	在给定代价下最好能做到多好	工程选型、定阈值	依赖代价参数的主观设定
固定阈值下的 FAR/FRR	我实际部署的这个点表现如何	上线验收	不能反映其他工作点

推导详解 · 第 12 讲　阈值、DET、EER 与检测代价

1. 符号对照表

符号	含义	取值 / 范围
θ	判决阈值	打分值域内
$N_{\text{tar}}, N_{\text{imp}}$	真实试验 / 冒充试验次数	常不等
FAR, FRR	误受率 / 误拒率	[0,1]
$C_{\text{FA}}, C_{\text{FR}}$	两类错误的代价	常用 10 : 1
P_{tar}	真实用户出现的先验	NIST 常用 0.01

2. FA/FR 随阈值单调变化：从分布图上读出来

设本人分数分布密度 $p(s \mid H_1)$、冒充者分数分布 $p(s \mid H_0)$，则

$$\text{FRR}(\theta) = \int_{-\infty}^{\theta} p(s \mid H_1)\,\mathrm{d}s, \qquad \text{FAR}(\theta) = \int_{\theta}^{\infty} p(s \mid H_0)\,\mathrm{d}s \tag{12-7}$$

对 θ 求导：$\dfrac{\mathrm{d}\,\text{FRR}}{\mathrm{d}\theta} = p(\theta \mid H_1) > 0$、$\dfrac{\mathrm{d}\,\text{FAR}}{\mathrm{d}\theta} = -p(\theta \mid H_0) < 0$。一个升、一个降，且都是密度积分，所以二者不可能同时变小。这条严格单调性是所有阈值权衡的根据。 实践中不假设分布形状，而是把所有试验分数排序，逐个候选阈值统计 $N_{\text{FA}}, N_{\text{FR}}$ 得到经验阶梯曲线。

3. EER 的插值算法（工程实现细节）

分数是离散的，FAR 与 FRR 两条阶梯曲线通常不严格相交。做法是：

$$\begin{aligned}&\text{(i) 在相邻阈值 } \theta_i,\theta_{i+1} \text{ 之间找 } d(\theta)=\mathrm{FAR}-\mathrm{FRR} \text{ 变号区间}\\&\text{(ii) 线性插值：}\quad \tau=\frac{d(\theta_i)}{d(\theta_i)-d(\theta_{i+1})}\\&\text{(iii) } \mathrm{EER}=\mathrm{FAR}(\theta_i)+\tau\big[\mathrm{FAR}(\theta_{i+1})-\mathrm{FAR}(\theta_i)\big]\end{aligned}\tag{12-8}$$

直接取「$|d|$ 最小的那个采样点」在试验次数少时会高估 EER，因为阶梯宽度是 $1/N_{\text{imp}}$ 或 $1/N_{\text{tar}}$。

4. 检测代价函数的推导：从贝叶斯风险出发

定义四种结果的风险：正确接受/正确拒绝代价为 0，误受代价 C_{FA}、误拒代价 C_{FR}。 期望风险（贝叶斯风险）为各错误概率按先验加权：

$$\begin{aligned}\mathcal{R}(\theta)&=C_{\text{FR}}\,P(H_1)\,\Pr(\text{拒}\mid H_1)+C_{\text{FA}}\,P(H_0)\,\Pr(\text{受}\mid H_0)\\&=C_{\text{FR}}P_{\text{tar}}\,\mathrm{FRR}(\theta)+C_{\text{FA}}P_{\text{nontarget}}\,\mathrm{FAR}(\theta)\end{aligned}\tag{12-9}$$

这正是式 (12-5) 的 C_{det}。对 θ 求导并令为 0：

$$C_{\text{FR}}P_{\text{tar}}\,p(\theta\mid H_1)-C_{\text{FA}}P_{\text{nontarget}}\,p(\theta\mid H_0)=0\quad\Longrightarrow\quad\Lambda(\theta)=\frac{p(\theta\mid H_1)}{p(\theta\mid H_0)}=\frac{C_{\text{FA}}P_{\text{nontarget}}}{C_{\text{FR}}P_{\text{tar}}}\tag{12-10}$$

最优阈值就是似然比等于「代价×先验之比」的那个点（呼应第 11 讲式 11-2）。把 12-6 的算例代进去：右边 $=\dfrac{10\times 0.1}{1\times 0.9}=1.11$，即在该点两类密度相近，阈值应偏「宽松」一侧——与算例结论（θ_1 优于 θ_2）一致。归一化基准 $C_{\text{default}}=\min(C_{\text{FR}}P_{\text{tar}},\,C_{\text{FA}}P_{\text{nontarget}})$ 是「永远拒绝 / 永远接受」两种平凡策略的风险，故 $\mathrm{minDCF}\in[0,1]$，越接近 0 越好。

5. z-norm / t-norm 在消除什么

不同目标模型的打分分布尺度不同（有的模型分数整体偏高），不同测试语音的难度也不同。设观测分数

$$s=a_{\text{model}}+b_{\text{test}}+s_{\text{true}}\tag{12-11}$$

其中 a_{model} 是模型偏置、b_{test} 是测试语音偏置。 z-norm 用一批冒充语音估出该模型的 (μ_z,σ_z) 从而消掉 a_{model}；t-norm 用一批背景模型估出该测试语音的 (μ_t,σ_t) 消掉 b_{test}。 两者串联（zt-norm）才把两个偏置都去掉。代价：需要额外的开发集，且每条测试要多算 N_{cohort} 次打分。 **s-norm** 把两者对称平均，对队列选择更鲁棒。

6. 公式 ↔ 代码

```
# 式(12-7) 经验 FAR/FRR 曲线（无需假设分布）
ths = np.unique(np.concatenate([tar_scores, imp_scores]))
far = np.array([(imp_scores >= t).mean() for t in ths])
frr = np.array([(tar_scores <  t).mean() for t in ths])

# 式(12-8) 插值求 EER
d = far - frr
i = np.where(np.sign(d[:-1]) != np.sign(d[1:]))[0][0]
tau = d[i] / (d[i] - d[i+1])
eer = far[i] + tau*(far[i+1] - far[i])

# 式(12-9)(12-10) minDCF
cdet = C_FR*frr*P_tar + C_FA*far*(1-P_tar)
cd = cdet.min() / min(C_FR*P_tar, C_FA*(1-P_tar))

# 式(12-11) z-norm
s_norm = (s - imp_scores.mean()) / imp_scores.std()
```

7. 边界与失效条件

- 试验次数少时 EER 分辨率受限于 $1/N$：100 次冒充试验的最小非零 FAR 就是 1%，报「EER=0.3%」毫无意义。报告指标必须同时给出试验次数与置信区间。
- DET 曲线常用正态偏差刻度 $\Phi^{-1}(p)$ 拉伸低错误率区域，与 ROC 的线性刻度读法不同；**DET** 越靠近左下角越好，AUC 说法不适用。
- 阈值必须在开发集上选定，再在测试集上报结果；在测试集上调阈值等于作弊。
- 归一化队列要与目标模型同域，否则估计出的 μ, σ 反而引入偏差。

误区与注意事项

误区 ① 把 **EER** 当"总体错误率"。它是单方向错误率，总体约为 2 倍。② 用机器学习教材的 **ROC** 读法去读声纹 **ROC**。轴和结论都相反。③ 拿 **EER** 直接定阈值。EER 点只是"两类等错"，不一定是你的最优工作点，要用 DCF。④ 不做分数归一化就比较不同人的性能。

自检

- [ ] 我能解释为什么提高阈值会同时降低 FA、提高 FR。
- [ ] 我能说清 EER=5% 时，总体错误率为什么约 10%。
- [ ] 我能区分两种 ROC 画法，并说出各自的 AUC 读法。
- [ ] 我能用 $C_{\text{det}} = C_{\text{FR}}\text{FRR}P_{\text{tar}} + C_{\text{FA}}\text{FAR}P_{\text{nontarget}}$ 算出一个具体数值并比较两个阈值。

第 13 讲

经典声纹方法：GMM、UBM、i-vector

目标

- 理解 GMM 为什么能刻画"一帧特征的概率分布"，以及 EM 在优化什么。
- 理解 UBM-MAP 为什么能解决"每人只有几十秒语音"的问题。
- 知道 i-vector 与 PLDA 各解决了什么，为什么深度学习方法取代了它们。

产出

- 能画出"特征 → GMM/UBM → 超矢量/i-vector → 打分"的流程。
- 能说出每一步的维度数字（39 → 512 高斯 → 400 维 i-vector）。

① 为什么用概率模型而不是直接比特征

一个人说 10 秒话，得到约 1000 帧、每帧 39 维。你没法"直接比较"两个人的 1000×39 矩阵——长度不同、时间对不齐。所以需要一个把变长序列压成定长模型的办法，这就是 GMM 的作用：它用一组高斯分布描述"这个人的特征在空间中倾向出现在哪些区域"。

$$p(\mathbf{x} \mid \lambda) = \sum_{c=1}^{C} \pi_c \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_c, \Sigma_c), \qquad \sum_c \pi_c = 1 \tag{13-1}$$

$\lambda = \{\pi_c, \boldsymbol{\mu}_c, \Sigma_c\}_{c=1}^{C}$：混合权重、均值、协方差；$\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \Sigma) = \dfrac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp\left[-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^{\mathsf{T}} \Sigma^{-1} (\mathbf{x}-\boldsymbol{\mu})\right]$。

GMM 用多个高斯的加权和逼近任意形状的分布。声纹里通常取对角协方差（$C = 512 \sim 2048$），因为 39 维特征全协方差的参数量与过拟合风险都太高。

直觉：单个高斯只能描述"一个团"，而人的特征分布是多峰的（不同音素、不同发声状态），所以用 C 个高斯加权叠加。C 通常取 512~2048。

② EM 算法：怎么把参数学出来

目标：最大化所有帧的对数似然 $\sum_t \ln p(\mathbf{x}_t \mid \lambda)$。直接求导没有解析解，所以用迭代的 EM：

$$\begin{aligned} \text{E:}\ & \gamma_{tc} = \frac{\pi_c \mathcal{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_c, \Sigma_c)}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_j, \Sigma_j)} \\ \text{M:}\ & \pi_c \leftarrow \frac{\sum_t \gamma_{tc}}{T}, \quad \boldsymbol{\mu}_c \leftarrow \frac{\sum_t \gamma_{tc} \mathbf{x}_t}{\sum_t \gamma_{tc}}, \quad \Sigma_c \leftarrow \frac{\sum_t \gamma_{tc} (\mathbf{x}_t - \boldsymbol{\mu}_c)(\mathbf{x}_t - \boldsymbol{\mu}_c)^{\mathsf{T}}}{\sum_t \gamma_{tc}} \end{aligned} \tag{13-2}$$

γ_{tc} 是「第 t 帧属于第 c 个高斯」的责任度（后验概率）。EM 通过构造对数似然的下界（ELBO）并交替优化：E 步固定参数算责任度，M 步固定责任度做加权极大似然，每轮保证似然不降，迭代到收敛。实现必须在对数域做（log-sum-exp 技巧），否则 512 个高斯的密度连乘会直接下溢为 0。初始化用 k-means，否则易陷入局部最优。

EM 保证每一步都不会让似然下降（这是它的理论性质），但只保证收敛到局部最优，所以初始化很重要（常用 k-means 初始化）。

③ UBM-MAP：解决"每人只有几十秒"

如果给每个说话人单独训一个 GMM，几十秒语音根本不够（参数有几十万个）。解决办法是两步走：

$$\hat{\boldsymbol{\mu}}_c = \alpha_c\,\boldsymbol{\mu}_c^{\text{data}} + (1-\alpha_c)\,\boldsymbol{\mu}_c^{\text{UBM}}, \qquad \alpha_c = \frac{n_c}{n_c + r}, \quad n_c = \sum_t \gamma_{tc} \tag{13-3}$$

UBM-MAP 自适应：先用大量不同说话人的数据训一个通用背景模型（描述「人类语音的通用分布」），再用目标说话人的少量数据把 UBM 的均值往数据方向拉。r 是相关性因子（常取 16）：某高斯分到的帧数 n_c 少 → α_c 小 → 更信任 UBM；数据多才敢偏离。这解决了「每个说话人只有几秒数据、训不出 2048 个高斯」的根本困难，是 GMM-UBM 时代的基石。

`α` 的含意很直观：该高斯分到的数据多（n_c 大），就更相信自己的数据；数据少就更多依赖 UBM。这样既不用从零学几十万参数，又能体现个体差异。

韩书 7.2.2 的实测结论 MAP 自适应时，只更新均值（不更新方差和权重）性能最好。原因：均值携带的身份信息最多，而方差在小样本下估计不稳，硬更新反而引入噪声。这条结论至今仍在很多工程实现里沿用。

④ 从超矢量到 i-vector：一次降维

把每个高斯（C = 512）的均值拼起来，得到一个 $512 \times 39 = 19968$ 维的"超矢量"。维度太高、且大部分变化是信道造成的。i-vector 用一个低秩假设把它压下来：

$$\mathbf{M} = \mathbf{m} + T\mathbf{w}, \qquad \mathbf{w} \sim \mathcal{N}(\mathbf{0}, I), \quad \mathbf{w} = (I + T^{\mathsf{T}}\Sigma^{-1}T)^{-1}T^{\mathsf{T}}\Sigma^{-1}(\mathbf{M}-\mathbf{m}) \tag{13-4}$$

$\mathbf{M}$：说话人的超矢量（把 UBM 所有高斯均值拼起来，$2048 \times 39 \approx 19968$ 维）；$\mathbf{m}$：UBM 的超矢量（所有人共用）；T：总变化空间矩阵（约 19968×400），从大量数据学出；$\mathbf{w}$：**i-vector**（400 维），即新的说话人表示。后验均值那一步是贝叶斯线性高斯模型的闭式解（400×400 求逆，与超矢量维度无关，所以很快）。i-vector 同时包含身份与信道信息，打分前要用 LDA/WCCN 去信道、再用 PLDA 或余弦打分。

直观理解：假设"说话人差异 + 信道差异"这些变化虽然维度高，但其实只在一个 400 维的子空间里发生。于是不管什么原因导致的差异，都被压进同一个 400 维向量 `w` 里——所以叫"总变化空间"（total variability）。

⑤ PLDA：把 i-vector 里的"身份"和"信道"分开

i-vector 里混着身份和信道。PLDA（概率线性判别分析）用生成模型把它们拆开：

$$\mathbf{w} = \boldsymbol{\mu} + V\mathbf{y} + U\mathbf{x} + \boldsymbol{\varepsilon} \tag{13-5}$$

这是 JFA（联合因子分析）的分解，也是 i-vector 的思想来源：$\mathbf{y}$ 是身份因子（同一人所有录音共享），$\mathbf{x}$ 是信道因子（同一段录音内共享），V, U 是对应子空间，$\boldsymbol{\varepsilon}$ 是残差。i-vector 的简化在于：不再区分 V, U，用一个总变化空间 T 把两者一起建模，再用 LDA/PLDA 在后端把信道抹掉。「先都装进来，再在打分时消掉」是这一代方法的核心思路。

于是"两段语音是否同一人"变成一个似然比检验：共享同一个 **y** 的假设 **vs** 不共享的假设。这个框架在小样本下比直接算余弦距离稳定得多。

⑥ 方法演进与代表性能

表 13-1　声纹方法的演进与代表性能

阶段	方法	核心思想	典型 EER（历史文献）
1990s–2000s	GMM-UBM	UBM + MAP 自适应，似然比打分	约 5–10%
2000s 中	SVM + GMM 超矢量	把超矢量当特征，用判别式分类	约 3–5%
2010s	i-vector + PLDA	低秩总变化空间 + 概率判别	约 1–3%
2014 以后	x-vector（DNN）	端到端学 embedding	约 0.5–2%

要注意这张表的数字只能看趋势，不能横向比较：不同年份、不同数据集（NIST SRE 各年份条件差异很大）、不同时长条件下的结果不可直接比。这个道理和第 15 讲要讲的"综述里的 99% 不能横比"是同一件事。

在设备声纹里，这条演进路线被大幅简化了——因为类别少（几种工况）、样本少，往往直接用 MFCC 统计量 + SVM/随机森林就够了。文献中也有走"物理先验特征 + 时序模型"路线的：刘云鹏 2020 用 50 Hz 倍频倒谱系数配合 GRU 识别直流偏磁，就是把"偏磁产生倍频"这一物理知识直接做进特征，比硬套通用框架更有效。

推导详解 • 第 13 讲　GMM–EM、MAP 自适应与 i-vector

1. EM 算法从 ELBO 推出来（不跳步）

目标是最大化对数似然 $\ln p(X\mid\lambda)=\ln\sum_{\mathbf{z}}p(X,\mathbf{z}\mid\lambda)$，$\mathbf{z}$ 是「每帧属于哪个高斯」的隐变量。引入任意分布 $q(\mathbf{z})$，由 Jensen 不等式：

$$\ln p(X\mid\lambda)=\ln\sum_{\mathbf{z}}q(\mathbf{z})\frac{p(X,\mathbf{z}\mid\lambda)}{q(\mathbf{z})}\geq\sum_{\mathbf{z}}q(\mathbf{z})\ln\frac{p(X,\mathbf{z}\mid\lambda)}{q(\mathbf{z})}\equiv\mathrm{ELBO}(q,\lambda)\tag{13-8}$$

两者之差恰是 $\mathrm{KL}\big(q(\mathbf{z})\,\|\,p(\mathbf{z}\mid X,\lambda)\big)\geq 0$。于是 EM 交替做两件事：

$$\begin{aligned}&\text{E 步：}\quad q\leftarrow p(\mathbf{z}\mid X,\lambda^{\mathrm{old}})\ \Rightarrow\ \mathrm{KL}=0,\ \text{ELBO 紧贴似然}\\&\text{M 步：}\quad \lambda\leftarrow\arg\max_{\lambda}\mathrm{ELBO}(q,\lambda)=\arg\max_{\lambda}\sum_{\mathbf{z}}q(\mathbf{z})\ln p(X,\mathbf{z}\mid\lambda)\end{aligned}\tag{13-9}$$

E 步算出的 $q(z_t=c)$ 就是式 (13-2) 的责任度 γ_{tc}（贝叶斯公式展开即得）。M 步在 q 固定下是带权极大似然：对 $\boldsymbol{\mu}_c$ 求偏导

$$\frac{\partial}{\partial\boldsymbol{\mu}_c}\sum_{t,c}\gamma_{tc}\Big[-\tfrac{1}{2}(\mathbf{x}_t-\boldsymbol{\mu}_c)^{\mathsf T}\Sigma_c^{-1}(\mathbf{x}_t-\boldsymbol{\mu}_c)\Big]=0\ \Longrightarrow\ \boldsymbol{\mu}_c=\frac{\sum_t\gamma_{tc}\mathbf{x}_t}{\sum_t\gamma_{tc}}\tag{13-10}$$

同理得 Σ_c 与 π_c（π_c 需加 $\sum_c\pi_c=1$ 约束，用拉格朗日乘子）。每轮「E 使下界贴合、M 使下界上升」，保证 $\ln p(X\mid\lambda)$ 单调不降。

实现必须在对数域：$\ln\big[\pi_c\mathcal{N}(\mathbf{x}_t\mid\cdot)\big]=\ln\pi_c-\frac{1}{2}\big[d\ln 2\pi+\ln|\Sigma_c|+(\mathbf{x}_t-\boldsymbol{\mu}_c)^{\mathsf T}\Sigma_c^{-1}(\mathbf{x}_t-\boldsymbol{\mu}_c)\big]$，再用 log-sum-exp 归一化 $\ln\gamma_{tc}=\ell_{tc}-\ln\sum_j e^{\ell_{tj}}$，其中 $\ln\sum_j e^{\ell_j}=m+\ln\sum_j e^{\ell_j-m}$、$m=\max_j\ell_j$。不这么做，39 维 × 512 高斯的密度连乘会直接下溢为 0。

2. UBM–MAP：为什么 $\alpha_c=n_c/(n_c+r)$

把 UBM 均值当作先验：$\boldsymbol{\mu}_c\sim\mathcal{N}(\boldsymbol{\mu}_c^{\mathrm{UBM}},\,\Sigma_c/r)$。观测到 $n_c=\sum_t\gamma_{tc}$ 帧、样本均值 $\boldsymbol{\mu}_c^{\mathrm{data}}$，其似然为 $\mathcal{N}(\boldsymbol{\mu}_c^{\mathrm{data}}\mid\boldsymbol{\mu}_c,\Sigma_c/n_c)$。高斯先验 × 高斯似然后验均值是精度加权平均：

$$\hat{\boldsymbol{\mu}}_c = \frac{(r/\Sigma_c)\boldsymbol{\mu}_c^{\text{UBM}} + (n_c/\Sigma_c)\boldsymbol{\mu}_c^{\text{data}}}{r/\Sigma_c + n_c/\Sigma_c} = \frac{n_c}{n_c + r}\boldsymbol{\mu}_c^{\text{data}} + \frac{r}{n_c + r}\boldsymbol{\mu}_c^{\text{UBM}} \tag{13-11}$$

正是式 (13-4)。r 是先验的「等效帧数」：数据少时先验占主导，数据多时才信任数据。 这一步把「每个说话人几秒数据」与「2048 个高斯」的矛盾化解掉，是 GMM-UBM 能实用的关键。

3. i-vector 后验均值公式的来历

模型 $\mathbf{M} = \mathbf{m} + T\mathbf{w} + \boldsymbol{\varepsilon}$，$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, I)$、$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \Sigma)$。由线性高斯模型，后验 $\mathbf{w} \mid \mathbf{M}$ 仍是高斯，其精度矩阵与均值为

$$\begin{aligned} \operatorname{Cov}(\mathbf{w} \mid \mathbf{M}) &= \left(I + T^{\mathsf{T}}\Sigma^{-1}T\right)^{-1} \\ \mathbb{E}[\mathbf{w} \mid \mathbf{M}] &= \left(I + T^{\mathsf{T}}\Sigma^{-1}T\right)^{-1} T^{\mathsf{T}}\Sigma^{-1}(\mathbf{M} - \mathbf{m}) \end{aligned} \tag{13-12}$$

矩阵求逆的维度是总变化空间维度（400×400），与超矢量的 **19968** 维无关，所以每条语音提 i-vector 很快。 Σ 由 UBM 的零阶/一阶 Baum–Welch 统计量按高斯块拼成分块对角阵，这是实现里最繁琐但最关键的一步。

4. PLDA 打分：把「像不像」变成似然比

对两条语音的 i-vector 建模（$\mathbf{w} = \boldsymbol{\mu} + V\mathbf{y} + \boldsymbol{\varepsilon}$，$\mathbf{y}$ 身份隐变量、$\boldsymbol{\varepsilon}$ 会话噪声），打分是

$$s(\mathbf{w}_1, \mathbf{w}_2) = \ln \frac{p(\mathbf{w}_1, \mathbf{w}_2 \mid \text{同一人})}{p(\mathbf{w}_1 \mid H_{\text{ind}})\, p(\mathbf{w}_2 \mid H_{\text{ind}})} \tag{13-13}$$

两个高斯模型都有闭式协方差，代入即可算。PLDA 相比余弦相似度的优势是显式建模了「同一人不同录音」的方差， 能自动给受信道影响大的维度降权，因此在 SRE 任务上长期优于余弦。

5. 三条技术路线的对照

方法	说话人表示	打分	少样本注册	主要弱点
GMM-UBM	自适应后的 2048 高斯	对数似然比	尚可（MAP）	维度高、信道敏感
i-vector + PLDA	400 维低秩向量	PLDA 似然比	好	线性高斯假设
x-vector + PLDA	512 维 DNN embedding	PLDA / 余弦	很好	需大量训练数据

6. 边界与失效条件

- GMM 用全协方差时参数量 $\sim Cd^2/2$，几秒数据必然奇异；对角协方差是必需而非简化。
- EM 只保证收敛到局部极大，k-means 初始化与多次重启影响明显。
- i-vector 的 T 必须在与测试同域的大规模数据上训练；跨域（录音设备不同）时性能下降明显，需要域适配。

误区与注意事项

误区 ① 以为 **GMM** 的 **C** 越大越好。数据不够时高斯越多越容易过拟合，UBM 常用 512–2048 是数据量决定的。② **i-vector** 维度越高越好。400 维是经验值，太高会引入信道噪声。③ 跳过 **UBM** 直接训每人一个 **GMM**。小样本必崩。④ 拿不同年份的 **EER** 直接比。数据集条件不同。

自检

- [ ] 我能写出 GMM 的混合密度公式，并解释为什么需要多个高斯。
- [ ] 我能说出 EM 的 E 步和 M 步分别在算什么。
- [ ] 我能解释 UBM-MAP 的 α 系数含义，以及为什么只更新均值最好。
- [ ] 我能写出 $\mathbf{M} = \mathbf{m} + \boldsymbol{T}\mathbf{w}$ 并说出 19968 → 400 维的意义。

第 14 讲

深度学习声纹：x-vector 与损失函数

目标

- 理解 x-vector 的核心创新是"统计池化"，它解决了变长序列问题。
- 知道 softmax、AAM-softmax、triplet 三种损失分别在追求什么。
- 能读懂近年变压器声纹文献的做法，并判断其结论的适用范围。

产出

- 能画出 TDNN + 统计池化 + embedding 的结构图。
- 能从一篇声纹论文里抽出"特征 / 模型 / 数据 / 指标"四要素。

① 从 i-vector 到 x-vector：换个方式得到定长向量

i-vector 的思路是"用 GMM 超矢量 + 低秩投影"，需要先训 UBM、再算 Baum-Welch 统计量，流程长且对不上齐。x-vector 直接把这件事交给神经网络：用 TDNN 逐帧提特征，再用统计池化把变长序列压成定长向量。

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t, \qquad \boldsymbol{\sigma} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(\mathbf{h}_t - \boldsymbol{\mu})^2}, \qquad \mathbf{e} = [\boldsymbol{\mu};\, \boldsymbol{\sigma}] \tag{14-1}$$

输入是 MFCC（T 帧 × 39 维），T 不固定。TDNN 前几层逐帧变换并利用上下文（类似一维卷积、跨层连接）得到 $\mathbf{h}_t$；统计池化把任意长度 T 压成固定长度的 $\mathbf{e}$（$2\times$隐层维），这是整条流水线能处理变长语音的关键。标准差项不是装饰：它携带了「帧间离散程度」信息，实测比只用均值明显更好。之后接全连接 → 512 维 embedding → softmax 分类。

为什么是"均值+标准差"而不是只取最后一帧？因为语音是变长的，只取最后一帧会丢掉其他时刻的信息；而均值和标准差是对时间顺序不敏感、但对内容敏感的统计量，正好把"这个人说话的总体倾向"压进去。

② 三种损失函数

表 14-1　三种损失函数的对比

损失	公式要点	在追求什么	局限
softmax	L = −log(e^(z_y) / Σ_j e^(z_j))	把类别分开	只要求"可分"，不要求类内紧凑
AAM-softmax	cos(θ+m) 代替 cos(θ)，再乘尺度 s	类内更紧、类间更开（加角度 margin）	margin 需调，训练更慢
triplet	max(0, d(a,p) − d(a,n) + m)	直接优化"同类近、异类远"	三元组采样策略影响很大

AAM-softmax 的关键在于：普通 softmax 只要"正确类得分最高"就满意了，哪怕只高一点点。加 **margin** 后，正确类必须比第二名高出 **cos** 意义上的 **m** 弧度才算过关，于是模型被迫把同一类的样本压得更紧。这对"开集"场景（测试时出现训练时没见过的人）特别重要——因为此时你要比的不是分类对不对，而是 embedding 之间的距离。

③ 两种使用范式

$$\text{A:}\quad \hat{c}=\arg\max_{c} p_c, \qquad \text{B:}\quad s=\cos(\mathbf{e}_1,\mathbf{e}_2)=\frac{\mathbf{e}_1^{\mathsf{T}}\mathbf{e}_2}{\|\mathbf{e}_1\|\,\|\mathbf{e}_2\|},\ s>\theta? \tag{14-2}$$

范式 **A**（分类）：softmax 输出固定类别，适合「几种已知工况」；范式 **B**（度量）：训练 embedding，测试时算余弦/PLDA 分数再比阈值，适合「类别会变」（新用户注册、未知故障），也是声纹确认的标准做法。训练 B 常用 AAM-Softmax：$L=-\log\dfrac{e^{s(\cos(\theta_y+m)-\cdots)}}{\cdots}$，在角度上加 margin m 迫使同类更紧、异类更开。

设备声纹大多用范式 A（工况种类固定），人的声纹大多用范式 B（要支持随时新增用户）。这个区别决定了你该用哪种损失：范式 **A** 用 **softmax** 就够，范式 **B** 才需要 **AAM-softmax / triplet**。

手写 BPNN vs 手写 CNN（同一批 6 类声纹）

模型	测试准确率	宏平均 F1	宏平均 AUC	参数量	训练耗时	最终验证准确率
BPNN	1.0000	1.0000	1.0000	2694	0.2s	1.0000
CNN	0.9792	0.9791	1.0000	6190	17.2s	0.9375

图 14-1　手写 BPNN 与 CNN 在同一批 6 类合成声纹上的对比：BPNN 参数量 2694、CNN 6190，测试准确率 1.000 与 0.979。参数少反而更准，说明在这个数据规模下模型复杂度不是瓶颈

④ 近年变压器/设备声纹文献的做法

下表只收录本讲义实际查阅过的文献，数字为其原文自报结果：

表 14-2　近年变压器与设备声纹文献的做法与结果

文献	特征	模型	数据/对象	原文自报结果
张重远 2020	Mel 时频谱（降维）	CNN	铁芯模型试验台，3 种工况	识别率 99.71%
刘云鹏 2020	50 Hz 倍频倒谱系数	GRU	变压器直流偏磁	偏磁声纹识别（时序建模）
陆云才 2023	时域+频域多通道混合特征	CNN + 集成学习	自建变压器声纹样本库	单一缺陷 99.2%、混合缺陷 99.7%
李楠 2023	小波声纹特征图谱（4 传感器融合，熵权法加权）	ShuffleNetV2	铁芯松动 25/50/75/100%	平均准确率 99.6%；比 FFT/GAF/MTF/RP 高 12.2%，比单传感器高 5.8%
李嘉宁 2025	可学习 Gabor 卷积替代 MFCC 前端	改进 Transformer（多头+时频注意力）	GIS 操作机构，含噪	高信噪比 96%；10 dB 时提升 >9.4%
齐子豪 2025	多粒度知识特征	Transformer	变压器故障声纹	故障声纹辨识

⑤ 从这些工作里能提炼的五条经验

经验 **1**：特征侧往往比模型侧更有效。张重远用 Mel 谱+CNN 就到 99.71%，刘云鹏用"50 Hz 倍频"这个物理先验特征也能解决问题——都不是靠更深的网络。设备声纹的样本量通常只有几百到几千条，堆模型收益有

限。

经验 **2**：多传感器融合是稳定增益。李楠 2023 用 4 个传感器、熵权法加权融合图谱，比单传感器高 5.8%。原因很直白：单点测声受驻波和方向性影响，多点能平均掉这些偶然因素。

经验 **3**：噪声是主要敌人，且必须单独报告。李嘉宁 2025 特意报告"10 dB 时提升 9.4%"，而不是只报高信噪比的 96%。这正是第 10 讲强调的"鲁棒性曲线"思路。

经验 **4**：前端可以学。李嘉宁用"可学习参数的 Gabor 卷积"替代固定的 MFCC 前端，本质是让网络自己决定滤波器形状——这是 MFCC 之后的一个重要演进方向，也解释了为什么"MFCC 不一定最优"。

经验 **5**：所有 **99%** 都不能横向比较。张重远的 99.71%（3 类、试验台）、陆云才的 99.2%/99.7%（自建库）、李楠的 99.6%（4 级松动程度）——类别数、数据来源、划分方式都不同。把它们排成排行榜是错的，只能看"各自解决了什么问题"。

推导详解 · 第 14 讲　统计池化与 margin 损失

1. 为什么统计池化能处理变长输入

设帧级输出 $\mathbf{h}_t \in \mathbb{R}^D$，$t = 1..T$，$T$ 随语音长度变化。统计池化

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t}\mathbf{h}_t, \qquad \boldsymbol{\sigma}^2 = \frac{1}{T}\sum_{t}(\mathbf{h}_t - \boldsymbol{\mu})^2, \qquad \mathbf{e} = [\boldsymbol{\mu};\boldsymbol{\sigma}] \in \mathbb{R}^{2D} \tag{14-1}$$

把「集合」映射成固定维数的一、二阶矩，因此后续全连接层的输入维度与 T 无关。 从概率角度看，这是假设各帧独立同分布于某高斯、用充分统计量近似它；标准差项补充了「分散程度」， 实测比只用均值提升明显（x-vector 论文的关键设计之一）。

注意池化对 T 的偏置：短语音的 $\boldsymbol{\sigma}$ 估计方差大，长语音更稳， 所以训练时要做长度均衡（按时长分桶、或随机裁剪到固定长度），否则模型会学到「时长」而非身份。

2. TDNN 与带上下文的逐帧变换

$$\mathbf{h}_t = f\left(W\left[\mathbf{x}_{t-\tau_1};\mathbf{x}_t;\mathbf{x}_{t+\tau_2}\right] + \mathbf{b}\right), \qquad \text{x-vector: } \tau \in \{-2,-1,0,1,2\} \text{ 的扩张卷积} \tag{14-2}$$

与 CNN 的差别是每个时间位置看的是「拼接的上下文帧」而非二维邻域， 且高层用扩张（**dilated**）卷积跳着取样：第 1 层看 ± 1 帧、第 2 层看 ± 2、第 3 层看 ± 3， 三层就覆盖 15 帧上下文而不增加参数。按 10 ms 帧移算约 150 ms，足以覆盖一个音节。

3. AAM-Softmax：margin 加在哪里

普通 softmax 只要求正确类分数最大，类内可以很松。把权重与特征都做长度归一化并令 $\mathbf{w}_c^{\top}\mathbf{e} = \cos\theta_c$，加性角度间隔损失为

$$L = -\ln \frac{e^{s\cos(\theta_y + m)}}{e^{s\cos(\theta_y + m)} + \sum_{c \neq y} e^{s\cos\theta_c}} \tag{14-3}$$

它强迫正确类的角度比原来再小 m（常用 $m = 0.2$ rad），等价于在球面上把类间拉开、类内压紧。 s 是尺度因子（常取 30），因为归一化后 $\cos\theta \in [-1,1]$，不放大则 softmax 太「软」、梯度太小。 训练完成后丢掉分类层，取倒数第二层的 $\mathbf{e}$ 作为 embedding，即可用于开集声纹确认。

4. embedding 打分的两种后端

$$s_{\cos} = \frac{\mathbf{e}_1^{\mathsf{T}}\mathbf{e}_2}{\|\mathbf{e}_1\|\|\mathbf{e}_2\|}, \qquad s_{\mathrm{PLDA}} = \ln \frac{p(\mathbf{e}_1, \mathbf{e}_2 \mid H_1)}{p(\mathbf{e}_1 \mid H_0)p(\mathbf{e}_2 \mid H_0)} \tag{14-4}$$

余弦简单、无需训练、适合数据量少；PLDA 需要一批开发数据估计类内/类间协方差，但能按维度加权， 在信道变化大时更稳。工程上常先做长度归一化 + LDA 降维去信道，再算余弦或 PLDA。

5. 与「手工特征」路线的对比账

环节	手工路线（第 6–10 讲）	x-vector 路线
特征	MFCC + Δ + ΔΔ（39 维，人工设计）	原始 MFCC / 频谱，逐帧由网络学变换
变长聚合	全局均值 / 统计量（人工）	统计池化（可学，且保留标准差）
说话人表示	GMM 超矢量 / i-vector	512 维 embedding
打分	对数似然比 / PLDA	余弦 / PLDA

两条路线的后半段其实一样（都要定长向量 + 似然比/相似度 + 阈值）， 差别在于「前面那段变换是人工设计还是学出来的」。理解这点，第 12 讲的评价体系就能无缝迁移到深度模型。

6. 边界与失效条件

- 训练类别数太少时 margin softmax 的类间结构学不充分，embedding 泛化差；这类方法依赖成千上万个说话人。
- 短语音（<2 s）时统计池化的二阶矩不可靠，性能明显下滑；可用注意力池化（给帧加权）缓解。
- 域不匹配（训练用 16 kHz 电话语音、测试用 8 kHz 设备声）影响远大于模型结构差异，优先做数据/前端对齐。

误区与注意事项

误区 ① 以为统计池化只是"求平均"。标准差那一半同样重要，它携带"波动程度"信息。② 在闭集任务上用 **triplet** 损失。没必要，softmax 更快更好。③ 照抄论文的超参数。数据规模差一个数量级，学习率、层数都要重调。④ 把不同论文的准确率排榜。数据集条件不同，比较无意义。

自检

- [ ] 我能写出统计池化的均值+标准差公式，并解释它为什么能处理变长输入。
- [ ] 我能说清 AAM-softmax 相比 softmax 多了什么约束、为什么开集场景需要它。
- [ ] 我能说出至少三条从文献里提炼的工程经验。
- [ ] 我知道为什么这些论文的 99% 不能横向比较。

专 题 A

变压器声纹：从物理机理到故障诊断

目标

- 能推出「正常变压器为什么是 100 Hz 基频」，并说清各类缺陷怎样改变频谱。
- 掌握现场抗噪的三条路线（小波阈值 / 谱减法 / FastICA）及各自的适用边界。
- 理解小波包能量谱与 TFCC 为什么比照搬语音的 MFCC 更贴合设备声纹。
- 能读懂多通道 CNN + 集成学习的诊断流水线，并复述其中的维度账与实测结果。

产出

- 一张「缺陷 → 物理机制 → 频域表现」对照表；一份可自己跑的去噪对比实验；一段能解释 (8, 96000) 输入怎么来的维度推导。

关于本专题的数字 下面标了出处的准确率（92.0% / 98.7% / 99.2% / 99.7% / 99.65% / 99.4% 等）来自上述两篇文献的自建样本库，样本数、采样率、噪声条件都和本讲义 `acoustic-lab` 的 8 kHz 合成数据不同，不能当成本项目的实测结果。讲义引用它们是为了说明「每一步改动带来了多少收益」以及「哪一步最容易翻车」，不是给自己的系统背书。

A.1 声音从哪来：先推出 100 Hz

变压器本体噪声不是「随机嗡嗡声」，而是有严格频率结构的确定性振动。主要来源是铁芯磁致伸缩：硅钢片在交变磁场中被周期性拉伸/压缩。关键在于磁致伸缩应变与磁感应强度的平方成正比，而电网工频是 50 Hz：

$$\varepsilon(t) \propto B^2(t) = B_m^2 \sin^2(2\pi \cdot 50\, t) = \frac{B_m^2}{2}\left[1 - \cos\left(2\pi \cdot 100\, t\right)\right] \tag{A-1}$$

用 $\sin^2\theta = \frac{1-\cos 2\theta}{2}$ 把平方展开，频率直接翻倍：50 Hz → **100 Hz**。绕组受到的洛伦兹力 $F = BIL \propto i^2$ 同理也含 $2f$ 分量。所以正常声纹是一组以 100 Hz 为基频的谐波串：100 / 200 / 300 / 400 Hz……这正是第 1 讲「谐波叠加」的物理实例。

非线性（磁化曲线弯曲、铁芯饱和）会让 $B(t)$ 不再是纯正弦，于是平方后除了 $2f$ 还会长出 $4f, 6f, \ldots$ 等高次谐波；一旦直流偏磁让工作点偏移、正负半周不对称，还会出现 50 Hz 的奇次倍频 150 / 250 / 350 Hz——本讲义合成数据里「直流偏磁」类正是这么造的（第 1 讲式 1-3、第 6 讲误区）。

状态 / 缺陷	物理机制	频域表现	时域表现
正常运行	磁致伸缩 + 绕组电动力，$\propto B^2$	100 Hz 基频 + 偶次谐波，谱线稳定	近似周期、幅值平稳
直流偏磁	铁芯半周饱和、正负不对称	新增 150 / 250 / 350 Hz（50 Hz 奇次倍频）	波形上下不对称
铁芯 / 夹件松动	固有模态被电磁力激发、约束变松	谐波比例改变，出现新的窄带峰与宽带底噪	周期性变差，幅值调制
绕组短路冲击	瞬态电动力冲击、结构位移	宽频能量突然抬升，随后衰减	短促强脉冲，非平稳

状态 / 缺陷	物理机制	频域表现	时域表现
局部放电（沿面/电晕/悬浮/间歇）	绝缘击穿产生压力脉冲	能量偏向高频（数 kHz 以上），基频区几乎不变	稀疏尖峰、重复率随类型变化
重过载	电流增大、磁通与振动增强	100 Hz 幅值显著上升，谐波相对比例变化	整体幅值变大、波形仍周期
油泵 / 风扇异响、冷却器	机械转动与叶片通过频率	固定低频线谱 + 与其谐波，常叠加宽带风噪	持续、准平稳

> **和第 6 讲接上了** 这张表解释了讲义反复强调的一句话：设备声纹的判别信息集中在 **100–500 Hz**。而 MFCC 的 Mel 滤波器组把这一段只分到 2–3 个通道，高频却分得很宽——所以照搬语音配置会丢掉主要信息。陆云才等（2023）也明确指出「梅尔频谱主要用于人声识别，和变压器这一场景并不完全相符，不利于提取变压器基频和高次倍频的信号特征」。

A.2 现场为什么必须先去噪

实验室里的合成信号干净，现场不是。陆云才等构建的声纹样本库共 **19** 类：4 类正常主变噪声（110 / 220 / 500 / ±800 kV，各 960 段）、5 种环境噪声（变电站噪声叠加雷声 / 鸟鸣 / 汽笛 / 人声 / 雨声，各 192 段）、10 类异常（短路冲击 160、沿面放电 150、电晕放电 150、间歇性放电 140、悬浮放电 150、重过载 300、直流偏磁 150、夹件松动 100、油泵异响 150、风扇异响 150 段）。采集条件是 **10 s**、**48 kHz**。

为什么现场用 48 kHz、而本讲义用 8 kHz？局放脉冲的高频分量在数 kHz 以上，8 kHz 采样的奈奎斯特上限只有 4000 Hz（第 2 讲式 2-2），会把最关键的放电特征直接混叠掉；48 kHz 则留出充分余量。采样率是任务定义的，不是随便选的——这句话在第 2 讲说过，这里有了工程上的代价演示。

朱柯佳（2021）把现场干扰分成三类，并实测出输入 SNR 常在 $[-5,\ 5]$ dB：

干扰类型	例子	特点	最合适的去噪法
瞬时强干扰	雷声、汽笛、人声	短时、能量高、非平稳	小波阈值 / FastICA
持续弱干扰	风机声、雨声	长时间、准平稳、与本体频段重叠	谱减法（但失真大）
混合噪声	上述叠加	频谱结构复杂	小波阈值（对不同噪声最稳）

论文结论值得原样记住：小波阈值法对不同噪声类型的效果差别不大，但受输入 **SNR** 影响较大；**FastICA** 更适合瞬时干扰与混合噪声、处理持续弱干扰效果不佳；谱减法更适合持续弱干扰，但三种方法里它的信号失真度最高；三者中小波阈值法略优于 **FastICA**。不存在「一种去噪打天下」。

A.3 去噪三法，逐个推到底

A.3.1 小波阈值去噪

观测模型 $y[n] = x[n] + d[n]$。正交小波变换 W 是线性的，所以 $Wy = Wx + Wd$：有用信号的能量集中在少数大系数上，白噪声能量则摊平在所有系数上。于是去噪三步：分解 → 对细节系数阈值量化 → 逆变换重构。两种经典阈值函数：

$$\eta_{\text{hard}}(w)=\begin{cases} w, & |w|>\lambda \\ 0, & |w|\le\lambda \end{cases} \qquad \eta_{\text{soft}}(w)=\operatorname{sgn}(w)\big(|w|-\lambda\big)_+ \tag{A-2}$$

硬阈值在 $w=\pm\lambda$ 处不连续，重构时容易产生振荡（吉布斯样伪影）；软阈值连续、重构平滑，但对所有保留系数都减去 λ，产生恒定偏差，幅值被系统性压低——论文原话是「会使得部分有效声音信号特征丢失」。

折中方案是半软阈值（**firm shrinkage**）：用两个阈值 $\lambda_1\le\lambda_2$，中间线性过渡，两端分别恒为 0 与恒等：

$$\eta_{\text{firm}}(w)=\begin{cases} 0, & |w|\le\lambda_1 \\ \operatorname{sgn}(w)\,\dfrac{\lambda_2\big(|w|-\lambda_1\big)}{\lambda_2-\lambda_1}, & \lambda_1<|w|<\lambda_2 \\ w, & |w|\ge\lambda_2 \end{cases} \tag{A-3}$$

取 $\lambda_1=\lambda_2$ 退化为硬阈值，取 $\lambda_2\to\infty$ 退化为软阈值。朱柯佳论文的「改进阈值函数」思路与此一致：调整 $\pm\lambda$ 附近及区间内的函数形状，既连续又不留恒定偏差。这里给出的是该家族的标准形式，便于自己实现；论文中具体的分段系数以原图为准。

阈值怎么定：Donoho–Johnstone 通用阈值（VisuShrink）用 $\lambda=\sigma\sqrt{2\ln N}$，其中噪声标准差由最细层细节系数的绝对中位差稳健估计 $\hat\sigma=\mathrm{MAD}/0.6745$。Stein 无偏风险估计（SURE / rigrsure）则在低 SNR 时更省；启发式阈值（heursure）按输入 SNR 在两者间选：

$$\lambda=\sigma\sqrt{2\ln N},\qquad \hat\sigma=\frac{\operatorname{median}\left(|cD_1|\right)}{0.6745},\qquad \lambda_j=\hat\sigma_j\sqrt{2\ln N_j}\ \ (j=1,\dots,J) \tag{A-4}$$

最后一式是分层阈值：不同分解层的噪声能量不同，每层用自己的 $\hat\sigma_j$ 算一个 λ_j，传进去的是一个数组而不是单一数值。这正是朱柯佳论文的第二处改进；配合 A-3 的改进阈值函数，实测输出 SNR 提高约 **1 dB**，整体去噪性能提升 **8–9%**，RMSE 与 LSD 都更小、波动也更小。

A.3.2 谱减法

假设噪声加性且短时平稳，先从前导静音段估出噪声谱 $\hat N[k]$，再从带噪谱里减掉：

$$|\hat X[k]|^2=|Y[k]|^2-\alpha\,\big|\hat N[k]\big|^2,\qquad |\hat X[k]|=\max\Big(|Y[k]|-\alpha\,|\hat N[k]|,\ \beta\,|Y[k]|\Big) \tag{A-5}$$

$\alpha\ge1$ 是过减因子（噪声估计偏低时补偿），$\beta|Y[k]|$ 是谱下限（防止减出负值导致相位翻转般的失真）。减完仍用带噪信号的相位 $\angle Y[k]$ 做逆变换，因为人耳/后续特征对相位不敏感（第 1 讲式 1-6）。

音乐噪声是谱减法的固有副作用：随机频点上被减成孤立尖峰，逆变换后听感像断续的音调。缓解办法是过减 + 谱下限、对噪声谱做时间平滑、以及多帧最小值跟踪。论文里谱减法失真度始终偏高，正与此有关。

A.3.3 FastICA（盲源分离）

把多通道观测写成 $\mathbf{y}=A\mathbf{s}$，目标是在只知道 $\mathbf{y}$ 的情况下找 $W\approx A^{-1}$ 使 $\mathbf{u}=W\mathbf{y}$ 的各分量尽量统计独立（非高斯性最大）。FastICA 用负熵近似做固定点迭代：

$$\mathbf{w}^{+} \propto \mathbb{E}\big[\mathbf{z}\, g(\mathbf{w}^{\mathsf{T}}\mathbf{z})\big] - \mathbb{E}\big[g'(\mathbf{w}^{\mathsf{T}}\mathbf{z})\big]\,\mathbf{w}, \qquad g(u) = \tanh(u) \text{ or } u^3 \tag{A-6}$$

$\mathbf{z}$ 是白化后的观测。每轮更新后做对称正交化 $W \leftarrow (WW^{\mathsf{T}})^{-1/2}W$，防止不同分量收敛到同一个源。它要求源之间相互独立且最多一个高斯源——持续弱干扰（风机、雨声）与本体振动在频带上长期重叠、统计上难以分离，这就是论文里 FastICA 对这类噪声效果不佳的原因。

A.3.4 三个评价指标，别只看 SNR

$$\begin{aligned} \mathrm{SNR}_{\text{out}} &= 10\log_{10}\frac{\sum_n x^2[n]}{\sum_n \big(\hat{x}[n]-x[n]\big)^2}, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_n \big(\hat{x}[n]-x[n]\big)^2} \\ \mathrm{LSD} &= \frac{1}{M}\sum_{m=1}^{M}\sqrt{\frac{1}{K}\sum_{k=1}^{K}\Big[20\log_{10}\big|X_m[k]\big| - 20\log_{10}\big|\hat{X}_m[k]\big|\Big]^2} \end{aligned} \tag{A-7}$$

SNR / RMSE 看时域波形误差，**LSD**（对数谱距离）看频谱畸变——对声纹特征而言后者往往更关键：波形误差很小但某个谐波峰被削掉，特征照样崩。朱柯佳论文表 2-8 给出不同噪声类型下三法的 LSD 对比（如输入 SNR = −10 dB 的风机声：小波阈值 2.697、FastICA 2.695、谱减 2.803，数值越小越好），可以看到谱减法在各类噪声下都偏高。

A.4 特征：为什么不是 MFCC，而是小波包能量 + TFCC

A.4.1 小波包能量谱

第 7 讲的 DWT 每层只继续分解近似支路 cA，所以低频分辨率高、高频粗；小波包（**wavelet packet**）把近似和细节都继续分解，第 j 层得到 2^j 个等宽频带：

$$\Delta f_{\text{seg}} = \frac{F_s/2}{2^j}, \qquad x[n] = \sum_{m=0}^{2^j-1} s_{j,m}[n], \qquad E_{j,m} = \sum_n \big|s_{j,m}[n]\big|^2 \tag{A-8}$$

三层分解 → 8 个频段；五层 → 32 个频段（朱柯佳论文采用五层，得到 32 维小波包能量谱）。以 $F_s = 8\,\mathrm{kHz}$、$j = 5$ 为例，每段宽 $4000/32 = 125\,\mathrm{Hz}$——刚好能把 100 / 200 / 300 Hz 的谐波结构分开，又比逐根谱线稳健得多。论文的三步法：① 小波包分解 → ② 各频段重构信号并求总能量 → ③ 排成特征向量 $T = [E_{3,0}, \ldots, E_{3,7}]$。

通常再做归一化与能量熵，避免整体音量变化主导特征：

$$p_m = \frac{E_{j,m}}{\sum_{m'} E_{j,m'}}, \qquad H = -\sum_m p_m \log_2 p_m, \qquad 0 \le H \le j \tag{A-9}$$

能量集中在少数频带（稳态嗡鸣）→ H 小；能量摊平（局放宽带、强噪声）→ H 大。单这一个标量就能粗分「周期性故障」与「宽带放电」，但它丢掉了「能量落在哪一段」的信息，所以还要保留完整的 p_m 向量。

A.4.2 TFCC：把 Mel 滤波器组换成设备专用的

第 6 讲 MFCC 的流程是「功率谱 → Mel 三角滤波器组 → log → DCT」。TFCC（Transformer Sound Frequency Cepstrum Coefficients，变压器声音频率倒谱系数）保留这个骨架，只换掉频率轴的划分方式：既然判别信息在 100 Hz 基频及其低次谐波，就把滤波器中心对准谐波簇、在低频加密，而不是按人耳的 Mel 刻度。

$$E_m = \sum_k P[k]\, H_m^{\mathrm{TF}}[k], \qquad L_m = \ln(E_m + \varepsilon), \qquad c_i = \sqrt{\frac{2}{M}} \sum_{m=1}^{M} L_m \cos\left[\frac{\pi i}{M}\left(m - \frac{1}{2}\right)\right] \tag{A-10}$$

与第 6 讲式 6-5、6-7 的唯一差别是 H_m 换成 H_m^{TF}。朱柯佳论文用遍历法筛选关键系数，得到 **40** 维 TFCC，单独用于故障诊断的准确率 98.85%。关键洞察：**Mel** 刻度是给人耳设计的，不是给变压器设计的。陆云才等从另一条路得出同样结论，改用「时域 + 频域双通道」把原始频谱直接喂给网络。

A.4.3 特征选择：Laplacian 得分 + Fisher 得分

32 维小波包能量 + 40 维 TFCC = 72 维，其中大量冗余甚至噪声维度。两个互补的过滤式评分：

$$\begin{aligned} \text{Fisher:} \quad & S_r = \frac{\sum_c n_c (\mu_r^c - \mu_r)^2}{\sum_c n_c \left(\sigma_r^c\right)^2} \\ \text{Laplacian:} \quad & L_r = \frac{\sum_{i,j} \left(f_{r,i} - f_{r,j}\right)^2 S_{ij}}{\sum_{i,j} \left(f_{r,i} - f_{r,j}\right)^2 D_{ii}} \quad \left(D_{ii} = \sum_j S_{ij}\right) \end{aligned} \tag{A-11}$$

Fisher 看类间散度 / 类内散度，偏好「不同故障取值差得开、同一故障取值稳」的维度；Laplacian Score 用样本近邻图 S_{ij}（常用热核 $e^{-\|x_i - x_j\|^2/t}$）衡量该维度是否保持局部几何结构，方差小、得分低。两者一个看判别性、一个看结构保持，加权融合 $\text{score} = \alpha\, \tilde{S}_r + (1-\alpha)\, \tilde{L}_r$；论文实验取 $\alpha = 0.8$ 时故障诊断准确率最高。

融合选维后的小波包能量–**TFCC** 特征：维度比 72 低，准确率 **99.65%**（干净条件）与 **99.4%**（高噪声现场），且论文特别指出「变压器声音信号失真后对故障诊断准确率影响最小」——也就是抗噪鲁棒性比单纯的高准确率更有价值。

A.4.4 一个反直觉但很重要的实验结论

> **别把去噪当成免费午餐** 朱柯佳论文第 4 章发现：三种去噪方法都能降低噪声，但去噪后的信号都存在一定失真度；用「未去噪的本体声音信号」训练故障模型、用「去噪后的信号」去测试，反而比反过来更好；高噪声现场下，改进小波阈值去噪后的最高诊断准确率是 **95.1%**，而换用抗噪特征（小波包能量–TFCC）能做到 **99.4%**。结论：去噪主要服务于推理端，而「选对特征」带来的收益往往大于「把噪声削干净」。这和讲义第 10 讲「别一上来就调网络，先按层排查」是同一个思路。

A.5 诊断模型：多通道 CNN + 注意力 + 集成学习

A.5.1 输入怎么构造成 (8, 96000)

陆云才等没有用「一张梅尔频谱图当图片」的常见做法，理由有二：二维时频谱要很高分辨率、内存吃不消；而 Mel 频谱是为人声设计的，压缩频率轴后不利于保留变压器基频与高次倍频。他们改成时域 + 频域双通道，让网络同时看见稳态周期结构与暂态异常：

步骤	操作	维度账（文献设定：10 s @ 48 kHz）
①	对整段做 FFT 得频域信号；时域信号做均值方差归一化并抽稀到与频域等长	两路各 480000 点量级，抽稀后对齐
②	两路并联成双通道数据	$2 \times L$
③	4 s 窗、2 s 滑动步长切段	10 s 上得到 4 段（窗口重叠 50%）

步骤	操作	维度账（文献设定：10 s @ 48 kHz）
④	4 段 × 2 通道重新并联	**(8, 96000)**：$96000 = 2\,\mathrm{s} \times 48\,\mathrm{kHz}$，即抽稀到原采样率一半的长度

这里 96000 的具体换算属于按文献参数反推，实际以原论文的预处理实现为准；要学的是这套构造逻辑：用「通道」承载不同视图，用「时间窗 + 重叠」把长信号切成等长样本，既扩充样本量又保留局部暂态。

A.5.2 基学习器：一维 CNN + CBAM

4 个一维卷积层，每层后接最大池化与 ReLU，并紧跟一个 CBAM（卷积块注意力模块）；之后 2 个全连接层（含 Dropout 与 ReLU）。卷积核尺寸依次为 $64 \times 11 \times 8$、$192 \times 5 \times 64$、$384 \times 3 \times 192$、$256 \times 3 \times 384$（输出通道 × 核长 × 输入通道）。CBAM 的串联结构：

$$
\begin{aligned}
M_c(F) &= \sigma\Big(\mathrm{MLP}\big(\mathrm{AvgPool}(F)\big) + \mathrm{MLP}\big(\mathrm{MaxPool}(F)\big)\Big) \\
M_s(F) &= \sigma\Big(\mathrm{conv}\big([\mathrm{AvgPool}_c(F);\, \mathrm{MaxPool}_c(F)]\big)\Big) \\
F' &= M_s\big(F \odot M_c(F)\big) \odot \big(F \odot M_c(F)\big)
\end{aligned}
\tag{A-12}
$$

通道注意力回答「哪个特征通道重要」，空间（这里是时间轴）注意力回答「哪个时间位置重要」。现场不同电压等级、不同工况与干扰会让某些通道/时段的响应失真，CBAM 让网络自适应地把权重压到真正有判别力的部分——可以看成第 9 讲「感受野」之后再加一层可学习的软掩码。

A.5.3 Stacking 集成：只在容易错的地方做二次诊断

单纯 CNN 在正常 vs 异常二分类上，20 轮迭代后只有 **92.0%**；错误集中在「220 kV 主变噪声」与「重过载」互相混淆（两者都是大幅值、周期性、频谱形状接近）。论文的做法很务实：不把集成学习铺到所有样本上，而是——

> **条件触发的二次诊断（stacking）**
>
> 1. CNN 预测标签不是易混淆类 → 直接映射为「正常 / 缺陷」并输出，省时间；
> 2. 预测标签是易混淆类 → CNN 不出结果，把它的预测向量与「特征分析法」的预测向量串联；
> 3. 送进由 2 隐层 MLP 构成的元学习器（交叉熵损失）做综合预测，输出最终标签。
>
> 基学习器捕捉非线性模式，特征分析法提供可解释的描述性证据，元学习器学会「什么时候该信谁」。这属于集成学习三大类（堆叠 / 提升 / 装袋）里的堆叠。

A.5.4 结果阶梯：每一步改动的收益都看得见

场景	方法	结果	出处
正常 vs 异常	单独 CNN，20 轮	92.0%	陆云才 2023，图 10
19 类单一缺陷（训练集）	条件触发 stacking，15 轮	98.7%	同上，图 11
6 大类单一缺陷（测试集）	集成模型	**99.2%**，其中局放与短路冲击 100%，重过载较低	同上，图 12
6 类任选 2 类融合 = 15 类混合缺陷	单独 CNN，20 轮	97.1%	同上，图 13

场景	方法	结果	出处
混合缺陷	CNN + 4 个二分类集成模型	**99.7%**	同上，摘要
高噪声现场（朱柯佳）	TFCC 单独	98.85%	朱柯佳 2021，第 5 章
高噪声现场	小波包能量–TFCC（选维后）	99.65%（干净）/ **99.4%**（现场）	同上
高噪声现场	改进小波阈值去噪后	最高 95.1%	同上

为什么混合缺陷里「夹件松动 + 局部放电」最容易混？论文分析是两者频率及能量分布影响了识别：一个是结构松动带来的中低频调制，一个是宽带高频脉冲，混合后能量量级不同、原有特征被相互破坏。于是他们再建 4 个二分类集成模型专门处理含这两类的情况——先定位错误集中在哪，再定点补模型，这比盲目加深网络有效得多，也正是第 10 讲「看混淆矩阵而不是只看总准确率」的实战版。

A.6 代码：把 A.3 与 A.4 跑起来

```
import numpy as np

# --- 式(A-2)(A-3)：三种阈值函数 ---
def shrink(w, lam, kind="soft", lam2=None):
    a = np.abs(w)
    if kind == "hard":
        return np.where(a > lam, w, 0.0)
    if kind == "soft":
        return np.sign(w) * np.maximum(a - lam, 0.0)
    l1, l2 = lam, (lam2 or 2 * lam)          # firm shrinkage
    return np.where(a <= l1, 0.0,
           np.where(a >= l2, w,
                    np.sign(w) * l2 * (a - l1) / (l2 - l1)))

# --- 式(A-4)：分层阈值 + 稳健噪声估计 ---
def denoise_levels(coeffs, rule="visu"):
    out = []
    for c in coeffs:
        sigma = np.median(np.abs(c)) / 0.6745 + 1e-12
        lam = sigma * np.sqrt(2 * np.log(len(c)))
        out.append(shrink(c, lam, "firm"))
    return out                                # 每层一个 lam，不是全局一个

# --- 式(A-5)：谱减法（含过减与谱下限）---
def spectral_subtract(y, noise, n_fft=1024, alpha=1.3, beta=0.02):
    Y = np.fft.rfft(y[:n_fft])
    N = np.abs(np.fft.rfft(noise[:n_fft]))
    mag = np.maximum(np.abs(Y) - alpha * N, beta * np.abs(Y))
    return np.fft.irfft(mag * np.exp(1j * np.angle(Y)), n=n_fft)

# --- 式(A-8)(A-9)：频段能量与能量熵 ---
E = np.array([np.sum(node**2) for node in nodes])   # nodes: 2^j 个重构频段
p = E / (E.sum() + 1e-12)
H = -(p * np.log2(p + 1e-12)).sum()

# --- 式(A-11)：Fisher 得分（过滤式特征选择）---
def fisher_score(F, y):
    mu = F.mean(axis=0)
    sb = sum((y == c).sum() * (F[y == c].mean(axis=0) - mu)**2
             for c in np.unique(y))
    sw = sum(F[y == c].var(axis=0) * (y == c).sum()
             for c in np.unique(y))
    return sb / (sw + 1e-12)
```

把 `nodes` 换成第 7 讲 `dwt()` 的多层细节/近似重构序列，就得到可运行的小波包近似版；`F` 是 $T \times 72$ 的特征矩阵，`y` 是故障标签。建议先在 `acoustic-lab/data/` 的 6 段合成声纹上跑通，再人为叠加不同 SNR 的高斯/风机噪声复现 A.2 的对照表。

推导详解 • 专题 A　两条最容易算错的账

1. 从 50 Hz 到 100 Hz，再到奇次谐波

把磁化曲线在工作点附近展开到二阶：$B(t) = B_m \sin \omega t + \gamma B_m^2 \sin^2 \omega t + \cdots$。磁致伸缩 $\varepsilon \propto B^2$，代入并保留到 ω 的二阶：

$$\varepsilon(t) \propto \frac{B_m^2}{2} - \frac{B_m^2}{2}\cos 2\omega t \; + \; \gamma B_m^3 \sin\omega t \sin^2\omega t + \cdots \tag{A-13}$$

直流项不辐射声音，$\cos 2\omega t$ 给出 100 Hz 基频；用 $\sin\theta\sin^2\theta = \frac{1}{4}(\sin\theta - \sin 3\theta)$ 展开高阶项，出现 $\sin 3\omega t$ 即 150 Hz，以及更高奇次倍频。直流偏磁相当于给 $B(t)$ 加一个常量 B_0，于是 $(B_0 + B_m\sin\omega t)^2$ 里出现 $2B_0B_m\sin\omega t$（50 Hz）与后续奇次项——这就是「直流偏磁 → **50 Hz** 奇次倍频」的数学来源，也是本讲义合成数据里 150/250/350 Hz 峰的依据。

2. 频率分辨率：小波包、DFT、Mel 三者别混

$$\Delta f_{\text{DFT}} = \frac{F_s}{N_{\text{obs}}}, \qquad \Delta f_{\text{WP}} = \frac{F_s/2}{2^j}, \qquad \Delta f_{\text{Mel}} \text{ increases with } f \tag{A-14}$$

以 8 kHz、观测 0.2 s 为例：DFT 的真实分辨率是 $1/0.2 = 5\,\text{Hz}$（第 4 讲式 4-6，由观测时长决定，补零不改变它）；五层小波包的每个频段是 $4000/32 = 125\,\text{Hz}$（由分解层数决定，与观测时长无关，但每段内仍含足够多采样点）；Mel 滤波器在 100–500 Hz 一段只有带宽约 50–95 Hz 的少数几个三角形（第 6 讲表格）。三者是不同意义上的「分辨率」，写论文或调参时混用会得出完全错误的结论。

3. 类别不平衡下准确率会骗人

陆云才样本库里正常主变噪声每类 960 段、夹件松动只有 100 段。若按样本数直接算微平均准确率，模型只要把小类全判成大类也能拿到很高的分数。正确做法是第 10 讲的宏平均 F_1 与混淆矩阵，或像论文那样专门针对易混淆类做二次诊断。看表 A.5-4 时请连同每类的样本数一起看。

误区与注意事项

误区 ① 把文献准确率当成自己系统的性能。样本库、采样率、噪声条件全不同，不可比。② 认为去噪一定提升识别率。去噪必然带来失真，朱柯佳的实测是「本体信号训练 + 去噪信号测试」更优。③ 直接用 **8 kHz** 数据做局放检测。4000 Hz 奈奎斯特上限会砍掉高频放电特征。④ 照搬 **Mel** 频谱图。它是为人声设计的，压缩后不利于基频与倍频。⑤ 只报总准确率。样本数 960 : 100 的不平衡下必须同时给宏 F_1 和混淆矩阵。⑥ 把「改进阈值函数」当成万能。它只解决小波阈值自身的两个缺陷；面对持续弱干扰，谱减法或换特征可能更有效。

自检

- [ ] 我能从 $\varepsilon \propto B^2$ 推出 100 Hz 基频，并解释直流偏磁为什么冒出 150/250/350 Hz。
- [ ] 我能说清硬阈值、软阈值、半软阈值各自的缺陷，以及分层阈值为什么要传数组。
- [ ] 我能解释为什么 TFCC / 小波包能量谱比照搬 MFCC 更适合设备声纹。
- [ ] 我能复述 (8, 96000) 多通道输入的构造，以及 stacking 为什么只在易混淆类上触发。
- [ ] 我知道「去噪后准确率 95.1%」与「换特征后 99.4%」的对比说明了什么。

专 题 B

经典算法补遗：LPC、VQ、HMM、DTW 与它们的位置

目标

- 补齐第 1–14 讲之间被跳过的经典方法，并说清它们各自解决什么问题、后来为什么被谁替代。
- 能手动推出 Yule–Walker 方程、前向算法、维纳滤波与 DTW 递推，而不是只会调库。
- 把「模板匹配 → 概率模型 → 深度模型」这条演进线和讲义第 11–14 讲接起来。

产出

- 一张经典方法对照表；一段能跑的 Levinson–Durbin / Viterbi / DTW 代码；一次对「为什么 HMM 要取对数」的定量验证。

为什么单开一个专题 前面 17 讲走的是「信号 → 特征 → 神经网络 → 声纹识别」这条依赖链，为了不打断它，把线性预测、矢量量化、隐马尔可夫、动态时间规整、语音增强、语言模型这些经典分支压到了这里。它们不是过时废物：LPC 至今是语音编码与共振峰分析的基础，Viterbi 解码是 WFST 与 CTC 的前身，维纳滤波是 A.3 谱减法的理论升级版，N-gram 的平滑思想在今天的语言模型里仍在用。

B.1 语音产生模型与线性预测 LPC

第 1 讲把声音看成正弦叠加，那是信号视角；语音处理还有产生视角：声带（激励源）→ 声道（时变滤波器）→ 口唇辐射。把三者合起来，浊音可近似成一个全极点系统：

$$s[n] = \sum_{k=1}^{p} a_k\, s[n-k] + G\, e[n], \qquad H(z) = \frac{S(z)}{E(z)} = \frac{G}{A(z)} = \frac{G}{1 - \sum_{k=1}^{p} a_k z^{-k}} \tag{B-1}$$

$e[n]$ 是声门激励（浊音为周期脉冲串、清音为白噪声），G 是增益，p 是预测阶数（8 kHz 常取 $p = 10 \sim 12$：每对共轭极点对应一个共振峰，再加若干补偿）。线性预测的假设就是「当前样本可由前 p 个样本线性加权得到」——声道是一个共鸣腔，自然带记忆。

定义预测误差 $e[n] = s[n] - \sum_k a_k s[n-k]$，在一帧内最小化 $\mathcal{E} = \sum_n e^2[n]$。对 a_i 求偏导并令为 0：

$$\frac{\partial \mathcal{E}}{\partial a_i} = 0 \;\Longrightarrow\; \sum_{k=1}^{p} a_k\, R[|i-k|] = R[i], \qquad i = 1, \dots, p, \qquad R[i] = \sum_n s[n]\, s[n-i] \tag{B-2}$$

写成矩阵就是 **Yule–Walker** 方程 $R_p \mathbf{a} = \mathbf{r}$，其中 R_p 是 Toeplitz 矩阵（元素只依赖于 $|i-k|$）。这个结构让一般 $O(p^3)$ 的求解降到 $O(p^2)$——Levinson–Durbin 递推：

$$
\begin{aligned}
&E_0 = R[0], \qquad k_m = \frac{R[m] - \sum_{j=1}^{m-1} a_j^{(m-1)} R[m-j]}{E_{m-1}} \\
&a_m^{(m)} = k_m, \qquad a_j^{(m)} = a_j^{(m-1)} - k_m\, a_{m-j}^{(m-1)} \ \ (j = 1, \dots, m-1) \\
&E_m = \left(1 - k_m^2\right) E_{m-1}
\end{aligned}
\tag{B-3}
$$

k_m 叫反射系数 / **PARCOR** 系数。只要 $|k_m| < 1$，就有 $E_m > 0$ 且 $A(z)$ 的全部根落在单位圆内 → 合成滤波器必定稳定。这是 LPC 被广泛用于编码的关键性质：直接量化 a_k 可能让滤波器炸掉，量化 k_m 则只要卡住 $|k_m| < 1$ 就安全。

手算一遍（$p = 2$）：设 $R[0] = 1,\ R[1] = 0.5,\ R[2] = 0.2$。

$$
\begin{aligned}
m = 1:\ & k_1 = \frac{R[1]}{R[0]} = 0.5, \quad a_1^{(1)} = 0.5, \quad E_1 = (1 - 0.25) \cdot 1 = 0.75 \\
m = 2:\ & k_2 = \frac{R[2] - a_1^{(1)} R[1]}{E_1} = \frac{0.2 - 0.25}{0.75} = -0.0667 \\
& a_2^{(2)} = -0.0667, \quad a_1^{(2)} = 0.5 - (-0.0667)(0.5) = 0.5333 \\
& E_2 = (1 - 0.00444) \cdot 0.75 = 0.7467
\end{aligned}
\tag{B-4}
$$

回代验证 $a_1 R[0] + a_2 R[1] = 0.5333 - 0.0333 = 0.5 = R[1]$ √，$a_1 R[1] + a_2 R[0] = 0.2667 - 0.0667 = 0.2 = R[2]$ √。预测误差能量从 1.0 降到 0.7467，说明用一个二阶模型就能解释约 25% 的样本方差。

B.1.1 LPC 倒谱、共振峰与线谱对

第 6 讲的倒谱来自「log 功率谱 + 反变换」；用全极点模型时，可以直接从 a_k 递推出倒谱系数，不必再跑一次 FFT：

$$
c_1 = a_1, \qquad c_n = a_n + \frac{1}{n} \sum_{k=1}^{n-1} k\, c_k\, a_{n-k} \ \ (2 \le n \le p), \qquad c_n = \frac{1}{n} \sum_{k=1}^{p} (n-k)\, c_{n-k}\, a_k \ \ (n > p)
\tag{B-5}
$$

由 $\ln H(z) = \ln G - \ln A(z)$ 两边对 z^{-1} 求导、比较系数即得（推导见本专题末尾）。LPCC 与 MFCC 目的一样——描述谱包络；区别是 MFCC 靠听觉滤波器组，LPCC 靠全极点拟合，后者对共振峰更锐利、对噪声更敏感。

把 $A(z) = 1 - \sum_k a_k z^{-k}$ 求根，共轭根 $z_i = r_i e^{j\theta_i}$ 直接给出共振峰的位置与带宽：

$$
F_i = \frac{\theta_i}{2\pi} F_s, \qquad B_i = -\frac{\ln r_i}{\pi} F_s
\tag{B-6}
$$

例：$F_s = 8000$、$r = 0.90,\ \theta = 2\pi(500/8000) \to F_1 = 500\,\text{Hz}$，$B_1 = -\ln(0.9) \cdot 8000/\pi \approx 268\,\text{Hz}$。$r$ 越接近 1，峰越尖锐（带宽越窄）——这正是「共振」的直观含义。若改用线谱对 **LSP**，构造 $P(z) = A(z) + z^{-(p+1)} A(z^{-1})$、$Q(z) = A(z) - z^{-(p+1)} A(z^{-1})$，可以证明二者的根都在单位圆上且彼此交错。把 p 个实数量化成 p 个角度，插值时系统仍稳定、误差只影响附近的谱峰——所以 LPC-10、G.729 一类编码器传的是 LSP 而不是 a_k。

B.2 矢量量化 VQ 与 LBG

把一帧特征向量 $\mathbf{x} \in \mathbb{R}^d$ 用码本 $\mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_K\}$ 中最近的一个码字代替：

$$Q(\mathbf{x}) = \arg\min_{1\le k\le K} d(\mathbf{x},\mathbf{c}_k), \qquad D = \frac{1}{T}\sum_{t=1}^{T} \min_k d(\mathbf{x}_t,\mathbf{c}_k), \qquad d(\mathbf{x},\mathbf{c}) = \|\mathbf{x}-\mathbf{c}\|^2 \tag{B-7}$$

码本大小 $K = 2^b$，每帧只传 b bit；这是第 9 讲「参数量」之外的另一种压缩思路——压缩的是数据本身，不是模型。失真测度不一定是欧氏距离：用 LPC 系数时常用 **Itakura–Saito** 失真，它按预测残差能量归一化，对增益变化不敏感；说话人识别里还可用「识别失真测度」，直接在度量里加入类间判别信息。

LBG 算法（Linde–Buzo–Gray，也叫广义 Lloyd）是 k-means 的码本版，靠逐步分裂避开局部最优：

LBG 流程

1. 用全部训练向量求质心，作为 $K=1$ 的唯一码字；
2. 分裂：每个码字 $\mathbf{c} \to \mathbf{c}(1\pm\epsilon)$（$\epsilon$ 取 0.01 量级），码本大小翻倍；
3. 最近邻划分：把所有训练向量归到最近的码字；更新质心为各类均值；
4. 重复 3 直到平均失真 D 的相对下降小于阈值（如 1%）；
5. 若 K 未达目标，回到 2 再分裂。

每次划分与质心更新都保证 D 不增，所以收敛有保证。用 **VQ** 做说话人确认：给每个注册人训一个专属码本 $\mathcal{C}_c$，测试时算总失真 D_c，取最小的那个——这是第 12 讲「打分」的一种最朴素实现，也解释了为什么后来需要 z-norm：不同人码本的失真尺度天生不同。

B.3 隐马尔可夫模型 HMM：三个问题、三个算法

离散 HMM 由 $\lambda = (A, B, \pi)$ 定义：状态转移 $a_{ij} = P(q_t = j \mid q_{t-1} = i)$、观测发射 $b_j(k) = P(o_t = v_k \mid q_t = j)$、初始分布 π_i。语音是时序信号，GMM（第 13 讲）只建模「这一帧像谁」而丢掉了帧间顺序，HMM 补上这一维。三个基本问题：

问题	要算什么	算法	复杂度
评估	$P(O \mid \lambda)$	前向–后向（或只用前向）	$O(TN^2)$
解码	最可能的状态序列 Q^*	Viterbi	$O(TN^2)$
学习	估计 λ 使 $P(O \mid \lambda)$ 最大	Baum–Welch（EM 的特例）	每轮 $O(TN^2)$

$$\begin{aligned} \alpha_t(j) &= \Big[\sum_{i=1}^{N} \alpha_{t-1}(i)\, a_{ij}\Big] b_j(o_t), & P(O\mid\lambda) &= \sum_{i=1}^{N} \alpha_T(i) \\ \beta_t(i) &= \sum_{j=1}^{N} a_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j), & \delta_t(j) &= \max_i \Big[\delta_{t-1}(i) a_{ij}\Big] b_j(o_t) \end{aligned} \tag{B-8}$$

前向 α 与 Viterbi δ 只差「求和 vs 取最大」——这是同一个动态规划骨架换掉一个算子（概率和 → 最大概率路径），也叫 **Viterbi** 是对数域/极大域里的前向算法。T 帧、N 状态的朴素枚举是 N^T，动态规划降到 $O(TN^2)$。

$$\gamma_t(i)=\frac{\alpha_t(i)\beta_t(i)}{P(O\mid\lambda)},\qquad \xi_t(i,j)=\frac{\alpha_t(i)\,a_{ij}\,b_j(o_{t+1})\,\beta_{t+1}(j)}{P(O\mid\lambda)},\qquad \hat{a}_{ij}=\frac{\sum_{t=1}^{T-1}\xi_t(i,j)}{\sum_{t=1}^{T-1}\gamma_t(i)} \tag{B-9}$$

$\gamma_t(i)$ 是「第 t 帧处于状态 i」的后验，$\xi_t(i,j)$ 是「$t\to t+1$ 从 i 转到 j」的后验——与第 13 讲 GMM 的责任度 γ_{tc} 完全对应：**Baum–Welch** 就是带时序约束的 **EM**。E 步算 γ,ξ，M 步用它们重估 A,B,π，每轮保证似然不降。

必须取对数 $\alpha_t(j)$ 是 $2t$ 个小于 1 的数连乘，$T=100$ 帧时双精度早已下溢为 0（$0.5^{200}\approx10^{-60}$，虽仍在双精度范围内，但真实发射概率常小到 10^{-10} 量级，T 稍大就归零）。工程实现要么每帧归一化并重标尺度，要么全程在对数域做 $\ln\alpha$ 并用 log-sum-exp。这与第 **13** 讲 **GMM** 的 **log-sum-exp**、第 **8** 讲 **softmax** 减 **max** 是同一类数值技巧。

和讲义主线怎么接：单状态 HMM 的输出密度用 GMM，就退化成第 13 讲的 UBM；把状态数设为 1、去掉转移矩阵，就是「忽略时序」的 i-vector / x-vector 路线。深度学习声纹不是推翻了 **HMM**，而是用统计池化（第 **14** 讲式 **14-1**）换掉了显式状态对齐；而 ASR 侧的 HMM 则被 CTC / attention 的端到端对齐替代（见 B.6）。

B.4 DTW：不用概率模型的模板匹配

同一个词，说得快和说得慢，特征序列长度不同。DTW 用动态规划找一条非线性时间对齐路径 $W=\{(i_l,j_l)\}$，使累计距离最小：

$$D(i,j)=d(\mathbf{q}_i,\mathbf{c}_j)+\min\Big\{D(i-1,j),\;D(i,j-1),\;D(i-1,j-1)\Big\},\qquad D_{\min}=\frac{D(N,M)}{L_W} \tag{B-10}$$

约束：单调（i,j 不减）、连续（每步最多跳 1）、边界（从 $(1,1)$ 到 (N,M)），再加 **Sakoe–Chiba** 带 $|i-j|\le R$ 防止病态对齐并省一半计算。除以路径长度 L_W 是为了让不同长度模板可比，否则长模板天然吃亏。

	DTW	HMM	本讲义的深度模型
建模对象	一条（或几条）模板	概率分布 + 状态转移	可学的 embedding / 分类器
训练	几乎不需要	Baum–Welch 迭代	SGD + 大量数据
时间对齐	显式 DP 路径	隐式状态序列	注意力 / 统计池化
适合	孤立词、小样本、与文本相关	连续语音、中等数据	开集、变长、大数据

赵力《语音信号处理（第三版）》第 7、8 章分别把 DTW 用于孤立字识别与说话人确认；柳若边书第 6.5 节也把 DTW 放进「语音信号处理」入门链条里。它的价值不在于性能，而在于让你亲手看见「时间对齐」这件事本身——理解了 DTW 的路径，再看 CTC 的 blank 折叠、注意力权重图就不会觉得抽象。

B.5 增强、端点检测与基音估计的补遗

B.5.1 维纳滤波：谱减法的理论升级

A.3 的谱减法是「减掉噪声功率谱」；维纳滤波从最小均方误差出发，直接导出最优增益。设 $Y=X+N$ 且信号与噪声不相关，令 $\hat{X}=HY$，最小化 $\mathbb{E}|X-HY|^2$，对 H 求导置零得：

$$H(k)=\frac{P_X(k)}{P_X(k)+P_N(k)}=\frac{\xi(k)}{1+\xi(k)},\qquad \xi(k)=\frac{P_X(k)}{P_N(k)}\ \text{(a priori SNR)}\tag{B-11}$$

谱减法相当于给 H 一个硬阈值式的近似，维纳增益则在 $0\sim1$ 之间平滑过渡：$\xi\gg1$ 时 $H\approx1$（几乎不处理），$\xi\to0$ 时 $H\to0$（几乎全抑制）。先验 SNR 未知，工程上用决策导向估计

$\hat{\xi}_t(k)=\alpha\,\frac{|\hat{X}_{t-1}(k)|^2}{P_N(k)}+(1-\alpha)\max\!\Big(\frac{|Y_t(k)|^2}{P_N(k)}-1,\,0\Big)$，$\alpha\approx0.98$。

它同样会产生音乐噪声，但比谱减法温和。把它和 **A.3** 的表连起来看：小波阈值、谱减、维纳、**FastICA** 是四条不同假设下的去噪路线，没有哪条在所有场景都赢。

B.5.2 端点检测、基音与共振峰的其他判据

第 3 讲用了能量 + 过零率双门限，赵力书第 5 章还列了自相关法、谱熵法、比例法、对数频谱距离法。谱熵法最直观：把每帧归一化谱当成概率分布 $p_k=|X[k]|^2/\sum_j|X[j]|^2$，

$$H=-\sum_k p_k\log_2 p_k\in[0,\log_2 K]\tag{B-12}$$

噪声段谱平坦 $\to H$ 大；语音段有共振峰结构 $\to H$ 小。谱熵对幅值不敏感（归一化消掉了增益），所以在稳态噪声下比能量门限稳；代价是对谱估计的方差敏感，需配合多帧平滑。

基音检测除第 3 讲的自相关外，还有 **AMDF**（平均幅度差函数）与倒谱法：

$$D_{\text{AMDF}}(k)=\sum_{n=0}^{N-1-k}\big|s[n]-s[n-k]\big|,\qquad k_0=\arg\min_{k\in[k_{\min},k_{\max}]}D_{\text{AMDF}}(k),\quad f_0=\frac{F_s}{k_0}\tag{B-13}$$

与自相关 $R(k)$ 互补：周期处 $R(k)$ 取峰、$D_{\text{AMDF}}(k)$ 取谷。AMDF 只需加减法和绝对值，没有乘法，早年在定点 DSP 上很吃香；缺点是谷底较宽、易受幅值调制影响，所以常与自相关或倒谱法联合、并做中值平滑后处理（赵力书第 5.3.5「基音检测的后处理」）。倒谱法则利用「激励的周期性在倒谱域表现为 k_0 处的尖峰」，把卷积变相加后再找峰，正是第 6 讲同态解卷积的另一个用途。

B.6 解码那一侧：N-gram、WFST 与端到端

第 11 讲说过「语音识别要知道说了什么、声纹识别要知道谁说的，方向正交」。补上 ASR 这一侧的最小知识，才能理解为什么讲义的声纹打分不依赖文本内容。

$$P(W)\approx\prod_{i=1}^{n}P\big(w_i\mid w_{i-2},w_{i-1}\big),\qquad \hat{P}_{\text{MLE}}(w_3\mid w_1w_2)=\frac{C(w_1w_2w_3)}{C(w_1w_2)}\tag{B-14}$$

三元模型的最大似然估计就是数数。问题在于没见过的三元组概率为 0，会让整句概率归零 → 必须平滑。加一平滑 $\hat{P}=(C+1)/(C_{\text{context}}+V)$ 最粗糙；Good–Turing 把「出现 1 次的计数」重分配给未见事件；Kneser–Ney 更进一步，用「该词能接在多少种不同上下文之后」而不是原始计数来算回退权重。柳若边书第 8.1 节把这些做成了一条从一元到 N 元的完整链条。

$$\mathrm{PPL}(W) = 2^{-\frac{1}{N}\sum_{i=1}^{N}\log_2 P(w_i|h_i)}, \qquad W^{*} = \arg\max_{W}\; P(X\mid W)\,P(W) \xrightarrow{\text{WFST}} H\circ C\circ L\circ G \tag{B-15}$$

困惑度 PPL 可理解为「每个词的等效分支数」，越小越好。传统 Kaldi 把 HMM 状态（H）、上下文（C）、词典（L）、语言模型（G）都做成加权有限状态转换器，先组合再求最短路——柳若边书第 **1.9** 节的 **FSA/FST/WFST** 就是为这里做铺垫，第 7 章的 nnet3 则把声学模型换成 DNN。

端到端把这条流水线压成一个网络。CTC 引入 blank 符号与折叠映射 $\mathcal{B}$（把连续重复字符合并、去掉 blank），对所有能折叠成标签的对齐路径求和：

$$L_{\mathrm{CTC}} = -\ln \sum_{\pi\in\mathcal{B}^{-1}(\mathbf{y})}\prod_{t=1}^{T} p(\pi_t\mid \mathbf{x}), \qquad \mathcal{B}(a\!-\!b\!-\!b) = \mathcal{B}(a\!-\!b\!-\!\!-\!b) = \mathrm{ab} \tag{B-16}$$

这个求和用前向–后向（式 B-8 的骨架）在 $O(T\cdot|\mathbf{y}|)$ 内算完，不需要帧级标注——这正是 CTC 取代 HMM 对齐的关键。注意力式 encoder–decoder 则让解码器每步自己「看」编码器的不同时间位置，权重图其实就是一条学出来的 **DTW** 对齐路径（呼应 B.4）。第 14 讲的统计池化与注意力池化，用的也是同一套思想，只是目的从「输出文字」变成「输出说话人 embedding」。

B.7 代码：四个算法的最小实现

```
import numpy as np

# --- 式(B-3) Levinson-Durbin：R[0..p] -> LPC 系数、反射系数、误差能量 ---
def levinson(R, p):
    a = np.zeros(p + 1); a[0] = 1.0
    E = R[0]; ks = []
    for m in range(1, p + 1):
        k = (R[m] - np.dot(a[1:m], R[m-1:0:-1])) / E
        old = a.copy()
        a[m] = k
        for j in range(1, m):
            a[j] = old[j] - k * old[m-j]
        E *= (1 - k*k); ks.append(k)
    return -a[1:], np.array(ks), E     # 注意 A(z)=1-sum(a_k z^-k) 的符号

# --- 式(B-5) LPC 倒谱 ---
def lpc_cepstrum(a, n_ceps):
    p = len(a); c = np.zeros(n_ceps)
    c[0] = a[0]
    for n in range(1, n_ceps):
        if n <= p:
            c[n] = a[n] + sum(k*c[k]*a[n-k] for k in range(1, n)) / n
        else:
            c[n] = sum((n-k)*c[n-k]*a[k] for k in range(1, p+1)) / n
    return c

# --- 式(B-8) 前向 + Viterbi（对数域）---
def forward_log(A, B, pi, obs):
    T, N = len(obs), A.shape[0]
    la = np.log(pi + 1e-300) + np.log(B[:, obs[0]] + 1e-300)
    for t in range(1, T):
        # log-sum-exp 取代 sum，避免下溢
        m = la.max()
        la = np.log(np.exp(la - m) @ A + 1e-300) + m + np.log(B[:, obs[t]] + 1e-300)
    m = la.max()
    return m + np.log(np.exp(la - m).sum())

def viterbi_log(A, B, pi, obs):
    T, N = len(obs), A.shape[0]
    d = np.log(pi + 1e-300) + np.log(B[:, obs[0]] + 1e-300); psi = []
    for t in range(1, T):
        s = d[:, None] + np.log(A + 1e-300)
        psi.append(s.argmax(axis=0)); d = s.max(axis=0) + np.log(B[:, obs[t]] + 1e-300)
    path = [int(d.argmax())]
    for p in reversed(psi): path.append(int(p[path[-1]]))
    return path[::-1]

# --- 式(B-10) DTW（带 Sakoe-Chiba 带）---
def dtw(Q, C, R=None):
    N, M = len(Q), len(C); R = R or max(N, M)
    D = np.full((N+1, M+1), np.inf); D[0, 0] = 0.0
    for i in range(1, N+1):
        for j in range(max(1, int(i*M/N)-R), min(M, int(i*M/N)+R)+1):
            d = np.linalg.norm(Q[i-1] - C[j-1])
            D[i, j] = d + min(D[i-1, j], D[i, j-1], D[i-1, j-1])
    return D[N, M]
```

```
# --- 式(B-7) LBG 的一次「划分 + 更新」---
def lbg_step(X, C):
    lab = np.argmin(((X[:, None, :] - C[None, :, :])**2).sum(-1), axis=1)
    return np.array([X[lab == k].mean(axis=0) if (lab == k).any() else C[k]
                     for k in range(len(C))])

# --- 式(B-11)(B-13) 维纳增益 / AMDF ---
def wiener(Y, PN, alpha=0.98):
    post = np.abs(Y)**2 / (PN + 1e-12)
    H = np.empty_like(Y); prev = np.zeros_like(PN)
    for t in range(len(Y)):
        xi = alpha*prev/(PN+1e-12) + (1-alpha)*np.maximum(post[t]-1, 0)
        H[t] = xi/(1+xi); prev = (H[t]**2)*np.abs(Y[t])**2
    return H * Y

def amdf(x, fmin=80, fmax=400, fs=8000):
    lo, hi = int(fs/fmax), int(fs/fmin)
    D = np.array([np.abs(x[k:] - x[:-k]).mean() for k in range(lo, hi+1)])
    return fs/(lo + D.argmin()), lo + D.argmin()
```

推导详解 · 专题 B　四个「为什么」

1. Yule–Walker 方程怎么来的

令 $e[n]=s[n]-\sum_{k=1}^{p}a_k s[n-k]$，$\mathcal{E}=\sum_n e^2[n]$。对 a_i 求偏导：

$$\frac{\partial \mathcal{E}}{\partial a_i}=-2\sum_n e[n]\,s[n-i]=0 \;\Longrightarrow\; \sum_n s[n]s[n-i]=\sum_{k=1}^{p}a_k\sum_n s[n-k]s[n-i] \tag{B-17}$$

右边内层求和正是 $R[|i-k|]$（自相关法用加窗帧、零填充外的值），于是得到式 (B-2)。注意这是「自相关法」的解；若不对帧外补零、改用协方差法，矩阵不再 Toeplitz，就不能用 Levinson–Durbin，要直接解一般线性方程——赵力书第 4.6.2 节、韩纪庆书第 4.2 节对这两种解法有专门比较。

2. 反射系数为什么保证稳定

由式 (B-3)，$E_m=(1-k_m^2)E_{m-1}$。误差能量必为正，故 $|k_m|<1$；反过来，若所有 $|k_m|<1$，递推出的 $A(z)$ 所有根都在单位圆内（这是 Schur–Cohn 稳定判据的等价形式）。因此只要约束反射系数，合成滤波器就不会发散——这就是编码器宁可传 k_m / LSP 也不直接量化 a_k 的原因。

3. LPC 倒谱递推怎么推

对 $\ln H(z)=\ln G-\ln A(z)$ 两边取 z^{-1} 的导数，并利用 $\ln H(z)=\sum_{n\ge 1}c_n z^{-n}$（忽略直流项）：

$$\frac{\mathrm{d}}{\mathrm{d}z^{-1}}\ln H(z)=-\frac{A'(z^{-1})}{A(z^{-1})} \;\Longrightarrow\; \sum_{n\ge 1}n c_n z^{-n-1}=\frac{\sum_{k=1}^{p}k a_k z^{-k-1}}{1-\sum_{k=1}^{p}a_k z^{-k}} \tag{B-18}$$

两边乘 $A(z^{-1})$ 并比较 z^{-n-1} 的系数，即得 $nc_n=na_n+\sum_{k=1}^{n-1}k a_k c_{n-k}$，整理就是式 (B-5)。这说明 **LPCC** 与 **MFCC** 是同一件事的两种算法路径：一个从全极点模型的系数直接递推，一个从谱的 DCT 得到，目标都是「谱包络的低维表示」。

4. 维纳增益为什么是 MMSE 最优

令 $\hat{X}=HY$，$J(H)=\mathbb{E}|X-HY|^2=\mathbb{E}|X|^2-2H\,\mathrm{Re}\,\mathbb{E}[XY^*]+H^2\mathbb{E}|Y|^2$。对 H 求导置零：

$$H^* = \frac{\mathbb{E}[XY^*]}{\mathbb{E}|Y|^2} = \frac{P_X}{P_X + P_N} = \frac{\xi}{1+\xi}, \qquad J_{\min} = \frac{P_X P_N}{P_X + P_N} \tag{B-19}$$

用了信号与噪声不相关（$\mathbb{E}[XN^*] = 0$）。可见维纳滤波是线性 **MMSE** 估计，而谱减法只是它的一种粗略近似，这解释了 A.3 里谱减法失真度最高的现象。

误区与注意事项

误区 ① 把 **LPC** 阶数当越大越好。p 过大拟合噪声、谱峰虚假分裂；8 kHz 一般 10–12 阶。② 直接量化 a_k 做编码。可能让 $A(z)$ 根跑到单位圆外，合成时发散；应量化反射系数或 LSP。③ **HMM** 不取对数。几十帧连乘必然下溢，且症状隐蔽（概率全 0 但不报错）。④ **DTW** 忘记按路径长度归一化。长模板系统性吃亏。⑤ 把 **CTC** 的 **blank** 当成「静音」。它是允许重复字符与无对齐输出的占位符，与声学静音无关。⑥ 以为经典方法都过时了。Viterbi、log-sum-exp、反射系数、维纳增益这些结构今天仍在深度模型内部。

自检

- [ ] 我能从最小化预测误差推出 Yule–Walker 方程，并用 B-4 的数字验算一遍 Levinson–Durbin。
- [ ] 我能说明为什么 $|k_m| < 1$ 保证滤波器稳定，以及 LSP 为什么更适合量化。
- [ ] 我能写出前向算法与 Viterbi 的递推，并说出它们只差一个算子。
- [ ] 我能解释 DTW 的路径约束、谱熵 VAD 为什么抗增益变化、AMDF 与自相关为何互补。
- [ ] 我能把 CTC 的 blank 折叠、注意力权重、统计池化三者串成一条「时间对齐」的演进线。

专题 C

动手实验清单与资料索引

目标

- 把前面 17 讲 + 专题 A/B 的每一条结论，都变成一条能自己跑、能判对错的实验。
- 知道每本参考书各自贡献了什么，遇到卡点时能直接定位到该翻哪一本、哪一章。
- 养成「先预测结果 → 再跑 → 对不上就找根因」的习惯，而不是把代码跑通就算学完。

产出

- 一张打了勾的实验记录表；一份自己写的「参数 → 现象」笔记；能说清每个验收标准的数字是怎么来的。

C.1 教材实验体系与本讲义的对应

梁瑞宇、赵力、魏昕《语音信号处理实验教程》是赵力《语音信号处理（第 3 版）》的配套实验教材，共 13 章、基于 MATLAB。它给的是实验编排，本讲义给的是为什么这么做 + 手写实现，两者正好互补：

教程章节	实验内容	对应本讲义	本项目的替代做法
第 1 章	MATLAB 基础教程	第 0 讲	`python run.py --check` 取代 MATLAB 环境
第 2 章	语音信号处理基础实验	第 1–2 讲	`src/wav.py` 手写 WAV 读写与 6 类合成声纹
第 3 章	语音信号分析实验	第 3–5 讲	能量 / 过零率 / 自相关 / STFT 全套手写
第 4 章	语音信号特征提取实验	第 6–7 讲	MFCC(13/39)、Mel 滤波器组、小波与 EMD
第 5 章	语音增强实验	专题 A.3 / B.5	谱减、维纳、小波阈值三种可对比实现
第 6 章	语音编码实验	专题 B.1 / B.2	LPC / 反射系数 / LSP / VQ 码本
第 7 章	语音合成与转换实验	专题 B.1（源–滤波器模型）	用全极点模型反过来合成，验证 $H(z)$
第 8 章	语音隐藏实验	第 4 讲（频域）、第 5 讲（时频）	可作为拓展：在谱里嵌信息再看可恢复性
第 9 章	声源定位实验	第 3 讲（互相关）	把自相关推广成互相关估时延 τ
第 10 章	语音识别实验	专题 B.3 / B.4 / B.6	DTW、Viterbi、WFST 概念验证
第 11 章	说话人识别实验	第 11–14 讲	VQ / GMM-UBM / i-vector / embedding 四类打分对照
第 12 章	语音情感识别实验	第 10 讲（特征与评估）	换标签重跑同一套特征 + BPNN/CNN
第 13 章	实用语音信号处理平台	第 15 讲	把前面各模块串成一条命令行流水线

怎么用这张表 教程用 MATLAB，本讲义用纯 Python + numpy + Pillow，没有第三方算法库。如果你的目的是「真正理解」，建议先按本讲义手搓一遍，再去对照教程里的 MATLAB 实现——两边结果应当一致，不一致就是最有价值的学习点。

C.2 15 个可自己跑的实验

每个实验都写清改什么、预期看到什么、怎么算通过。所有实验都在 `acoustic-lab/` 里做，先用 `python run.py --check` 确认基线，再单独改动一个参数——一次只动一个变量，否则现象无法归因。

$$\varepsilon_{\text{rel}} = \frac{\left\| g_{\text{ours}} - g_{\text{ref}} \right\|}{\left\| g_{\text{ours}} \right\| + \left\| g_{\text{ref}} \right\| + \epsilon} < 10^{-10}, \qquad \text{macro}F_1 = \frac{1}{C}\sum_{c=1}^{C} \frac{2P_c R_c}{P_c + R_c} \tag{C-1}$$

左边是所有「对拍类」实验的通用验收线（第 8 讲梯度检查、第 4 讲 DFT 对拍都用它）；右边是类别不平衡时必须补报的指标（第 10 讲、专题 A.5.4）。

第一组：基础层（E1–E5）

编号	改动	预期现象	验收标准
E1 混叠	把含 1000 Hz 分量的信号按 800 Hz 重采样	峰跑到 200 Hz，且再怎么增加采样点数也回不来	用 $f_{\text{alias}} = \min_k \lvert f - kF_s \rvert$ 手算得 200 Hz（第 2 讲式 2-3）
E2 量化	量化位数 16 → 8 → 4 bit	波形出现台阶，底噪抬升	SNR 依 $6.02B + 1.76$ 约 98 / 50 / 26 dB（式 2-4、推导 2-11）
E3 加窗	汉明窗 ↔ 矩形窗，对非整周期正弦做谱	矩形窗旁瓣约 −13 dB 且主峰降约 3.9 dB；汉明窗旁瓣约 −43 dB	量出两者旁瓣差 ≥ 25 dB
E4 DFT 对拍	自己写 $X[k] = \sum_n x[n] W_N^{kn}$，与 `np.fft.fft` 比	逐点几乎相同	最大绝对偏差 $< 10^{-12}$（本仓库实测 1.4×10^{-12}）
E5 补零	256 点补到 1024 点，信号含 100 Hz 与 120 Hz	谱线从 31.25 Hz 变「密」到 7.8 Hz，但两个峰仍糊在一起	能说出真实分辨率由 T_{obs} 决定（式 4-6 / 4-13）

第二组：特征层（E6–E10）

编号	改动	预期现象	验收标准
E6 预加重	$\alpha: 0 \to 0.97$	100 Hz 基频被明显压低	按 $\lvert H \rvert^2 = (1-\alpha)^2 + 4\alpha \sin^2(\omega/2)$ 算出低频约 −26 dB（专题 A / 第 6 讲式 6-9）
E7 Mel 通道账	打印 26 个滤波器中心频率，数 100–500 Hz 内有几个	只有 2–3 个通道覆盖最关键的谐波区	能复算 $m(f) = 2595 \log_{10}(1 + f/700)$ 与第 6 讲前 10 个中心频率表
E8 差分 vs 维度	13 维静态 → 30 维静态 → 13+Δ+ΔΔ（39 维），各跑同一分类器	加维度收益很小，加差分明显变好	复现韩书表 3-3 的结论（加差分约降 20% 误识），并解释最小二乘斜率（式 6-15）
E9 阈值函数	对同一含噪信号分别用硬 / 软 / 半软阈值	硬阈值重构有振荡；软阈值整体幅值偏低；半软两者都缓解	同时报 RMSE 与 LSD，说明为什么只看 SNR 会漏掉谱畸变（专题 A 式 A-7）
E10 谱减法	调过减因子 $\alpha = 1.0 \to 2.0$、谱下限 β	α 太大出现音乐噪声、谱峰被削	画出「去噪后」与「原始」的谐波峰高对比，指出哪一列判别信息丢了

第三组：模型与经典算法（E11–E15）

编号	改动	预期现象	验收标准
E11 学习率	$\eta: 0.1 \to 2.0$，连点「下降一步」	先震荡、后发散甚至 NaN	能用 $\eta < 2/\lambda_{\max}$ 解释（第 10 讲）；`labs.html` 第二个实验台可直接拖
E12 梯度检查	关掉 dropout，对每个权重做中心差分	解析梯度与数值梯度一致	绝对误差 $< 10^{-10}$；近零元素要用式 C-1 的相对误差判据，别被 5×10^{-6} 吓到
E13 LPC 阶数	$p = 4, 8, 12, 20$，画 $1/\lvert A(e^{j\omega})\rvert$ 与 MFCC 包络叠加	低阶平滑欠拟合，过高出现虚假谱峰	用 B-6 从根算出前 3 个共振峰频率，与谱峰位置对上
E14 VQ 码本	码本大小 $K = 2, 4, \ldots, 256$，画平均失真 D 曲线	单调下降、边际收益递减；注意过拟合	每次 LBG 迭代 D 不增；报告每帧比特数 $b = \log_2 K$
E15 时间对齐	同一段语音快放/慢放，分别跑 DTW 与 Viterbi	得到可解释的对齐路径，快放版路径被压缩	手算一个 3×3 的 DTW 网格，与代码输出逐格一致（式 B-10）

实验记录模板 每条实验记四行：预测（我以会看到什么）→ 实测（实际数字/截图）→ 差异（对不上的地方）→ 根因（哪条公式或哪行代码）。第 0 讲说过「预测—打脸」的过程才是真正记住的地方；没有第一行的实验记录等于没做。

C.3 资料来源索引

本讲义的知识点来自下列资料。按仓库约定，原书全文与从电子书提取的文本均不入库（版权内容），仓库只包含自己撰写的讲义、自己手写的算法实现、以及由脚本实测生成的图表与数值。

资料	形态	本次用于	对应章节
韩纪庆、张磊、郑铁然《语音信号处理（第 3 版）》	EPUB，可提取全文	理论根基：产生模型、短时分析、同态解卷积、Mel 倒谱、线性预测、LPC 倒谱	第 1–7 讲、专题 B.1 / B.5
王泉《声纹技术：从核心算法到工程实践》	MOBI，可提取全文	工程视角：预处理、评价指标、GMM-UBM、i-vector、深度学习声纹	第 11–14 讲
赵力《语音信号处理（第三版）》	PDF 扫描版，仅目录可用	知识地图：矢量量化、HMM、LPC/LSP、端点检测、基音/共振峰、语音增强、DTW、说话人识别各分支	专题 B 全篇、第 3/5 讲延伸
梁瑞宇、赵力、魏昕《语音信号处理实验教程》	PDF，可提取	13 章实验体系与编排	专题 C.1、各讲「动手」部分
柳若边《深度学习语音识别技术实践》	EPUB，可提取	Kaldi / WFST / FST、DTW、VAD、端到端、N-gram 与平滑、困惑度	专题 B.4 / B.6

资料	形态	本次用于	对应章节
宋知用《MATLAB 语音信号分析与合成（第 2 版）》	PDF 扫描版	仅作「MATLAB 实现路线」的参照，未转录正文	专题 C.1 对照
姜囡《语音信号识别技术与实践》	PDF 扫描版	识别系统结构的旁证，未转录正文	第 11 讲
朱柯佳《高噪声环境下变压器声纹特征提取方法研究》（2021，硕士论文）	PDF，字符定位需重排	专题 **A** 主体：三种去噪法对比、改进/分层阈值、小波包能量谱、TFCC、Laplacian/Fisher 选维、现场实测数字	专题 A.2–A.4、A.6
陆云才等《基于声纹特征和集成学习的变压器缺陷诊断方法》（2023）	PDF，可提取	专题 **A** 主体：19 类样本库、多通道时频输入、CNN+CBAM、stacking 二次诊断、单一/混合缺陷实测结果	专题 A.1 / A.5

一句提醒 三本扫描版 PDF 没有文本层，本次只用它们的目录做知识地图，正文公式全部按标准教材形式自行推导，没有从扫描件 OCR 后照抄。专题 A 里朱柯佳论文的「改进阈值函数」也一样：讲义给出的是同家族的半软阈值标准形式并说明思路，不是原论文图中分段公式的逐字转录。

C.4 从讲义到现场：十条检查清单

上线前逐条过

1. 采样率是不是任务定的？局放要数 kHz 以上，8 kHz 不够（专题 A.2）。
2. 抗混叠滤波在 **ADC** 之前吗？采样后再补已经晚了（第 2 讲式 2-10）。
3. 预处理有没有压掉判别频段？预加重 $\alpha = 0.97$ 会把 100 Hz 压掉约 26 dB。
4. 分帧/帧移是否满足重叠相加？无重叠会让重构失真（第 5 讲式 5-5）。
5. 特征是不是照搬语音配置？Mel 在低频只给 2–3 个通道（第 6 讲、专题 A.4）。
6. 去噪有没有引入失真？同时报 SNR、RMSE、LSD，不要只看波形像不像。
7. 划分是不是按「段/设备」分组？按帧随机切会让指标虚高（第 10 讲）。
8. 类别不平衡有没有报宏 F_1？960 : 100 的样本比会骗人（专题 A.5.4）。
9. 阈值是在开发集上选的吗？在测试集上调阈值等于作弊（第 12 讲）。
10. 换设备/换工况后还稳吗？CMN、z-norm、域适配至少做一个（第 6/12 讲）。

自检

- [ ] 我能不看讲义，把 15 个实验里任意 5 个的「预期现象 + 验收数字」说出来。
- [ ] 我知道遇到「频谱突然多出不该有的峰」「换设备就崩」「指标虚高」分别该翻哪一讲。
- [ ] 我能说清哪些资料是扫描版、为什么讲义没有照抄它们的公式。
- [ ] 我已经真的跑过至少 5 个实验，并写下了「预测 / 实测 / 差异 / 根因」四行记录。

第 15 讲

收尾：学习路线回顾与进阶方向

完整依赖链回顾

表 15-1 完整依赖链回顾

环节	核心问题	关键公式/数字	对应讲次
物理	声音是什么	$x(t)=A\cdot\sin(2\pi ft+\varphi)$；变压器基频 100 Hz	1
数字化	怎么变成数	$F_s>2f_{max}$；SNR≈6.02B+1.76；25 ms/10 ms	2
时域	响度/快慢/周期	$E=\Sigma x^2$；$Z=2fN/F_s$；$f_0=F_s/k_0$	3
频域	能量在哪些频率	$X[k]=\Sigma x\cdot e^{-j2\pi kn/N}$；$\Delta f=F_s/N$	4
时频	什么时候出现什么频率	$\Delta t\cdot\Delta f\approx 1$；25 ms→40 Hz	5
特征	怎么压成低维向量	Mel 26 通道；13+13+13=39 维	6
多分辨	瞬态怎么抓	$f\approx F_s/a$；3 层 DWT；IMF	7
模型	怎么从数据学规律	$\delta_2=p-y$；$\partial L/\partial W=a^T\delta$	8–9
评估	怎么知道模型好不好	P/R/F1；AUC；噪声衰减	10
判决	阈值定在哪	EER；2×EER；C_{det}	11–12
经典/深度	用什么模型	GMM-UBM；i-vector；x-vector	13–14

怎么验证自己"真的会了"

三关，从易到难，缺一不可：

> **三道出师关**
>
> 1. 能讲：合上讲义，向别人解释「为什么 MFCC 要取 log」。讲不清 = 只记住流程，没理解原因。
> 2. 能写：不看现成代码，写出能与 numpy 对拍到 10^{-10} 的 DFT。写不出 = 公式还停在纸面上。
> 3. 能改：给定新需求（如「要在 10 dB 噪声下识别局放」），能说出该改哪个环节、预期会怎样、怎么验证。 说不出 = 还不会用，只会复现。

第三关才是真正的分水岭。举个具体例子：要在强噪声下识别局放，你会怎么改？可以从四个层面答——数据层（加噪训练、谱减降噪）；特征层（换用对噪声更稳的特征，如谱平坦度、过零率，或学时频掩蔽）；模型层（多传感器融合、注意力机制）；评估层（报告噪声衰减曲线而不是单一准确率）。能把这四层串起来讲，就说明整条链路通了。

进阶方向（结合综述列出的挑战）

龚文洁等 2026 的综述把领域瓶颈列为五条：噪声鲁棒性、样本失衡、可解释性、标准化、跨模态融合。对应到可以动手的题目：

表 15-2　五个挑战与可做的题目

挑战	可做的题目	为什么有价值
噪声鲁棒性	在 0–20 dB 信噪比下系统评测 MFCC / 谱图 / 可学习前端三种方案的衰减曲线	直接对应现场最常见的失败模式
样本失衡	故障样本只有几十条时，比较重采样、代价敏感、少样本学习	现场故障本来就稀有
可解释性	把 CNN 的注意力热图叠回语谱图，看它是否真的在看谐波/脉冲	运维人员不信黑箱
标准化	统一采集协议 + 公开基准数据集	目前各研究各用私有数据，结果无法横比
跨模态	声纹 + 振动 + 温度的多源融合	单一声学通道信息量有限

如果只选一个，我建议做"统一评测"类的工作：把现有几种方法放在同一套数据、同一套指标下比较，并公开代码与数据划分。这类工作技术上不难，但对领域的价值比"再刷一个 99.x%"高得多——因为现在最缺的正是可比性。

最终自检（12 项总验收）

- ☐ 我能不看笔记写出正弦表达式，并说出三个物理量对应什么听感。
- ☐ 我能算出任意采样率、任意帧长下的点数与帧数。
- ☐ 我能解释混叠，并算出一个具体例子。
- ☐ 我能手算 4 点 DFT，并解释"投影"的含义。
- ☐ 我能算出给定窗长的 Δf，并说出它对分辨能力的影响。
- ☐ 我能默写 MFCC 七步，并说出每步的理由。
- ☐ 我能说出小波、EMD 各自解决什么问题、代价是什么。
- ☐ 我能推出 BP 的两条核心公式，并做一次梯度检查。
- ☐ 我能算出卷积的输出尺寸与参数量。
- ☐ 我能识别数据泄漏，并说出三种以上的过拟合对策。
- ☐ 我能解释 EER 与 2×EER，并用 DCF 比较两个阈值。
- ☐ 我能对一篇声纹论文提出至少两个方法学质疑。

推导详解 • 第 15 讲　从「能跑」到「能用」的检查清单

1. 一条完整流水线的参数表（可直接照抄）

环节	参数	取值	改错的后果
采集	F_s	8000 Hz / 16 bit	<2×最高频率 → 混叠，不可恢复
抗混叠	模拟低通截止	3.4 kHz	缺失 → 高频伪装成低频峰
预加重	α	设备声 0～0.45；语音 0.97	过大 → 100 Hz 基频被压 30 dB
分帧	L/S	200 / 80 点	无重叠 → OLA 重构失真
窗	汉明	0.54−0.46cos	矩形窗 → −13 dB 旁瓣、严重泄漏

环节	参数	取值	改错的后果
FFT	N	256（2 的幂）	补零只改显示密度，不改分辨率
幅度谱	$2/N$	直流除外	漏乘 → 幅值虚高 $N/2$ 倍
Mel	M	26	照搬语音配置 → 低频判别信息只占 2–3 通道
倒谱	n_{ceps}	$13 + \Delta + \Delta\Delta = 39$	只加维不加差分 → 误识别高约 20%
归一化	CMN	逐维减均值	漏做 → 换设备即崩
划分	按段分组	60/20/20	按帧随机切 → 指标虚高
判决	θ	在开发集上按 minDCF 选	测试集上调阈值 → 作弊

2. 排查问题的固定顺序（从前往后，别跳）

1. 时域：画原始波形，确认没削波、没有直流偏置、长度与 F_s 对得上。
2. 频域：画纯正弦的谱，确认峰值落在正确频率、幅值经 $2/N$ 后正确、旁瓣是加了窗的样子。
3. 特征：打印每一帧的形状与取值范围，确认 39 维、无 NaN、CMN 后各维均值≈0。
4. 模型：跑梯度检查（$< 10^{-8}$），确认一轮更新后损失确实下降（式 8-13）。
5. 划分：确认训练集与测试集没有共享同一段录音。
6. 评价：同时报 FAR/FRR/EER/minDCF 与试验次数，别只报准确率。

3. 三个可自己动手的「破坏性实验」

- 把 F_s 改成 **500 Hz**：看 100 Hz 基频附近凭空多出哪些峰，验证式 (2-10) 的混叠预测。
- 把汉明窗换成矩形窗：比较纯正弦谱的旁瓣高度，量出约 30 dB 的差异。
- 把 $\Delta/\Delta\Delta$ 去掉：在同样数据上对比分类准确率，复现「加差分比加维数更有效」的结论。

附 录

中英术语对照、章节映射与参考文献

常用术语对照

表 补-1 常用术语中英对照

中文	英文	缩写	一句话解释
声纹识别 / 说话人识别	speaker recognition / voiceprint recognition	—	用声音判断"是谁"
声纹验证	speaker verification	—	1:1 判断"是不是这个人"
声纹辨认	speaker identification	—	1:N 判断"是库里哪个人"
短时傅里叶变换	short-time Fourier transform	STFT	分帧做 FFT，得到时频图
梅尔倒谱系数	mel-frequency cepstral coefficients	MFCC	按人耳刻度压成的低维特征
感知线性预测	perceptual linear prediction	PLP	另一套听觉模型特征
等错误率	equal error rate	EER	FA=FR 时的错误率
错误接受率 / 错误拒绝率	false accept rate / false reject rate	FAR / FRR	误受 / 误拒
检测代价函数	detection cost function	DCF	把两类错误代价写进指标
高斯混合模型	Gaussian mixture model	GMM	多个高斯加权描述分布
通用背景模型	universal background model	UBM	描述"所有人"的通用分布
最大后验自适应	maximum a posteriori	MAP	从 UBM 微调到个人模型
身份向量	identity vector	i-vector	低秩总变化空间的坐标
嵌入码	embedding	x-vector / d-vector	神经网络输出的定长身份向量
概率线性判别分析	probabilistic linear discriminant analysis	PLDA	把身份与信道因子分开
支持向量机	support vector machine	SVM	最大间隔线性分类器
联合因子分析	joint factor analysis	JFA	i-vector 的前身
经验模态分解	empirical mode decomposition	EMD	按时间尺度自适应分解
本征模态函数	intrinsic mode function	IMF	EMD 分出的单尺度分量
离散小波变换	discrete wavelet transform	DWT	二进尺度的多分辨分解
倒谱均值归一化	cepstral mean normalization	CMN	减掉信道造成的加性偏移
加性角度间隔	additive angular margin	AAM-softmax	加大类间角度间隔的损失
统计池化	statistical pooling	—	用均值+标准差把变长压成定长
信噪比	signal-to-noise ratio	SNR	信号功率与噪声功率之比（dB）

与两本教材的章节映射

表 补-2 与两本教材的章节映射

本讲义	韩纪庆《语音信号处理》	王泉《声纹技术》
第 1 讲	2.1 语音产生、2.2 感知	1 声纹前世今生、2.2 声学基础
第 2 讲	3.1 数字化、3.1.2 加窗	2.3 采样量化、2.4 短时分析
第 3 讲	3.2 时域分析	2.5.1 时域特征
第 4 讲	3.3.2 傅里叶频谱分析	2.5.2 傅里叶变换
第 5 讲	3.4 时频分析、3.5 Gabor	2.5.2 STFT
第 6 讲	3.7.4 Mel 倒谱系数	2.5.5 MFCC
第 7 讲	3.6 小波变换	（EMD 为项目补充）
第 8–9 讲	6.10 深度学习语音识别	3.4 深度学习声纹
第 10 讲	（通用机器学习）	3.5 数据处理
第 11 讲	7.1 说话人识别概述	3.1 声纹识别核心
第 12 讲	7.2 阈值选取	3.2 评价指标
第 13 讲	7.2 GMM/UBM、7.5 i-vector	3.3 深度学习前方法
第 14 讲	7.5.2 基于 DNN 的 i-vector	3.4 深度学习、3.4.4 损失函数

说明：本讲义由两书核心知识重新组织编写，配合 `acoustic-lab` 复现项目使用。原书公式多为图片，本讲义公式按标准形式重写并注明出处；"伽马变换/Gammatone"与"EMD/经验模态分解"经全书检索确认两书均无，已明确标注为项目补充。

参考文献

表 补-3 参考文献

编号	文献
[1]	韩纪庆, 张磊, 郑铁然. 语音信号处理（第 3 版）. 北京: 清华大学出版社.
[2]	王泉. 声纹技术：从核心算法到工程实践.
[3]	龚文洁, 林国松, 韦晓广. 变压器声纹故障诊断研究综述. 电子与信息学报, 2026, 48(4): 1591–1607.
[4]	张重远, 罗世豪, 岳浩天, 王博闻, 刘云鹏. 基于 Mel 时频谱-卷积神经网络的变压器铁芯声纹模式识别方法. 高电压技术, 2020, 46(2): 413–423.
[5]	刘云鹏, 王博闻, 岳浩天, 等. 基于 50 Hz 倍频倒谱系数与门控循环单元的变压器偏磁声纹识别. 中国电机工程学报, 2020, 40(14): 4681–4694.
[6]	齐子豪, 仝杰, 张中浩, 等. 基于多粒度知识特征和 Transformer 网络的电力变压器故障声纹辨识方法. 中国电机工程学报, 2025, 45(4): 1311–1322.
[7]	李嘉宁, 李喆, 盛戈皞. 含噪背景下 GIS 操作机构声纹信号可学习特征提取及辨识方法. 高电压技术, 2025, 51(11): 5516–5525.
[8]	李楠, 马宏忠, 段大卫, 等. 基于多传感器融合声纹特征图谱的变压器铁芯松动故障诊断方法. 振动与冲击, 2023, 42(15).
[9]	陆云才, 廖才波, 李群, 等. 基于声纹特征和集成学习的变压器缺陷诊断方法. 电力工程技术, 2023, 42(5): 46–55.

编号	文献
[10]	张瀞. 电力设备故障声学检测技术综述及展望. 2022.

说明：上表只列出本讲义正文实际引用、且已核对过原文的文献。[10] 为综述性文献，用于了解领域全貌；其余为具体方法文献，正文引用处均标注了其原文自报指标。所有自报指标都来自各自的数据集与实验条件，不可横向比较。

常用常数与换算速查

表 补-4　常用常数与换算速查

量	公式 / 数值	示例
频率分辨率	Δf = Fs / N	8 kHz、256 点 → 31.25 Hz
帧内点数	点数 = 时长(ms)·Fs/1000	16 kHz、25 ms → 400 点
帧数	floor((N−L)/S)+1	16000、L=400、S=160 → 98
量化信噪比	SNR ≈ 6.02B + 1.76 dB	16 bit → 98 dB
过零率与频率	f = Z·Fs/(2N)	Z=25、N=200、8 kHz → 500 Hz
自相关求基频	f_0 = Fs / k_0	k_0=80、8 kHz → 100 Hz
Mel 刻度	mel = 2595·$\log_{10}$(1+f/700)	1000 Hz → 1000 mel
小波尺度换算	f ≈ Fs / a	8 kHz、a=80 → 100 Hz
卷积输出	(H−F+2P)/S+1	32、F=3、P=1、S=1 → 32

附录 · 全书符号总表与公式速查

A. 符号总表

符号	含义	首次出现
$x(t), x[n]$	连续 / 离散信号	第 1、2 讲
F_s, T_s, N	采样率、采样间隔、点数	第 2 讲
L, S, M	帧长、帧移、帧数 / 滤波器数	第 2、6 讲
$w[n]$	窗函数	第 2 讲
$X[k], X[m,k]$	DFT / STFT 系数	第 4、5 讲
W_N	旋转因子 $e^{-j2\pi/N}$	第 4 讲
$P[k], H_m[k], E_m, L_m, c_i$	功率谱、Mel 滤波器、通道能量、对数能量、倒谱系数	第 6 讲
a, b, ψ, cA_j, cD_j	尺度、平移、母小波、近似/细节系数	第 7 讲
$W, \mathbf{b}, \mathbf{z}, \mathbf{h}, \boldsymbol{\delta}$	权重、偏置、净输入、激活、误差信号	第 8 讲
η, λ, γ	学习率、正则系数、动量系数	第 8、10 讲
F, P, S, RF	核大小、padding、步长、感受野	第 9 讲

符号	含义	首次出现
$\theta, \mathrm{FAR}, \mathrm{FRR}, \mathrm{EER}, C_{\mathrm{det}}$	阈值、两类错误率、等错误率、检测代价	第 12 讲
$\pi_c, \boldsymbol{\mu}_c, \Sigma_c, \gamma_{tc}$	GMM 权重/均值/协方差、责任度	第 13 讲
$\mathbf{M}, \mathbf{m}, T, \mathbf{w}$	超矢量、UBM 超矢量、总变化空间、i-vector	第 13 讲
$\mathbf{e}, \boldsymbol{\mu}, \boldsymbol{\sigma}$	embedding、统计池化均值/标准差	第 14 讲

B. 公式速查（按用途）

用途	公式	编号
采样	$x[n] = x(n/F_s)$	2-1
奈奎斯特条件	$F_s > 2f_{\max}$	2-2
混叠频率	$f_{\mathrm{alias}} = \min_k \lvert f - kF_s \rvert$	2-3
量化信噪比	$\mathrm{SNR}_{\mathrm{dB}} = 6.02B + 1.76$	2-4
DFT	$X[k] = \sum_n x[n] W_N^{kn}$	4-2
IDFT	$x[n] = \frac{1}{N}\sum_k X[k] e^{j2\pi kn/N}$	4-9
单边幅度谱	$A[k] = 2\lvert X[k] \rvert / N$	4-5
真实分辨率	$\Delta f = 1/T_{\mathrm{obs}} = F_s/N_0$	4-6
FFT 复杂度	$\frac{N}{2}\log_2 N$	4-6
STFT	$X[m,k] = \sum_n x[n] w[n - mS] e^{-j2\pi kn/N}$	5-1
时频不确定	$\Delta t \, \Delta f \geq 1/(4\pi)$	5-2
Mel 刻度	$m(f) = 2595 \log_{10}(1 + f/700)$	6-3
通道能量	$E_m = \sum_k P[k] H_m[k]$	6-4
对数能量	$L_m = \ln(E_m + \varepsilon)$	6-5
DCT-II	$c_i = \sqrt{2/M}\sum_m L_m \cos[\frac{\pi i}{M}(m - \frac{1}{2})]$	6-6
一阶差分	$d_t = \frac{\sum_n n(c_{t+n} - c_{t-n})}{2\sum_n n^2}$	6-7
CWT	$W(a,b) = \int x(t) \overline{\psi((t-b)/a)} / \sqrt{a} \, \mathrm{d}t$	7-1
softmax	$p_c = e^{z_c} / \sum_j e^{z_j}$	8-2
交叉熵	$L = -\sum_c y_c \ln p_c$	8-3
输出层误差	$\boldsymbol{\delta}_2 = \mathbf{p} - \mathbf{y}$	8-4
隐层误差	$\boldsymbol{\delta}_1 = (W_2^{\mathsf{T}} \boldsymbol{\delta}_2) \odot \sigma'(\mathbf{z}_1)$	8-5
卷积尺寸	$H_{\mathrm{out}} = \lfloor (H_{\mathrm{in}} + 2P - F)/S \rfloor + 1$	9-2
检测代价	$C_{\mathrm{det}} = C_{\mathrm{FR}}\mathrm{FRR}P_{\mathrm{tar}} + C_{\mathrm{FA}}\mathrm{FAR}P_{\mathrm{nontarget}}$	12-5
GMM	$p(\mathbf{x} \mid \lambda) = \sum_c \pi_c \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_c, \Sigma_c)$	13-1
i-vector	$\mathbf{M} = \mathbf{m} + T\mathbf{w}$	13-5

用途	公式	编号
统计池化	$\mathbf{e} = [\boldsymbol{\mu}; \boldsymbol{\sigma}]$	14-1

C. 关于公式排版的说明

本版起，全部公式改用 **KaTeX** 排版（本地字体，离线可用），并按「讲-序」编号。 编号如 **(4-9)** 中的 4 表示第 4 讲、9 表示该讲的公式序号；带「推导详解」字样的编号（如 4-9、6-10） 出现在各讲末尾的推导补充中，与正文公式属于同一编号体系。 所有下式里的中文说明、变量表、数值算例都放在公式之外，以免中文字形干扰数学排版。